

音声基盤モデルは人間と同様の知覚的話者類似性を持つのか？

八木 颯斗^{†1} 岸 秀^{†*1} 高道 慎之介^{1,2} 齋藤 佑樹²

概要：本研究では、音声基盤モデルにおける話者埋め込みの類似性と、人間の知覚的話者類似性との対応関係について比較分析を行う。人間は2話者の音声がどの程度似ているかを連続的な尺度で判断する能力を有している。一方、音声基盤モデルでは話者の特徴は数値ベクトルとして表現されるが、その埋め込み空間における距離が、人間の知覚的話者類似性とどの程度一致しているかは明らかでない。そこで本研究では、40以上のモデルを対象に、モデルが算出する埋め込みの間の距離と、人間による知覚的話者類似性との関係を包括的に検証する。さらに、知覚的話者類似性と整合的な話者埋め込みの獲得に寄与するモデル設計要因についても分析を行う。本研究の結果は、人間の知覚に基づいた音声基盤モデルの設計に向けた有用な知見を提供する。

1. はじめに

音声には話者情報が含まれており、人間はそれを聴取によって容易に知覚できる [1]。また、人間は2つの音声の同一話者によるものかどうかを判別するだけでなく、異なる話者による2つの音声のどの程度似ているか、あるいは似ていないかも判断できる [2]。このような知覚的話者類似性 [3] は、音響特徴量だけでは十分に説明できない高次の知覚機能である [4]。

一方、近年の音声基盤モデル（自己教師あり学習モデル (self-supervised learning; SSL) [5], [6], [7] および大規模教師あり学習モデル [8], [9]）は、音声に含まれる話者性を高精度に捉えることが示されている。これらの内部表現は話者認証に有効であり [10], [11]、さらに各種のプロービング実験 [12], [13] によっても、識別的な話者埋め込みを獲得していることが確認されている。

しかし、これらの音声基盤モデルが、人間の知覚と整合する形で話者間の“類似性の程度”を捉えているかどうかは明らかではない。言い換えれば、話者埋め込み間の幾何学的関係、すなわち話者埋め込み類似性は、人間の知覚的話者類似性とどのように対応しているのだろうか。もしこれらのモデルが人間の知覚と整合的な表現を獲得している




図 1 本論文の概念図。

ならば、高次の知覚機能がデータのみから創発しうることを示唆する。さらに、どのようなモデル設定がこの対応関係に寄与するかを明らかにできれば、人間らしい話者知覚を備えた音声基盤モデルの設計に重要な知見を与えることができる。

以上を踏まえ、本研究では話者埋め込み類似性と知覚的話者類似性の対応関係を検討する (図 1)。40以上の音声基盤モデルと知覚的話者類似性スコア [14], [15] を用いて、どのモデルのどの層が人間の知覚と整合的な話者埋め込みを与えるかを分析する。さらに、重回帰分析により、モデル設定の各要因がこの対応度を与える影響を定量的に評価する。

2. 関連研究

2.1 知覚的話者類似性

知覚的話者類似性スコアは、異なる2話者の音声対を人間の聴取者に提示し、その類似度を数値で評価させることで得られる。例えば先行研究 [3] では、複数の聴取者に対

*† 両著者は本研究に等しく貢献した (equal contribution)。

¹ 慶應義塾大学
3-14-1 Hiyoshi, Kohoku-ku, Yokohama-shi, Kanagawa 223-8522, Japan.

² 東京大学
The University of Tokyo, 7-3-1 Hongo, Bunkyo-ku, Tokyo 113-8656, Japan.

し、 -3 （完全に異なる）から $+3$ （非常に似ている）の 7 段階尺度で評価を行っている。各話者対に対して得られたスコアは、全聴取者で平均される。この手続きを話者集合内のすべての話者組み合わせに対して繰り返すことで、収集されたデータはノードを話者、エッジの重みを類似度スコアとした重み付き無向グラフとして表現できる。

2.2 音声基盤モデルの分析

多くの音声基盤モデルは複数の Transformer 層によって構成されており、各層が捉える特徴に関する分析が進められている [5], [6], [7]。一般に、下位層はピッチやエネルギー [12]、性別 [16] といった低次の音響情報を主に捉える。一方、中間層は話者識別 (SID) や話者認証 (ASV) において高い性能を示し、識別的な話者関連情報が顕著に表現されていることが示唆されている [13]。

本研究では、知覚的話者類似性に関する分析結果を、これらの層ごとの特性に関する知見と対応付けて考察する。

3. 提案手法

3.1 知覚的話者類似性

話者集合を S とする。任意の話者対 $(i, j) \in S$ ($i \neq j$) に対して、知覚的話者類似性スコアを $c_{i,j}^{(\text{human})} \in \mathbb{R}$ と定義する。これらのスコア集合は $W^{(\text{human})} = \{c_{i,j}^{(\text{human})} \mid i, j \in S, i \neq j\}$ と表される。

これを重み付き無向グラフとして表現すると、 $G^{(\text{human})} = (S, E, W^{(\text{human})})$ と表せる。ここで、ノード集合およびエッジ重み集合はそれぞれ S および $W^{(\text{human})}$ に対応し、エッジ集合は $E = \{(i, j) \mid i, j \in S, i \neq j\}$ である。このグラフは自己ループを除く完全グラフである。

3.2 話者埋め込み類似性

話者埋め込みを抽出するために、音声基盤モデルにおける入力層から特定の Transformer 層までの変換関数を $f(\cdot)$ と定義する。話者 i の発話 x_i を入力したとき、当該 Transformer 層の出力は隠れ状態列 $f(x_i) = \{\mathbf{h}_{i,t}\}_{t=1}^T$ として得られる。ここで T はフレーム数を表す。話者埋め込み $\mathbf{e}_i$ は、これらの隠れ状態を全フレームおよび全発話にわたって平均したベクトルとして定義する。この処理を話者集合 S 内のすべての話者に対して行う。

得られた表現は重み付き無向グラフ $G^{(\text{model})} = (S, E, W^{(\text{model})})$ として表される。話者対 (i, j) に対する類似性スコア $c_{i,j}^{(\text{model})}$ は、それぞれの埋め込み $\mathbf{e}_i$ と $\mathbf{e}_j$ のコサイン類似度として定義する。エッジ重み集合は $W^{(\text{model})} = \{c_{i,j}^{(\text{model})} \mid i, j \in S, i \neq j\}$ である。

3.3 知覚的話者類似性と話者埋め込み類似性の対応関係

人間の知覚とモデル表現の対応関係を定量化するために、上記で定義した 2 つのグラフ $G^{(\text{human})}$ と $G^{(\text{model})}$ の

類似度を以下の 3 つの指標により評価する。

話者ペア単位での類似度相関。 両グラフのエッジ重みの直接的な相関を評価する。具体的には、 $\{c_{i,j}^{(\text{human})}\}$ と $\{c_{i,j}^{(\text{model})}\}$ の間の Pearson 相関係数 (LCC) および Spearman 順位相関係数 (SRCC) を計算する。グラフは無向であるため、 (i, j) と (j, i) の重複を除去し、各話者対を一度のみ用いる。

フロベニウス距離。 類似度スコアを隣接行列（重み付きグラフの類似度行列）として扱い、構造的な差異を評価する。 $\mathbf{A}^{(\text{human})}$ および $\mathbf{A}^{(\text{model})}$ をそれぞれの隣接行列とし、その (i, j) 成分を $c_{i,j}^{(\text{human})}$ および $c_{i,j}^{(\text{model})}$ とする。これら 2 つの行列のフロベニウス距離を計算することで、要素ごとの差異を定量化する。

スペクトル距離。 グラフの大域的構造を比較するためにスペクトル解析を用いる。各グラフの隣接行列から正規化グラフラプラシアンを計算し、その固有値を求める。そのうちゼロでない最小の k 個の固有値について ℓ_2 距離を計算する。この指標は低周波成分に対応する構造、すなわち話者クラスタ構造の類似性を反映する。

4. 実験

4.1 実験設定

知覚的話者類似性。 知覚的話者類似性データセットとして、JVS (男性 49 名、女性 51 名) [14] および VCTK (女性 52 名) [15], [17] を用いた。各データセットでは、同一性別内のすべての話者組み合わせに対して $[-3, 3]$ のスコアが付与されている。本研究ではこれらを $[0, 1]$ に正規化して用いた。

話者埋め込み類似性。 評価対象として、6 種類に分類される合計 43 個のオープンソースモデルを用いた。モデルのラベルは公式名称に従う。

- **教師あり自動音声認識 (automatic speech recognition; ASR) モデル:** Parakeet (parakeet- $\{\text{c_tc, rnn}\}$ - $\{0.6\text{b}, 1.1\text{b}\}$, parakeet-tdt- 0.6b - $\{v2, v3\}$, parakeet-tdt- 1.1b) [9]^{*1} and Whisper (whisper- $\{\text{small, base, medium, large}\}$) [8]^{*2}
- **教師ありテキスト音声合成 (text-to-speech; TTS)**: Qwen3-TTS (qwen3-tts- 12hz - $\{0.6\text{b}, 1.7\text{b}\}$ -base) [18]^{*3}, SpeechT5 (speecht5- $\{\text{base, large, tts}\}$) [19]^{*4}, SpeechGPT (speechgpt- 7b - $\{\text{ma, cm}\}$) [20]^{*5}, and VALL-E X (vallex- $\{\text{q01--q08}\}$) [21]^{*6}.

^{*1} <https://huggingface.co/nvidia/models>

^{*2} <https://github.com/openai/whisper>

^{*3} <https://github.com/QwenLM/Qwen3-TTS>

^{*4} <https://github.com/microsoft/speecht5>, https://huggingface.co/microsoft/speecht5_tts

^{*5} <https://github.com/Onutiation/SpeechGPT>

^{*6} <https://github.com/Plachtaa/VALL-E-X> ($\{\text{q01--q08}\}$ indicates index of the codebook.)




図 2 全モデルおよび全 Transformer 層における LCC.

- 教師ありテキスト環境音合成 (text-to-audio; TTA)
モデル: AudioGen (audiogen-medium) [22]^{*7}.
- 教師あり環境音分類モデル:
AST (ast_audioset_10_10_0.4593) [23]^{*8}.
- 音声 SSL モデル: HuBERT (hubert-{base-ls960, large-1l160k, large-ls960-ft}) [6]^{*7}, wav2vec 2.0 (wav2vec2-{base, base-960h, large, large-960h, large-xlrs-53}) [5]^{*7}, and WavLM (wavlm-{base, base+, large, ssl_sv}) [7], [11]^{*9}.
- 一般音 SSL モデル: ATST-Frame (atstframe_base) [24]^{*10}.

音声以外の一般音を含むデータで学習されたモデルの影響を調べるため、TTA、一般音 SSL、環境音分類のモデルも含めた。TTS/TTA モデルについては、音声/音響プロンプトを入力として受け取ることが可能なアーキテクチャを選択した。特徴抽出の際には、音声プロンプトのみを入力とし、テキストを含むその他の入力、モデル内部の話者表現を分離するためにパディングとして扱った。各話者について 10 発話から埋め込みを抽出した。各埋め込み次元は z-score 正規化を行い、類似度は [0, 1] に正規化した。

スペクトル距離の設定。スペクトル解析 (3.3 節) では固有値数を $k = 10$ とした。 k の変化は全体傾向に大きな影響を与えないことを確認している。

4.2 全体傾向：定性的分析

全体傾向を把握するために、全モデルの全 Transformer 層における対応スコアを算出した。図 2 は全データセットで平均した LCC を示す。モデルごとに層数が異なるため、層インデックスは [0, 1] に正規化している。この可視化から、以下の観察結果が得られる。なお、簡潔さのため省略

するが、他のデータセットや評価指標においても同様の傾向が確認された。

モデル間でスコアのばらつきが大きい。例えば、WavLM は多くの層で高いスコアを示す一方、Qwen3-TTS は低い値を示す。これは対応関係がモデル設定に強く依存することを示唆する。

層ごとのスコア推移に多様な傾向が見られる。類似性の相関が層の深さに応じてどのように変化するかについて、明確に異なるパターンが観察された。多くのモデルでは深い層ほど相関が低下するが、AudioGen や VALL-E X では逆に向上する傾向が見られる。このことから、層方向のスコア変化の傾きはモデル設定に依存する特性であるといえる。

4.3 モデル設定の影響：重回帰分析

4.2 節で観察された全体傾向にどのようなモデル設定が寄与しているかを明らかにするために、重回帰分析を行った。説明変数は以下のように定義する：

- is_dec: モデルがデコーダ型構造か (1), エンコーダ型構造か (0) を示す二値変数。
- is_mlang: モデルが多言語データで学習されているか (1), 単一言語データで学習されているか (0) を示す二値変数。
- is_ssl: 自己教師あり学習モデル (1) か教師あり学習モデル (0) かを示す二値変数。ファインチューニングされた SSL モデルは教師あり (0) として扱う。
- hours: 学習データ量 [時間] (対数スケール)。
- params: モデルのパラメータ数 (対数スケール)。

二値変数はカテゴリ的な構成を表し、連続変数 (hours, params) は標準化されている。

各モデルの層ごとの挙動を特徴付けるために、以下の 2 つの目的変数を定義する：

- layer_max: モデル内の全 Transformer 層における指標値の最大値。
- layer_slope: 正規化された Transformer 層インデッ

^{*7} <https://huggingface.co/facebook/models>

^{*8} <https://github.com/YuanGongND/ast>

^{*9} https://huggingface.co/docs/transformers/model_doc/wavlm, https://github.com/theolepage/wavlm_ssl_sv/blob/main/README.md

^{*10} <https://github.com/Audio-WestlakeU/audioss1/blob/main/audioss1/methods/ATST-Frame/README.md>

表 1 モデル構成を説明変数とした重回帰分析における係数 (p 値). 太字は $p < 0.05$ で有意な係数を示す.

Response variable	is_dec	is_mlang	is_ssl	hours	params	R^2
layer_max						
LCC	-0.77 ($< .001$)	0.00 (0.992)	-0.14 (0.020)	-0.12 (0.117)	-0.14 (0.022)	0.747
SRCC	-0.79 ($< .001$)	-0.03 (0.687)	-0.15 (0.015)	-0.10 (0.182)	-0.15 (0.010)	0.764
Neg. Frobenius norm	-0.22 ($< .001$)	-0.02 (0.407)	-0.01 (0.359)	-0.01 (0.568)	0.05 (0.002)	0.983
Neg. spectral dist.	0.03 (0.529)	-0.16 (0.008)	-0.15 (0.003)	0.10 (0.096)	-0.03 (0.550)	0.835
layer_slope						
LCC	0.31 (0.002)	0.10 (0.425)	0.06 (0.610)	-0.26 (0.054)	0.29 (0.008)	0.205
SRCC	0.29 (0.004)	0.14 (0.297)	0.09 (0.424)	-0.24 (0.083)	0.26 (0.017)	0.184
Neg. Frobenius norm	-0.12 (0.240)	0.20 (0.152)	-0.02 (0.890)	0.06 (0.650)	0.07 (0.553)	0.123
Neg. spectral dist.	0.09 (0.340)	0.54 ($< .001$)	0.20 (0.058)	-0.15 (0.275)	0.13 (0.211)	0.241

クスに対して各指標値を線形回帰したときの傾き.

これらの変数は, 3.3 節で述べた 4 つの指標すべてについて計算した. フロベニウス距離およびスペクトル距離については, “値が大きいほど良い” という解釈を LCC および SRCC と一致させるために, 符号を反転した.

分析の信頼性を担保するために, 事前にすべての変数に対する分散拡大係数 (VIF) を確認したところ, 十分に低い値であり, 多重共線性が結果に影響していないことを確認した. さらに, モデル設定の効果を分離するために, データセット間の差 (例: JVS と VCTK) に起因するバイアスを制御する目的で, 回帰モデルにデータセット固定効果を導入した. なお, 本回帰分析では音声モデルに焦点を当てるため, 音声関連モデルは除外している. 表 1 に回帰結果を示す. これらの結果から, 以下の知見が得られる.

エンコーダ型構造は人間知覚と整合的な表現形成を促進する. is_dec の係数は layer_max に関する 3 つの指標すべてにおいて有意に負 ($p < 0.001$) であった. これは, デコーダ型はエンコーダ型に比べて人間の知覚との整合性が低い話者埋め込みを形成する傾向があることを示している.

大規模教師ありモデルは人間知覚とより整合する. is_ssl も同様に layer_max に関する 3 つの指標すべてにおいて負の有意な係数 ($p < 0.001$) を示した. これは, 大規模教師ありモデルの方が SSL モデルと比較して, 人間の知覚に対応する話者埋め込みを獲得しやすいことを示唆している.

パラメータ増加は平均な整合性を下げるが層間変動を平坦化する. LCC および SRCC において, params は layer_max に対して負の影響を持つ一方で, layer_slope に対しては正の影響を持つ. 4.2 節で述べた通り, 一般的に layer_slope は負の傾向を示すため, ここで正の係数が得られるということは, モデルサイズが大きくなるほど, 層間におけるスコア分布が平坦化することを意味する. 同様の傾向は is_dec 変数についても観察される.

モデル設定は平均スコアを強く説明するが層傾向の説




図 3 SSL モデルにおける層ごとの傾向.

明力は低い. 決定係数は layer_max で約 0.8 に達する一方で, layer_slope で約 0.2 に留まる. この乖離は, 話者表現の全体的な性能は現在のモデル設定によってよく説明される一方で, 各層がどのように寄与するかという相対的な挙動については, 本研究で用いた説明変数では捉えきれていない要因の影響を受けていることを示唆している.

4.4 個別モデルおよび要因の分析

4.4.1 SSL モデルのファインチューニングの影響

SSL モデルではファインチューニング目的により傾向が大きく異なる. ASR 用にファインチューニングされたモデル (例: hubert-large-ls960-ft や wav2vec2-{base-960h, large-960h}) は, SSL のみで学習された対応モデル (例: hubert-large-ll60k や wav2vec2-{base, large}) と比較して, 層が深くなるにつれて, モデルの話者埋め込み類似性と人間の知覚的話者類似性との整合性が低下する. こ




図 4 一般音で学習されたモデルの LCC. 比較のため、一部の音声モデルも併せて示す。

れは、ASR のファインチューニングによって表現が言語内容寄りにシフトし、話者に関連する変動が抑制されるためと考えられる [25]. 図 3 の上段および中段に示されているように、ASR ファインチューニングモデルではすべての指標において低下が観察される。

一方で、話者関連タスクに最適化されたモデルは異なる傾向を示す。図 3 の下段に示されているように、wavlm-base+ (SSL のみ) と比較して、話者表現学習のために提案された wavlm-ssl_sv [11] は、層方向の変化がより平坦である。この場合、すべての指標が層を通して比較的安定しており、ネットワーク全体で話者類似構造が保持されることを示す。

これらの観察結果は、ファインチューニングの目的が SSL モデルにおける表現の層構造に影響を与えることを示唆しており、これはファインチューニングが主にエンコーダの深い層を変化させることを示した先行研究 [26], [27] と一致している。

4.4.2 一般音で学習されたモデル

音声以外の一般音で学習されたモデルが人間の知覚とどのように関係するかを分析するために、図 4 に LCC を示す。SRCC, フロベニウス距離, スペクトル距離は省略しているが、いずれも LCC と同様の傾向を示す。TTA モデルおよび音声 SSL モデルは、場合によっては音声のみで学習されたモデルよりも高いスコアを達成することがある。

特に TTA モデルである audiotgen-medium は層が深くなるにつれて単調にスコアが向上する。これは、audiotgen-medium が音生成モデルとして学習されていることから、深い層ほど音色や詳細な音響特性をより豊かに表現し、人間の知覚的話者類似性に近い表現が形成されるためと考えられる。

一方、環境音分類モデルである ast_audioset_10_10_0.4593 は中間層でピークを示し、後半層では低下する。これは、この種のカテゴリ情報が主に中間層にエンコードされるためであり、後段の層では、音声・笑い・泣き声・歌声といったイベントレベルのラベルに基づいて人間の音を認識する傾向が強く、細粒度な話者特性に基づく表現が弱まるためと考えられる。

最後に、atstframe_base は全層にわたり比較的平坦な傾向を示す。このモデルは多様な音を対象に学習されており、特定のタスクに特化していないため、ネットワーク全体にわたって音響表現が比較的一様に扱われていると解釈できる。

5. おわりに

本研究では、音声基盤モデルにおける話者表現が、人間の知覚的話者類似性をどの程度反映しているかを検証した。その結果、人間の知覚との対応関係はモデル設定に依存して大きく異なることが明らかとなった。また、層方向の振る舞いもモデル設定に依存し、さらにファインチューニングの目的が話者表現に影響を与えることが確認された。これらの知見は、モデル構造や学習戦略が知覚的に意味のある話者表現の獲得にどのように影響するかについての示唆を提供する。

謝辞 本研究は、JST 創発的研究支援事業 JP-MJFR226V, JSPS 科研費 23K28108, 内閣府ムーンショット型研究開発制度「誰もが自在に活躍できるアバター共生社会の実現」の支援を受けて実施した。

参考文献

- [1] P. Belin, R. Zatorre, P. Lafaille, P. Ahad, and B. Pike, "Voice-selective areas in human auditory cortex," *Nature*, vol. 403, pp. 309–312, 2000.
- [2] T. Kitamura, T. Nakama, H. Ohmura, and H. Kawamoto, "Measurement of perceptual speaker similarity for sentence speech in ATR speech database," *Journal of the Acoustical Society of Japan*, vol. 71, no. 10, pp. 516–525, 2015, (in Japanese).
- [3] Y. Saito, S. Takamichi, and H. Saruwatari, "Perceptual-similarity-aware deep speaker representation learning for multi-speaker generative modeling," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 29, pp. 1033–1048, 2021.
- [4] S. Liu, M. Babel, and J. Zhu, "A comparison of voice similarity through acoustics, human perception and deep neural network (DNN) speaker verification systems," in *Interspeech*, 2024, pp. 3674–3678.
- [5] A. Baevski, Y. Zhou, A. Mohamed, and M. Auli, "wav2vec 2.0: A framework for self-supervised learning of speech representations," in *NeurIPS*, vol. 33, 2020, pp. 12 449–12 460.
- [6] W.-N. Hsu, B. Bolte, Y.-H. H. Tsai, K. Lakhotia, R. Salakhutdinov, and A. Mohamed, "HuBERT: Self-supervised speech representation learning by masked prediction of hidden units," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 29, pp. 3451–3460, 2021.
- [7] S. Chen, C. Wang, Z. Chen, Y. Wu, S. Liu, Z. Chen, J. Li, N. Kanda, T. Yoshioka, X. Xiao, J. Wu, L. Zhou, S. Ren, Y. Qian, Y. Qian, J. Wu, M. Zeng, X. Yu, and F. Wei, "WavLM: Large-scale self-supervised pre-training for full stack speech processing," *IEEE Journal of Selected Topics in Signal Processing*, vol. 16, no. 6, pp. 1505–1518, 2022.
- [8] A. Radford, J. W. Kim, T. Xu, G. Brockman,

- C. McLeavey, and I. Sutskever, “Robust speech recognition via large-scale weak supervision,” in *ICML*, 2023.
- [9] D. Rekish, S. Krizan, S. Majumdar, V. Noroozi, H. Juang, O. Hrinchuk, A. Kumar, and B. Ginsburg, “Fast conformer with linearly scalable attention for efficient speech recognition,” *ASRU*, pp. 1–8, 2023.
- [10] Z. Chen, S. Chen, Y. Wu, Y. Qian, C. Wang, S. Liu, Y. Qian, and M. Zeng, “Large-scale self-supervised speech representation learning for automatic speaker verification,” in *ICASSP*, 2022, pp. 6147–6151.
- [11] V. Miara, T. Lepage, and R. Dehak, “Towards supervised performance on speaker verification with self-supervised learning by leveraging large-scale asr models,” in *Interspeech*, 2024, pp. 2660–2664.
- [12] A. Y. F. Chiu, K. C. Fung, R. T. Y. Li, J. Li, and T. Lee, “A large-scale probing analysis of speaker-specific attributes in self-supervised speech representations,” *arXiv preprint arXiv:2501.05310*, 2025.
- [13] T. Ashihara, M. Delcroix, T. Moriya, K. Matsuura, T. Asami, and Y. Ijima, “What do self-supervised speech and speaker models learn? new findings from a cross model layer-wise analysis,” in *ICASSP*, 2024, pp. 10 166–10 170.
- [14] S. Takamichi, K. Mitsui, Y. Saito, T. Koriyama, N. Tanji, and H. Saruwatari, “JVS corpus: free japanese multi-speaker voice corpus,” *arXiv preprint arXiv:1908.06248*, 2019.
- [15] J. Yamagishi, C. Veaux, and K. MacDonald, “CSTR VCTK Corpus: English multi-speaker corpus for CSTR voice cloning toolkit (version 0.92),” 2019.
- [16] A. Krishnan, B. M. Abdullah, and D. Klakow, “On the encoding of gender in transformer-based asr representations,” in *Interspeech*, 2024, p. 3090–3094.
- [17] Y. Saito, S. Takamichi, and H. Saruwatari, “DNN-based speaker embedding using subjective inter-speaker similarity for multi-speaker modeling in speech synthesis,” in *ISCA SSW*, 2019, pp. 97–102.
- [18] H. Hu, X. Zhu, T. He, D. Guo, B. Zhang, X. Wang, Z. Guo, Z. Jiang, H. Hao, Z. Guo, X. Zhang, P. Zhang, B. Yang, J. Xu, J. Zhou, and J. Lin, “Qwen3-TTS technical report,” *arXiv preprint arXiv:2601.15621*, 2026.
- [19] J. Ao, R. Wang, L. Zhou, C. Wang, S. Ren, Y. Wu, S. Liu, T. Ko, Q. Li, Y. Zhang, Z. Wei, Y. Qian, J. Li, and F. Wei, “SpeechT5: Unified-modal encoder-decoder pre-training for spoken language processing,” in *ACL*, 2022, pp. 5723–5738.
- [20] D. Zhang, S. Li, X. Zhang, J. Zhan, P. Wang, Y. Zhou, and X. Qiu, “SpeechGPT: Empowering large language models with intrinsic cross-modal conversational abilities,” in *Findings of the Association for Computational Linguistics: EMNLP*, 2023, pp. 15 757–15 773.
- [21] Z. Zhang, L. Zhou, C. Wang, S. Chen, Y. Wu, S. Liu, Z. Chen, Y. Yan, H. Liu, J. Jiao *et al.*, “Speak foreign languages with your native tongue: Cross-lingual neural codec language modeling,” *arXiv preprint arXiv:2303.03926*, 2023.
- [22] F. Kreuk, G. Synnaeve, A. Polyak, U. Singer, A. Défossez, J. Copet, D. Parikh, Y. Taigman, and Y. Adi, “AudioGen: Textually guided audio generation,” in *ICLR*, 2023.
- [23] Y. Gong, Y.-A. Chung, and J. Glass, “AST: Audio spectrogram transformer,” in *Interspeech*, 2021, pp. 571–575.
- [24] X. Li, N. Shao, and X. Li, “Self-supervised audio teacher-student transformer for both clip-level and frame-level tasks,” *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 32, pp. 1336–1351, 2024.
- [25] A. Pasad, J.-C. Chou, and K. Livescu, “Layer-wise analysis of a self-supervised speech representation model,” in *ASRU*, 2021, pp. 914–921.
- [26] Y. El Kheir, A. Ali, and S. A. Chowdhury, “Speech representation analysis based on inter- and intra-model similarities,” in *ICASSP Workshops*, 2024, pp. 848–852.
- [27] A. Fuente and D. Jurafsky, “A layer-wise analysis of mandarin and english suprasegmentals in ssl speech models,” in *Interspeech*, 2024, pp. 1290–1294.