


(61) [一般発表] 音声基盤モデルは人間と同様の知覚的話者類似性を持つのか？

◎岸 秀, ◎八木 颯斗 (慶應義塾大学), 高道 慎之介 (慶應義塾大学/東京大学), 齋藤 佑樹 (東京大学)

1. はじめに

- 人間: どれくらい声が似ているかを連続的に知覚可能 [1]
- 音声基盤モデル:
 - 音声から埋め込みベクトルを抽出
 - 埋め込みの類似度を話者識別タスクに利用可能 [2-4]



モデル内の話者埋め込み類似性は人間の知覚的話者類似性と整合するか？

- 話者埋め込み類似性と知覚的話者類似性が整合する場合:
 - 高次の知覚機能がデータのみから創発する可能性を示唆
 - 人間知覚と整合する音声基盤モデル設計への知見を提供
- 本研究の目的:
 - 43モデル × 全 Transformer 層を分析
 - 人間知覚と整合するモデル設計要因を解明

2. 提案法

- 類似性の無向完全グラフ表現
 - ノード (話者) 集合 S
 - エッジ (話者間) 集合 $E = \{\{i, j\} \mid i, j \in S, i \neq j\}$
 - エッジ重み $W = \{c_{i,j} \mid i, j \in S, i \neq j\}$

$$G = (S, E, W)$$

- 知覚的話者類似性





- $c_{i,j}^{(\text{human})}$ は, 2 話者の音声を人間に受聴させたときに聞き手が知覚したスコア

$$G^{(\text{human})} = (S, E, W^{(\text{human})})$$

- 話者埋め込み類似性

- $c_{i,j}^{(\text{model})}$ は, 2 話者それぞれの話者埋め込みベクトルのコサイン類似度

$$G^{(\text{model})} = (S, E, W^{(\text{model})})$$



- 2つのグラフ $G^{(\text{human})}$, $G^{(\text{model})}$ の類似度を3つの指標により評価
 - ピアソンの線形相関係数 (LCC)
 - グラフのエッジ重みから話者ペア単位での類似度相関を評価
 - フロベニウス距離
 - 類似度スコアを要素とする隣接行列間の差異を評価
 - スペクトル距離
 - グラフの正規化グラフラプラシアンから得た固有値間の ℓ_2 距離を計算
 - グラフの大域的構造の差異を評価


3. 実験的評価

3.1 実験条件

- データセット
 - JVS (男性49名, 女性51名) [5]
 - VCTK (女性52名) [6]
 - 知覚的話者類似性スコア [5-7]
 - 同一性別内の全話者対について, [-3, 3] の話者類似度スコアが存在
 - 話者埋め込み類似性
 - 各Transformer層において, 各話者10発話の全フレーム・全発話平均表現を話者埋め込みとして抽出
 - 同一性別内の全話者対について, 話者埋め込み間のコサイン類似度を計算
- それぞれ [0, 1] に正規化

3.2 全モデルおよび全Transformer層におけるLCC

- 合計43個のオープンソースモデルを使用 [2-4, 8-17] ※ Layer ratio: 各モデルの層番号を [0,1] に正規化
- 教師あり {ASR, TTS, TTA, 環境音分類} モデル, {音声, 一般音} SSL モデル



- モデルごとにスコアが異なる: WavLMは高いスコアを示す一方, Qwen3-TTSは低い
 - 層方向の変化が異なる: 多くのモデルでは深層で低下, AudioGenやVALL-E Xでは向上
- 人間知覚との整合性およびその層方向の変化は, モデル設定に依存する可能性を示唆

3.3 重回帰分析によるモデル設定の寄与分析


Response variable	is_dec	is_mlang	is_ssl	hours	params	R ²
layer_max (各モデルの全層における層最大スコア)						
LCC	-0.77	0.00	-0.14	-0.12	-0.14	0.747
Neg. Frobenius norm	-0.22	-0.02	-0.01	-0.01	0.05	0.983
Neg. spectral dist.	0.03	-0.16	-0.15	0.10	-0.03	0.835

- is_dec < 0: エンコーダ型は人間知覚と整合的な表現形成を促進する.
- is_ssl < 0: 教師ありモデルは人間知覚とより整合する.
- R² ≒ 0.8: モデル設定は層最大スコアを強く説明するが, 層傾向は十分に説明できない.

Response variable	is_dec	is_mlang	is_ssl	hours	params	R ²
layer_slope (スコアの層方向変化を表す回帰係数)						
LCC	0.31	0.10	0.06	-0.26	0.29	0.205
Neg. Frobenius norm	-0.12	0.20	-0.02	0.06	0.07	0.123
Neg. spectral dist.	0.09	0.54	0.20	-0.15	0.13	0.241


- params > 0: パラメータ増加は層最大スコアを下げるが, 層間変動を平坦化する.
 - デコーダ型も上記と同様の傾向を持つ.

3.4 SSL モデルのファインチューニングの影響



- wav2vec2-{base,large}-960h
 - SSLのみで学習されたモデルと比べて, 深い層ほどスコアが低下する.
 - ASR fine-tuning により言語情報寄りへ変化
 - 話者性に関する情報が抑制
- wavlm-ssl_sv
 - 全層にわたり平坦化する.
 - 話者関連タスクに最適化されたことにより, 話者類似構造が全層で表現

3.5 一般音で学習されたモデル



- audigen-medium
 - 深い層ほど単調にスコアが上昇
 - 音生成モデルとして学習されたため, 深層ほど音色や詳細な音響特徴を表現
- atstframe_base
 - 全層にわたり比較的平坦な傾向
 - 特定のタスクに特化していないため, 全層で均一な汎用音響表現を維持

Reference


- [1] 北村, 日本音響学会, 2015 [4] S. Chen, JSTSP, 2022 [7] Y. Saito, TASLP, 2021 [10] F. Kreuk, ICLR, 2023 [13] H. Hu, arXiv, 2026 [16] X. Li, TASLP, 2024
[2] A. Baevski, NeurIPS, 2020 [5] S. Takamichi, arXiv, 2019 [8] D. Zhang, EMNLP, 2023 [11] Y. Gong, Interspeech, 2021 [14] J. Ao, ACL, 2022 [17] D. Rekesh, ASRU, 2023
[3] W.-N. Hsu, TASLP, 2021 [6] J. Yamagishi, 2019 [9] Z. Zhang, arXiv, 2023 [12] A. Radford, ICML, 2023 [15] V. Miara, Interspeech, 2024

(61) [一般発表] 音声基盤モデルは人間と同様の知覚的話者類似性を持つのか？

◎岸 秀, ◎八木 颯斗 (慶應義塾大学), 高道 慎之介 (慶應義塾大学/東京大学), 齋藤 佑樹 (東京大学)

1. はじめに

- 人間: どれくらい声が似ているかを連続的に知覚可能 [1]
- 音声基盤モデル:
 - 音声から埋め込みベクトルを抽出
 - 埋め込みの類似度を話者識別タスクに利用可能 [2-4]




モデル内の話者埋め込み類似性は人間の知覚的話者類似性と整合するか？

- 話者埋め込み類似性と知覚的話者類似性が整合する場合:
 - 高次の知覚機能がデータのみから創発する可能性を示唆
 - 人間知覚と整合する音声基盤モデル設計への知見を提供
- 本研究の目的:
 - 43モデル × 全 Transformer 層を分析
 - 人間知覚と整合するモデル設計要因を解明

2. 提案法



- 知覚的話者類似性と話者埋め込み類似性のグラフ表現
 - 話者集合 S の各話者をノード, エッジ集合 $E = \{\{i, j\} \mid i, j \in S, i \neq j\}$ の各話者対 (i, j) の類似度 $c_{i,j}$ をエッジの重みとする無向完全グラフを構築
 - 知覚的話者類似性
 - 人間の知覚的話者類似性スコア $c_{i,j}^{(\text{human})}$ を要素とする重み集合 $W^{(\text{human})} = \{c_{i,j}^{(\text{human})} \mid i, j \in S, i \neq j\}$ をエッジ重みとするグラフ

$$G^{(\text{human})} = (S, E, W^{(\text{human})})$$



- 話者埋め込み類似性
 - モデルの話者埋め込み類似度 $c_{i,j}^{(\text{model})}$ を要素とする重み集合 $W^{(\text{model})} = \{c_{i,j}^{(\text{model})} \mid i, j \in S, i \neq j\}$ をエッジ重みとするグラフ

$$G^{(\text{model})} = (S, E, W^{(\text{model})})$$



- 2つのグラフ $G^{(\text{human})}, G^{(\text{model})}$ の類似度を3つの指標により評価
 - ピアソンの線形相関係数 (LCC)
 - グラフのエッジ重みから話者ペア単位での類似度相関を評価
 - フロベニウス距離
 - 類似度スコアを要素とする隣接行列間の差異を評価
 - スペクトル距離
 - グラフの正規化グラフラプラシアンから得た固有値間の ℓ_2 距離を計算
 - グラフの大域的構造の差異を評価

3. 実験的評価

3.1 実験条件

- データセット
 - JVS (男性49名, 女性51名) [5]
 - VCTK (女性52名) [6]
 - 知覚的話者類似性スコア [5-7]
 - 同一性別内の全話者対について, $[-3, 3]$ の話者類似度スコアが存在
 - 話者埋め込み類似性
 - 各Transformer層において, 各話者10発話の全フレーム・全発話平均表現を話者埋め込みとして抽出
 - 同一性別内の全話者対について, 話者埋め込み間のコサイン類似度を計算
- それぞれ $[0, 1]$ に正規化

3.2 全モデルおよび全Transformer層におけるLCC

- 合計43個のオープンソースモデルを使用 [2-4, 8-17] ※ Layer ratio: 各モデルの層番号を $[0, 1]$ に正規化
 - 教師あり {ASR, TTS, TTA, 環境音分類} モデル, {音声, 一般音} SSL モデル
-
- モデルごとにスコアが異なる: WavLM は高いスコアを示す一方, Qwen3-TTS は低い
 - 層方向の変化が異なる: 多くのモデルでは深層で低下, AudioGen や VALL-E X では向上
- 人間知覚との整合性およびその層方向の変化は, モデル設定に依存する可能性を示唆

3.3 重回帰分析によるモデル設定の寄与分析

Response variable	is_dec	is_mlang	is_ssl	hours	params	R ²
layer_max						
LCC	-0.77	0.00	-0.14	-0.12	-0.14	0.747
Neg. Frobenius norm	-0.22	-0.02	-0.01	-0.01	0.05	0.983
Neg. spectral dist.	0.03	-0.16	-0.15	0.10	-0.03	0.835

- $\text{is_dec} < 0$: エンコーダ型は人間知覚と整合的な表現形成を促進する.
- $\text{is_ssl} < 0$: 教師ありモデルは人間知覚とより整合する.
- $R^2 \approx 0.8$: モデル設定は層最大スコアを強く説明する一方, 層傾向は十分に説明できない.

Response variable	is_dec	is_mlang	is_ssl	hours	params	R ²
layer_slope						
LCC	0.31	0.10	0.06	-0.26	0.29	0.205
Neg. Frobenius norm	-0.12	0.20	-0.02	0.06	0.07	0.123
Neg. spectral dist.	0.09	0.54	0.20	-0.15	0.13	0.241

- $\text{params} > 0$: パラメータ増加は層最大スコアを下げるが, 層間変動を平坦化する.
 - デコーダ型も上記と同様の傾向を持つ.

3.4 SSL モデルのファインチューニングの影響

-
- wav2vec2-{base,large}-960h
 - SSL のみで学習されたモデルと比べて, 深い層ほどスコアが低下する.
 - ASR fine-tuning により言語情報寄りへ変化
 - 話者性に関する情報が抑制
 - wavlm-ssl_sv
 - 全層にわたり平坦化する.
 - 話者関連タスクに最適化されたことにより, 話者類似構造が全層で表現

3.5 一般音で学習されたモデル

-
- audiogen-medium
 - 深い層ほど単調にスコアが上昇
 - 音生成モデルとして学習されたため, 深層ほど音色や詳細な音響特徴を表現
 - atstframe_base
 - 全層にわたり比較的平坦な傾向
 - 多様な音を対象に学習されたため, 全層で均一な汎用音響表現を維持

Reference


- [1] 北村, 日本音響学会, 2015 [4] S. Chen, JSTSP, 2022 [7] Y. Saito, TASLP, 2021 [10] F. Kreuk, ICLR, 2023 [13] H. Hu, arXiv, 2026 [16] X. Li, TASLP, 2024
[2] A. Baevski, NeurIPS, 2020 [5] S. Takamichi, arXiv, 2019 [8] D. Zhang, EMNLP, 2023 [11] Y. Gong, Interspeech, 2021 [14] J. Ao, ACL, 2022 [17] D. Rekesh, ASRU, 2023
[3] W.-N. Hsu, TASLP, 2021 [6] J. Yamagishi, 2019 [9] Z. Zhang, arXiv, 2023 [12] A. Radford, ICML, 2023 [15] V. Miara, Interspeech, 2024

2. 提案法

- 類似性の無向完全グラフ表現

- ノード (話者) 集合 S
- エッジ (話者間) 集合 $E = \{\{i, j\} \mid i, j \in S, i \neq j\}$
- エッジ重み $W = \{c_{i,j}^{(\text{human})} \mid i, j \in S, i \neq j\}$


$$G^{(\text{human})} = (S, E, W^{(\text{human})})$$



- 知覚的話者類似性

- $c_{i,j}^{(\text{human})}$ は, 2 話者の音声を人間に受聴させたときに聞き手が知覚したスコア


$$G^{(\text{human})} = (S, E, W^{(\text{human})})$$



- 話者埋め込み類似性

- $c_{i,j}^{(\text{model})}$ は, 2 話者それぞれの話者埋め込みベクトルのコサイン類似度

$$G^{(\text{model})} = (S, E, W^{(\text{model})})$$



3. 実験的評価

(61) [一般発表] 音声基盤モデルは人間と同様の知覚的話者類似性を持つのか？

◎岸 秀, ◎八木 颯斗 (慶應義塾大学), 高道 慎之介 (慶應義塾大学/東京大学), 齋藤 佑樹 (東京大学)

1. はじめに

- 人間：どれくらい声が似ているかを連続的に知覚可能 [1]
- 音声基盤モデル：
 - 音声基盤モデルは話者を埋め込み空間として表す




モデル内の話者埋め込み類似性は人間の知覚的話者類似性と整合するか？

- もし整合するなら：
 - 高次の知覚機能がデータのみから創発する可能性を示唆
 - 人間知覚と整合する音声基盤モデル設計への知見を提供
- 本研究では
 - 43モデル × 全Transformer層を分析
 - 人間知覚と整合するモデル設計要因を解明

2. 提案法

2.1 提案法概要



- 知覚的話者類似性・話者埋め込み類似性のグラフ表現
 - 各話者をノードとし、任意の2話者間の知覚的話者類似性スコアまたは話者埋め込みの類似度をエッジの重みとする無向完全グラフを構築

2.2 提案法詳細

- 定義した2つのグラフの類似度を3つの指標により評価
 - 話者ペア単位での類似度相関
 - ピアソンの線形相関係数 (LCC)
 - スピアマンの順位相関係数 (SRCC)
 - フロベニウス距離
 - 類似度スコアを要素とする隣接行列間の差異を評価
 - スペクトル距離
 - 各グラフの正規化グラフラプラシアンから得られる固有値間のL2距離を計算


3. 実験の評価

3.1 実験条件

- データセット
 - JVS (男性49名, 女性51名) [2]
 - VCTK (女性52名) [3]
- 知覚的話者類似性スコア [2-4]
 - 同一性別内の全話者対に対して [-3, 3] の話者類似度スコアが存在
- 話者埋め込み類似性
 - 各話者10発話から抽出した話者埋め込みを平均化
 - 同一性別内の全話者対に対して平均埋め込み間のコサイン類似度を計算 → それぞれ [0, 1] に正規化

3.2 全モデルおよび全Transformer層におけるLCC

- 合計43個のオープンソースモデルを使用 [5-17]
 - 教師あり {ASR, TTS, TTA, 環境音分類} モデル, {音声, 一般音} SSL モデル




- モデル間でスコアのばらつきが大きい。
- 層ごとのスコア推移に多様な傾向が見られる。

3.4 重回帰分析によるモデル設定の寄与分析

Response variable	is_dec	is_mlang	is_ssl	hours	params	R ²
layer_max						
LCC	-0.77	0.00	-0.14	-0.12	-0.14	0.747
SRCC	-0.79	-0.03	-0.15	-0.10	-0.15	0.764
Neg. Frobenius norm	-0.22	-0.02	-0.01	-0.01	0.05	0.983
Neg. spectral dist.	0.03	-0.16	-0.15	0.10	-0.03	0.835
layer_slope						
LCC	0.31	0.10	0.06	-0.26	0.29	0.205
SRCC	0.29	0.14	0.09	-0.24	0.26	0.184
Neg. Frobenius norm	-0.12	0.20	-0.02	0.06	0.07	0.123
Neg. spectral dist.	0.09	0.54	0.20	-0.15	0.13	0.241


- is_dec < 0: エンコーダ型は人間知覚と整合的な表現形成を促進する。
- is_ssl < 0: 大規模教師ありモデルは人間知覚とより整合する。
- R² ≒ 0.8: モデル設定は最大スコアを強く説明するが層傾向の説明力は低い。

3.5 SSL モデルのファインチューニングの影響



- wav2vec2-{base,large}-960h
 - 深い層ほどスコアが低下 → ASR fine-tuning により言語情報寄りへ変化
- wavlm-ssl_sv
 - 全層にわたり平坦化 → 話者類似構造を全層で保持

3.6 一般音で学習されたモデル



- audigen-medium
 - 深い層ほど単調にスコアが上昇 → 深層で詳細な音響特徴を獲得
- atstframe_base
 - 全層にわたり比較的平坦な傾向 → 全層で均一な汎用音響表現を保持

Reference

- [1] 北村, 日本音響学会, 2015 [4] Y. Saito, TASLP, 2021 [7] J. Ao, ACL, 2022 [10] F. Kreuk, ICLR, 2023 [13] W.-N. Hsu, TASLP, 2021 [16] X. Li, TASLP, 2024
[2] S. Takamichi, arXiv, 2019 [5] A. Radford, ICML, 2023 [8] D. Zhang, EMNLP, 2023 [11] Y. Gong, Interspeech, 2021 [14] S. Chen, JSTSP, 2022 [17] D. Rekesh, ASRU, 2023
[3] J. Yamagishi, 2019 [6] H. Hu, arXiv, 2026 [9] Z. Zhang, arXiv, 2023 [12] A. Baevski, NeurIPS, 2020 [15] V. Miara, Interspeech, 2024

(61) [一般発表] 音声基盤モデルは人間と同様の知覚的話者類似性を持つのか？

◎岸 秀, ◎八木 颯斗 (慶應義塾大学), 高道 慎之介 (慶應義塾大学/東京大学), 齋藤 佑樹 (東京大学)


1. はじめに

1.1 研究背景

- 人間はどれくらい声が似ているかを連続的に知覚可能[1]
- 音声基盤モデルから得られる話者埋め込み類似性は、人間の知覚的話者類似性とどのように対応するのか？

2. 提案法

2.1 提案法概要



- 知覚的話者類似性・話者埋め込み類似性のグラフ表現
 - 各話者をノードとし、任意の2話者間の知覚的話者類似性スコアまたは話者埋め込みの類似度をエッジの重みとする無向完全グラフを構築

1.2 研究目的

- どのモデル設定がこの対応関係に寄与するかを解明
 - 43個の基盤モデル比較, 層ごとの分析
 - 人間知覚と整合するモデル設計要因分析

2.2 提案法詳細

- 定義した2つのグラフの類似度を3つの指標により評価
 - 話者ペア単位での類似度相関
 - ピアソンの線形相関係数 (LCC)
 - スピアマンの順位相関係数 (SRCC)
 - フロベニウス距離
 - 類似度スコアを要素とする隣接行列間の差異を評価
 - スペクトル距離
 - 各グラフの正規化グラフラプラシアンから得られる固有値間の ℓ_2 距離を計算


3. 実験的評価

3.1 実験条件

- データセット
 - JVS (男性49名, 女性51名) [2]
 - VCTK (女性52名) [3]
- 知覚的話者類似性スコア [2-4]
 - 同一性別内の全話者対に対して [-3, 3] の話者類似度スコアが存在
- 話者埋め込み類似性
 - 各話者10発話から抽出した話者埋め込みを平均化
 - 同一性別内の全話者対に対して平均埋め込み間のコサイン類似度を計算 → それぞれ [0, 1] に正規化

3.2 全モデルおよび全Transformer 層におけるLCC

- 合計43個のオープンソースモデルを使用 [5-17]
 - 教師あり {ASR, TTS, TTA, 環境音分類} モデル, {音声, 一般音} SSL モデル




- モデル間でスコアのばらつきが大きい.
- 層ごとのスコア推移に多様な傾向が見られる.

3.4 重回帰分析によるモデル設定の寄与分析

Response variable	is_dec	is_mlang	is_ssl	hours	params	R ²
layer_max						
LCC	-0.77	0.00	-0.14	-0.12	-0.14	0.747
SRCC	-0.79	-0.03	-0.15	-0.10	-0.15	0.764
Neg. Frobenius norm	-0.22	-0.02	-0.01	-0.01	0.05	0.983
Neg. spectral dist.	0.03	-0.16	-0.15	0.10	-0.03	0.835
layer_slope						
LCC	0.31	0.10	0.06	-0.26	0.29	0.205
SRCC	0.29	0.14	0.09	-0.24	0.26	0.184
Neg. Frobenius norm	-0.12	0.20	-0.02	0.06	0.07	0.123
Neg. spectral dist.	0.09	0.54	0.20	-0.15	0.13	0.241


- $is_dec < 0$: エンコーダ型は人間知覚と整合的な表現形成を促進する.
- $is_ssl < 0$: 大規模教師ありモデルは人間知覚とより整合する.
- $R^2 \approx 0.8$: モデル設定は最大スコアを強く説明するが層傾向の説明力は低い.

3.5 SSL モデルのファインチューニングの影響



- wav2vec2-{base,large}-960h
 - 深い層ほどスコアが低下 → ASR fine-tuning により言語情報寄りへ変化
- wavlm-ssl_sv
 - 全層にわたり平坦化 → 話者類似構造を全層で保持

3.6 一般音で学習されたモデル



- audiotgen-medium
 - 深い層ほど単調にスコアが上昇 → 深層で詳細な音響特徴を獲得
- astframe_base
 - 全層にわたり比較的平坦な傾向 → 全層で均一な汎用音響表現を保持

Reference

- [1] 北村, 日本音響学会, 2015 [4] Y. Saito, TASLP, 2021 [7] J. Ao, ACL, 2022 [10] F. Kreuk, ICLR, 2023 [13] W.-N. Hsu, TASLP, 2021 [16] X. Li, TASLP, 2024
[2] S. Takamichi, arXiv, 2019 [5] A. Radford, ICML, 2023 [8] D. Zhang, EMNLP, 2023 [11] Y. Gong, Interspeech, 2021 [14] S. Chen, JSTSP, 2022 [17] D. Rekesh, ASRU, 2023
[3] J. Yamagishi, 2019 [6] H. Hu, arXiv, 2026 [9] Z. Zhang, arXiv, 2023 [12] A. Baevski, NeurIPS, 2020 [15] V. Miara, Interspeech, 2024

音声基盤モデルは人間と同様の知覚的話者類似性を持つのか？

岸 秀, 八木 颯斗 (慶應義塾大学), 高道 慎之介 (慶應義塾大学/東京大学), 齋藤 佑樹 (東京大学)


1. はじめに

1.1 研究背景

- 人間はどれくらい声が似ているかを連続的に知覚可能[1]
- 音声基盤モデルから得られる話者埋め込み類似性は、人間の知覚的話者類似性とどのように対応するのか？

2. 提案法

2.1 提案法概要



- 知覚的話者類似性
 - 各話者をノード、任意の2話者間の知覚的話者類似性スコアをエッジの重みとする無向完全グラフ
- 話者埋め込み類似性
 - 各話者をノード、任意の2話者間の話者埋め込みの類似度をエッジの重みとする無向完全グラフ


3. 実験的評価

3.1 実験条件

- データセット
 - JVS (男性49名, 女性51名) [1]
 - VCTK (女性52名) [1]
- 知覚的話者類似性スコア [1][1]
 - 同一性別内の全話者対に対して $[-3, 3]$ の話者類似度スコアが存在
- 話者埋め込み類似性
 - 各話者10発話から抽出した話者埋め込みを平均化
 - 同一性別内の全話者対に対して平均埋め込み間のコサイン類似度を計算 → それぞれ $[0, 1]$ に正規化

3.2 全モデルおよび全Transformer 層におけるLCC

- 合計43個のオープンソースモデルを使用
 - 教師あり {ASR, TTS, TTA, 環境音分類} モデル, {音声, 一般音} SSL モデル



- モデル間でスコアのばらつきが大きい。
- 層ごとのスコア推移に多様な傾向が見られる。

3.4 重回帰分析によるモデル設定の寄与分析

Response variable	is_dec	is_mlang	is_ssl	hours	params	R^2
layer_max						
LCC	-0.77 (< .001)	0.00 (0.992)	-0.14 (0.020)	-0.12 (0.117)	-0.14 (0.022)	0.747
SRCC	-0.79 (< .001)	-0.03 (0.687)	-0.15 (0.015)	-0.10 (0.182)	-0.15 (0.010)	0.764
Neg. Frobenius norm	-0.22 (< .001)	-0.02 (0.407)	-0.01 (0.359)	-0.01 (0.568)	0.05 (0.002)	0.983
Neg. spectral dist.	0.03 (0.529)	-0.16 (0.008)	-0.15 (0.003)	0.10 (0.096)	-0.03 (0.550)	0.835
layer_slope						
LCC	0.31 (0.002)	0.10 (0.425)	0.06 (0.610)	-0.26 (0.054)	0.29 (0.008)	0.205
SRCC	0.29 (0.004)	0.14 (0.297)	0.09 (0.424)	-0.24 (0.083)	0.26 (0.017)	0.184
Neg. Frobenius norm	-0.12 (0.240)	0.20 (0.152)	-0.02 (0.890)	0.06 (0.650)	0.07 (0.553)	0.123
Neg. spectral dist.	0.09 (0.340)	0.54 (< .001)	0.20 (0.058)	-0.15 (0.275)	0.13 (0.211)	0.241

- is_dec: エンコーダ型構造は人間知覚と整合的な表現形成を促進する。
- is_ssl: 大規模教師ありモデルは人間知覚とより整合する。
- params: パラメータ増加は整合性を下げるが層間変動を平坦化する。
- R^2 : モデル設定は平均スコアを強く説明するが層傾向の説明力は低い。

3.6 ○○の実験

- あああ
- あああ
- あああ
- あああ
- あああ
- あああ
- あああ
- あああ
- あああ
- あああ
- あああ
- あああ

Reference

- [1] xxx
- [2] xxx
- [3] xxx

音声基盤モデルは人間と同様の知覚的話者類似性を持つのか？

岸 秀, 八木 颯斗 (慶應義塾大学), 高道 慎之介 (慶應義塾大学/東京大学), 齋藤 佑樹 (東京大学)


1. はじめに

1.1 研究背景

- 人間はどれくらい声が似ているかを連続的に知覚可能[1]
- 音声基盤モデルから得られる話者埋め込み類似性は、人間の知覚的話者類似性とどのように対応するのか？

2. 提案法

2.1 提案法概要



- 知覚的話者類似性・話者埋め込み類似性のグラフ表現
 - 各話者をノードとし、任意の2話者間の知覚的話者類似性スコアまたは話者埋め込みの類似度をエッジの重みとする無向完全グラフを構築


3. 実験的評価

3.1 実験条件

- データセット
 - JVS (男性49名, 女性51名) [1]
 - VCTK (女性52名) [1]
- 知覚的話者類似性スコア [1][1]
 - 同一性別内の全話者対に対して [-3, 3] の話者類似度スコアが存在
- 話者埋め込み類似性
 - 各話者10発話から抽出した話者埋め込みを平均化
 - 同一性別内の全話者対に対して平均埋め込み間のコサイン類似度を計算 → それぞれ [0, 1] に正規化

3.2 全モデルおよび全Transformer 層におけるLCC

- 合計43個のオープンソースモデルを使用
 - 教師あり {ASR, TTS, TTA, 環境音分類} モデル, {音声, 一般音} SSL モデル




- モデル間でスコアのばらつきが大きい。
- 層ごとのスコア推移に多様な傾向が見られる。

3.4 重回帰分析によるモデル設定の寄与分析

Response variable	is_dec	is_mlang	is_ssl	hours	params	R ²
layer_max						
LCC	-0.77	0.00	-0.14	-0.12	-0.14	0.747
SRCC	-0.79	-0.03	-0.15	-0.10	-0.15	0.764
Neg. Frobenius norm	-0.22	-0.02	-0.01	-0.01	0.05	0.983
Neg. spectral dist.	0.03	-0.16	-0.15	0.10	-0.03	0.835
layer_slope						
LCC	0.31	0.10	0.06	-0.26	0.29	0.205
SRCC	0.29	0.14	0.09	-0.24	0.26	0.184
Neg. Frobenius norm	-0.12	0.20	-0.02	0.06	0.07	0.123
Neg. spectral dist.	0.09	0.54	0.20	-0.15	0.13	0.241


- is_dec: エンコーダ型は人間知覚と整合的な表現形成を促進する。
- is_ssl: 大規模教師ありモデルは人間知覚とより整合する。
- R²: モデル設定は最大スコアを強く説明するが層傾向の説明力は低い。

3.6 一般音で学習されたモデル



- audiogen-medium
 - 深い層ほど単調にスコアが上昇 → 深層で詳細な音響特徴を獲得
- atstframe_base
 - 全層にわたり比較的平坦な傾向 → 全層で均一な汎用音響表現を保持

3.6 SSL モデルのファインチューニングの影響



- wav2vec2-{base,large}-960h
 - 深い層ほどスコアが低下 → ASR FTにより言語情報寄りに変化
- wavlm-ssl_sv
 - 全層にわたり比較的平坦な傾向 → 話者類似構造を全層で保持

Reference

- [1] xxx
- [2] xxx
- [3] xxx

音声基盤モデルは人間と同様の知覚的話者類似性を持つのか？

岸 秀, 八木 颯斗 (慶應義塾大学), 高道 慎之介 (慶應義塾大学/東京大学), 齋藤 佑樹 (東京大学)


1. はじめに

1.1 研究背景

- 人間はどれくらい声が似ているかを連続的に知覚可能[1]
- 音声基盤モデルから得られる話者埋め込み類似性は、人間の知覚的話者類似性とどのように対応するのか？

2. 提案法

2.1 提案法概要



- 知覚的話者類似性・話者埋め込み類似性のグラフ表現
 - 各話者をノードとし、任意の2話者間の知覚的話者類似性スコアまたは話者埋め込みの類似度をエッジの重みとする無向完全グラフを構築


3. 実験的評価

3.1 実験条件

- データセット
 - JVS (男性49名, 女性51名) [1]
 - VCTK (女性52名) [1]
- 知覚的話者類似性スコア [1][1]
 - 同一性別内の全話者対に対して [-3, 3] の話者類似度スコアが存在
- 話者埋め込み類似性
 - 各話者10発話から抽出した話者埋め込みを平均化
 - 同一性別内の全話者対に対して平均埋め込み間のコサイン類似度を計算 → それぞれ [0, 1] に正規化

3.2 全モデルおよび全Transformer 層におけるLCC

- 合計43個のオープンソースモデルを使用
 - 教師あり {ASR, TTS, TTA, 環境音分類} モデル, {音声, 一般音} SSL モデル




- モデル間でスコアのばらつきが大きい。
- 層ごとのスコア推移に多様な傾向が見られる。

3.4 重回帰分析によるモデル設定の寄与分析

Response variable	is_dec	is_mlang	is_ssl	hours	params	R ²
layer_max						
LCC	-0.77	0.00	-0.14	-0.12	-0.14	0.747
SRCC	-0.79	-0.03	-0.15	-0.10	-0.15	0.764
Neg. Frobenius norm	-0.22	-0.02	-0.01	-0.01	0.05	0.983
Neg. spectral dist.	0.03	-0.16	-0.15	0.10	-0.03	0.835
layer_slope						
LCC	0.31	0.10	0.06	-0.26	0.29	0.205
SRCC	0.29	0.14	0.09	-0.24	0.26	0.184
Neg. Frobenius norm	-0.12	0.20	-0.02	0.06	0.07	0.123
Neg. spectral dist.	0.09	0.54	0.20	-0.15	0.13	0.241


- is_dec: エンコーダ型は人間知覚と整合的な表現形成を促進する。
- is_ssl: 大規模教師ありモデルは人間知覚とより整合する。
- R²: モデル設定は最大スコアを強く説明するが層傾向の説明力は低い。

3.6 SSL モデルのファインチューニングの影響



- wav2vec2-{base,large}-960h
 - 深い層ほどスコアが低下 → ASR FTにより言語情報寄りに変化
- wavlm-ssl_sv
 - 全層にわたり比較的平坦な傾向 → 話者類似構造を全層で保持

3.6 一般音で学習されたモデル



- audiogen-medium
 - 深い層ほど単調にスコアが上昇 → 深層で詳細な音響特徴を獲得
- atstframe_base
 - 全層にわたり比較的平坦な傾向 → 全層で均一な汎用音響表現を保持

Reference

- [1] xxx
- [2] xxx
- [3] xxx

[研究紹介] ◎ 41. Altered auditory feedbackに基づく感情誘導における音声特徴量弁別閾の調査

中村 颯, 福田 航希, 高道 慎之介 (慶應義塾大学), 高畑 龍 (産総研)

1. はじめに

1.1 研究背景

- **Altered auditory feedback (AAF)** は、話者の音声をリアルタイムに変調し、話者本人へ聴覚フィードバックする技術[1]
- 感情的な変調により **話者の感情誘導**が可能[1]だが、**変調を検知した場合に効果が消失**[2]する。
- **話者に検知されない変調強度**を把握する必要がある。


1.2 研究目的

- **Happy**に聞こえるような感情的音声変調に対する弁別閾を測定する。
 - Happyは感情誘導AAFにて最も頑健に効果が示されたため。
- **弁別閾の個人差**が自己音声を聞く頻度、音楽経験などの因子で説明できるか分析する。

2. 実験・分析方法

2.1 実験概要

- 大学生16名が、提示文を朗読しながら、**happy方向に変調**された自己音声をヘッドホンで聴取
 - **Happy変調**[1]：変調率 α のみに依存。基本周波数の上昇、イントネーション変化、高域成分の増幅など。
- 各試行後に「自己音声加工された、または違和感があったか」をyes/noで回答
- **2down-1up staircase法**[3] (右図) に従い、 α を**変化**。
- **無変調 ($\alpha = 0$) の試行を10%挿入**
- 刺激文[4]の感情 (happy, neutral, sad) を分けて、3セッション実行
 - Happy文例：いやー、本当に日本酒飲み放題幸せだった。
- 実験前後に質問紙を実施し、個人差となり得る要因を収集
 - 感情状態、感情発露傾向、自己聴取音との差異 (主観) など



2.2 分析手法


- **線形混合効果モデル**[5]により、弁別閾を説明する因子を分析
- 過適合を避けるため、**因子を二分**し、候補因子はLasso[6]で選定
 - **主要因子**：理論に基づき、弁別閾に影響すると予測された因子
 - **候補因子**：探索的に設計された因子



3. 結果


3.1 弁別閾の分布

- 平均：4.060 ± 2.486
- 中央値：3.470
- $\alpha = 4$ はF0の100cent上昇に対応 → 半音程度の変調で検知される。



3.2 弁別閾の説明因子

- 候補因子はLassoによる変数選択ですべて棄却された。
→ 主要因子のみをモデルに投入
- 主要因子はいずれも有意ではなかった。
- 各因子と弁別閾の単相関は上位のもので中程度 ($r \approx 0.4$)



4. まとめ

- happy方向の感情的音声変調に対する弁別閾を測定し、その弁別閾には大きな個人差があった。
- 想定した個人差要因では、**弁別閾のばらつきを説明できなかった**。
- 実用的なAAF感情誘導システムでは、**個人ごとの適応的キャリブレーションが必要**。

Reference


- [1] J.-J. Aucouturier, Proceedings of the National Academy of Sciences, 2016.
[2] L. Goupil, bioRxiv, 2019
[3] H. Levitt, The Journal of the Acoustical Society of America, 1971

- [4] 梶原智之, 自然言語処理, 2021
[5] N. M. Laird, Biometrics, 1982
[6] R. Tibshirani, Journal of the Royal Statistical Society, 1996

1. はじめに

1.1 研究背景

- 表現学習: 入力データから有用な表現(ベクトル)を得るモデルの学習[1].
- 分離表現学習: データを構成する要因を特定し, それらを分離した表現を得る[2].




- 音響信号(および対応するテキスト)の構成要素[3]
 - 音源情報: 何が鳴っているか? 音の音色, ピッチ (例. 犬, 猫)
 - 空間情報: どこで鳴っているか? 部屋の広さ, 残響時間, マイクと音源の距離, 方向
 - ex) 車のエンジン音が, 残響時間の長い部屋の右側から鳴っている.

<音源情報>

<空間情報>


1.2 従来法との比較



- この研究の意義
 - 拡張性: 空間音響生成, VR/映画への応用.
 - 制御性の向上: 音源と空間の影響を独立に扱える


2. 提案法

2.1 DISSE 概要



- {audio, text} × {音源, 空間} の4つの表現を出力.
 - 音源, 空間表現同士の対応を学習.
 - 音源表現は, 音源情報に依存し, 空間情報に依存しないことが望ましい.

2.2 提案法詳細(学習データの作り方, 学習方法)



- 学習データ: {1チャンネル音, 音源テキスト} を空間的に拡張.
 - 1チャンネル音 → 多チャンネル音: RIR畳み込み
 - 音源テキスト → 空間・音源テキスト: 空間に関する句を追加
- 学習方法(教師あり対照学習[4])
 - 空間が一致するとき, 音源表現間でnegative(類似度低), 空間表現間でpositive(類似度高)として学習される.

3. 実験的評価


* 目的因子: {音源, 空間} 表現における {音源, 空間} 情報 非目的因子: {音源, 空間} 表現における {空間, 音源} 情報

3.1 実験条件

- データセット: AudioCaps[5]を拡張
- 評価データ: 9216個 (以下の全組み合わせ)
 - AudioCapsのテストセットから96個
 - RIR 96個 (= 距離(2) × 方位角(4) × 仰角(2) × 部屋サイズ(3) × T30(2))
- 表現の次元数: 512
- エンコーダ
 - HTS-AT[6], [3]で使われた空間エンコーダ,
 - RoBERTa[7]
- 最適化: AdamW[8]
- ベースライン: ELSA[3]
 - 音とテキストを入力しそれぞれ1つの表現を出力

3.2 音源情報と空間情報の分離性

- 目的因子に感度高く, 非目的因子に不変 (下図) かどうか?



- IIDR[9]: 表現がどちらの因子の情報を持っているかを示す.
 - IIDR(src)が高いほど, 音源情報に反応し, 空間情報に不変であることを示す.
 - 音源表現: IIDR(src) ↑, IIDR(spa) ↓


$$IIDR_{aud}^{(src)} = \frac{E[d(x_{aud}^{(src, spa)}, x_{aud}^{(src', spa)})]}{E[d(x_{aud}^{(src, spa)}, x_{aud}^{(src, spa')})]}$$

Modality	Model	Embedding	IIDR ^(src)	IIDR ^(spa)
Audio	ELSA	-	1.6056	0.6228
	DISSE	Source Spatiality	5.5653	0.1797
Text	ELSA	-	1.7242	0.5800
	DISSE	Source Spatiality	15.5462	0.0643

- 提案法では目的因子に対する値が上昇, 非目的因子に対する値が減少.
 - 目的因子に高い感度を持ち, 非目的因子に対して不変である.

3.3 音源情報, 空間情報に基づく検索[10]

- オンタスク: 目的因子に対する検索性能があるか?
 - ex) 音源表現で音源情報の一致するデータを検索.
- オフタスク: 因子間で情報漏洩が無い?
 - 非目的因子を検索 [11]
 - ex) 音源表現で空間情報の一致するデータを検索.



- 同一モダリティ内での検索結果

TABLE II
INTRA-MODAL RETRIEVAL (R@1 / MedR).²


Model	Modality	On-task (src)	On-task (spa)	Off-task (src)	Off-task (spa)
ELSA	aud → aud	0.919 / 1	0.080 / 19	0.919 / 1	0.080 / 19
	txt → txt	0.982 / 1	0.015 / 24	0.982 / 1	0.015 / 24
DISSE	aud → aud	0.936 / 1	0.703 / 1	0.274 / 13	0.064 / 97
	txt → txt	0.994 / 1	0.234 / 5	0.733 / 1	0.004 / 100

- DISSEはon-taskでELSAを上回り, 特にon-task (spa) で大幅な改善.
 - 目的因子に対する検索能力の向上を達成.
- off-taskでもELSAより良い性能.
 - 情報漏洩の抑制を示す.

※モダリティ間の結果は論文参照

3.4 音源表現・空間表現の可視化

- 4つの表現をt-SNE[12]で可視化.



- 目的因子に対する表現でクラスタが形成される.
- 非目的因子に対しては, 色が混ざる.
 - 定性的にも, 目的因子に敏感で, 非目的因子に不変という傾向.

Reference

- [1] Y. Bengio, TPAMI, 2013.
- [2] J. Higgins, ICLR, 2017.
- [3] Devnani, NeurIPS, 2024.
- [4] P. Khosla, NeurIPS, 2020.
- [5] C. Dongjoo Kim, NAACL-HLT, 2019.
- [6] K. Chen, ICASSP, 2022.
- [7] Y. Liu, arXiv, 2019.
- [8] I. Loshchilov, ICLR, 2019
- [9] Y. Zeng, NAR Genom. Bioinform, 2024
- [10] Andrej Karpathy, CVPR, 2015
- [11] Hyeonngon Ryu, CVPR, 2025
- [12] Laurens van der Maaten, JMLR, 2008

1. はじめに

1.1 研究背景

- 漫画画像に対してシーンに沿った音を付与したい！
 - 漫画に沿った音声を合成する研究[1]
 - 漫画音声のデータセット構築[2]
- 漫画の環境音を合成する研究は未開拓。
 - オノマトペ画像から音を作る研究は存在[3]


1.2 研究目的

- 漫画画像から環境音を合成する技術を漫画環境音合成と定義する。
- 演技音声の付与された漫画に対して、各コマのシーンに適した環境音を合成することを目指す。
 - 音声付き漫画の品質向上及びユーザ体験の向上。

2. 提案法

2.1 提案手法の概要図

- 漫画コマ画像から、環境音を合成するために3種類の手法を提案。



2.2 各手法の詳細

- 写実的画像のみを介した環境音合成 (左図 上)
 - 漫画コマ画像を写実的画像に変換。
 - 写実的画像から環境音を合成。
- キャプションと写実的画像を介した環境音合成 (左図 中央)
 - 漫画コマ画像からそのコマで発生しうる環境音のキャプションを生成。
 - キャプションを、対応する写実的画像に変換。
 - 写実的画像から、それに沿う環境音を合成。
- キャプションのみを介した環境音合成 (左図 下)
 - 漫画コマ画像からそのコマで発生しうる環境音のキャプションを生成。
 - キャプションから、それに沿う環境音を合成。

3. 実験的評価

3.1 実験条件

- 提案手法の3手法を以下のように呼ぶ。
 - via-real**
 - 漫画画像→写実的画像→環境音
 - via-caption-real**
 - 漫画画像→キャプション→写実的画像→環境音
 - via-caption**
 - 漫画画像→キャプション→環境音
- 上記3種に加え、環境音配布サイト[4]から実際の環境音を**ground-truth**として使用。

3.5 客観評価

Method	PAM	AudioBERTScore
via-real	0.299	<u>0.487</u>
via-caption-real	<u>0.131</u>	0.508
via-caption	0.485	0.576
GT	0.492	

PAM[9]: 合成音の音質評価

AudioBERTScore[10]: GTと合成音の意味的整合性

- via-captionが他手法を**上回る**性能。
- 写実画像を介すると各手法のスコアが**低い**。
 - 画像生成の過程で環境音合成に必要な情報が欠落する可能性

3.2 モダリティ変換に用いたモデル

- GPT**
 - “GPT-4o”を採用[5]
 - 漫画画像の内容理解
 - キャプション生成
 - 写実画像への変換
- image-to-audio**
 - “I Hear Your True Colors”を採用[6]
 - 写実的画像から環境音を生成
- text-to-audio**
 - “AudioLDM”を採用[7]
 - キャプションから環境音を生成

3.6 主観評価

Method	MOS	
	OVL	REL
via-real	2.227	2.227
via-caption-real	<u>1.933</u>	<u>2.027</u>
via-caption	2.853	2.520
GT	4.053	4.107

- via-captionでもGTに及ばない。
 - 無音**や**ノイズ**が含まれていた。
 - 合成音の質感がシーンと**乖離**。
- キャプションの指示は反映しつつ適切な音色や品質を担保できない**。

3.3 データセット

- Manga109[8,9]
 - 日本語漫画109冊の画像
 - アノテーション付き
- 今回は20コマ分の画像を使用

3.4 各条件で合成した環境音

iPad貼る

4. まとめ

- 漫画コマ画像に合った環境音を合成する手法を提案。
- キャプションのみ介する手法**が客観評価・主観評価ともに最も良かった。
- ただし**音質や画像との一致度**には課題が残った。
- 収録困難・非現実的な音は生成できていない。

Reference

- [1] 越野颯太, SPEASIP, 2026
[2] S. Takamichi, Proc. ICASSP, 2026
[3] Y. Okamoto, arxiv, 2021
[4] <https://soundeffect-lab.info/>
[5] <https://openai.com/ja-JP/index/hello-gpt-4o/>
[6] R. Shiffer, arxiv, 2022
[7] H. Liu, Proc. ACM, 2024
[8] K. Aizawa, IEEE MultiMedia, 2020
[9] S. Deshmukh, arxiv, 2023
[10] M. Kishi, Audio-AAI, 2026


環境音埋め込みベクトル系列の類似度に基づく環境音合成の自動評価

岸 秀 (きしみのる)[†], 阪井 瞭介[†], 高道 慎之介^{†,‡}, 金森 勇介[‡], 岡本 悠希[‡] ([†]慶應義塾大学, [‡]東京大学)

1. はじめに

1.1 研究背景

- 環境音合成 (text-to-audio; TTA) は、アニメや映画に必要な音の作成に使われる[1]。
→環境音収録, 検索コストを大幅に削減。
- TTAモデルの性能を上げるには何が必要？
→合成音の適切な評価指標。




1.2 従来の評価指標

- 主観評価 (MOS) [2]: 人間が1~5の5段階で評価した平均。
 - OVL (overall quality): 合成音の品質・自然さ
 - REL (relevance): 入力テキストと合成音の関連度→課題: 時間的・金銭的コストがかかる。
- 自動評価: 合成音と{テキスト・正解音}を用いて合成音を自動で評価。
→課題: 従来の自動評価 (MCD[3]等) は主観評価値と相関が低い[4]。
→人間の評価に強く相関する自動評価指標を作りたい。


2. 提案法 (AudioBERTScore): 合成音, 正解音それぞれの埋め込みベクトル系列の類似度計算によるスコア

2.1 提案法概要




- 合成音と参照音 (テキストと対の正解音) からそれぞれ埋め込みベクトル系列を獲得
→類似度計算によりスコアを算出。
- そのスコアと主観評価の相関が高くなる
ことが望ましい。
- 主観評価値との相関を上げる際に重要な点
 - Feature extractorが適切に音をベクトル系列で表現できるか。
 - 合成音と正解音ベクトルの類似度計算をどのように行うか。

2.2 類似度計算の詳細



- 類似度行列の計算
 - $\tilde{r}_*$ (行) は正解音ベクトル系列, $\tilde{s}_*$ (列) は合成音ベクトル系列
 - 各要素は合成音と正解音ベクトルのコサイン類似度
- 2種類のノルム計算
 - 最大値: 自然言語処理の既存手法 BERTScore [5] と同様。局所フレームの対応を仮定。
 - p-norm: 時間遍在する環境音に対応するよう新たに定式化。p->∞で最大値ノルム。



- 3種類のスコア
 - precision: 合成音の特徴を正解音がどのくらい含むか
$$\text{precision}_{\lambda,p} = \lambda \cdot \text{precision}_{\max} + (1 - \lambda) \cdot \text{precision}_p$$
 - recall: 正解音の特徴を合成音がどのくらい含むか
$$\text{recall}_{\lambda,p} = \lambda \cdot \text{recall}_{\max} + (1 - \lambda) \cdot \text{recall}_p$$
 - F1: precisionとrecallの調和平均
$$F1_{\lambda,p} = 2 \times \frac{\text{precision}_{\lambda,p} \times \text{recall}_{\lambda,p}}{\text{precision}_{\lambda,p} + \text{recall}_{\lambda,p}}$$

3. 実験的評価: 提案法は人間の評価値とどのくらい相関する?

3.1 実験条件


- 評価セット = PAM[5]テストセット332組
 - 参照音 (正解音)
 - テキスト
 - 合成音
 - 主観評価値: OVL, REL の5段階MOS値
- 特徴抽出器
 - BYOL-A[7], ATST-Frame[8], AST[9]
- 提案手法スコアと人間評価値の相関の計算
 - ピアソンの線形相関係数 (LCC)
 - スピアマンの順位相関係数 (SRCC)

3.2 各特徴抽出器と各層の比較実験

- 主観評価値と相関が高くなる特徴抽出器の探索。
 - 特徴抽出器はそれぞれ層を持つ。各層を用いて計算したスコアと主観評価値との相関。
-
- TransformerベースであるAST-13層目が主観評価値と最も高い相関。
 - BYOL-A (CNNベース) → local層は音響特徴, global層は文脈情報をそれぞれ保持。
 - AST, ATST-Frame (Transformerベース) → 後半の層が文脈情報を含んでいる。

3.3 OVLとRELの相関値の相関


- 特徴抽出器各層の{OVL, REL}-LCCの相関。



- 全体的にOVL-LCC < REL-LCC。
→音質より関連度の定量化に優れる。
- 相関値の相関 > 0.8
→片方の性能向上でもう一方も向上

3.4 p, λの値の比較実験

- 主観評価値との相関が高くなるp, λの探索。
 - p=106, λ=-3.5で最も高い相関。



3.5 他の自動評価指標との比較

- 参照音を用いる従来指標MCD・WARP-Q[10]よりも高い相関。
→環境音の自動評価に強く貢献。

	OVL		REL	
	LCC	SRCC	LCC	SRCC
Compared metrics				
MCD	0.004	0.008	0.029	0.05
WARP-Q	0.241	0.228	0.202	0.213
Proposed AudioBERTScore (AST, 13-th layer)				
F1 _{max}	0.368	0.397	0.490	0.515
F1 _{λ=0, p=106}	0.401	0.420	0.523	0.545
F1 _{λ=-3.5, p=106}	0.424	0.433	0.546	0.567
Other metrics				
PAM	0.595	0.604	0.529	0.556
CLAPScore	0.337	0.323	0.487	0.475

Reference

- [1] T. Marrinan, arXiv, 2024
- [2] Y. Okamoto, "APSIPA ASC, 2022.
- [3] R. Kubichek, PACRIM, 1933
- [4] 高野, 日本音響学会, 2025
- [5] T. Zhang, ICLR, 2020
- [6] T. Saeki, Interspeech, 2024
- [7] D. Niizumi, TASLP, 2023
- [8] Y. Gong, Interspeech, 2021
- [9] X. Li, arXiv, 2023
- [10] W. A. Jassim, ICASSP, 2021
- [11] F. Xiao, DCASE Workshop, 2024