

(61) [一般発表] 音声基盤モデルは人間と同様の知覚的話者類似性を持つのか?

◎岸 秀, ◎八木 颯斗 (慶應義塾大学), 高道 慎之介 (慶應義塾大学/東京大学), 齋藤 佑樹 (東京大学)

1. はじめに

- 人間: どれくらい声が似ているかを連続的に知覚可能 [1]
- 音声基盤モデル:
 - 音声から埋め込みベクトルを抽出
 - 埋め込みの類似度を話者識別タスクに利用可能 [2-4]



モデル内の話者埋め込み類似性は人間の知覚的話者類似性と整合するか?

- 話者埋め込み類似性と知覚的話者類似性が整合する場合:
 - 高次の知覚機能がデータのみから創発する可能性を示唆
 - 人間知覚と整合する音声基盤モデル設計への知見を提供
- 本研究の目的:
 - 43モデル × 全 Transformer 層を分析
 - 人間知覚と整合するモデル設計要因を解明

2. 提案法

- 類似性の無向完全グラフ表現

- ノード (話者) 集合 S
- エッジ (話者間) 集合 $E = \{i, j \mid i, j \in S, i \neq j\}$
- エッジ重み $W = \{c_{i,j} \mid i, j \in S, i \neq j\}$

$$G = (S, E, W)$$

- 知覚的話者類似性





- $c_{i,j}^{(\text{human})}$ は、2 話者の音声を人間に受聴させたときに聞き手が知覚したスコア

$$G^{(\text{human})} = (S, E, W^{(\text{human})})$$

- 話者埋め込み類似性

- $c_{i,j}^{(\text{model})}$ は、2 話者それぞれの話者埋め込みベクトルのコサイン類似度

$$G^{(\text{model})} = (S, E, W^{(\text{model})})$$



- 2つのグラフ $G^{(\text{human})}, G^{(\text{model})}$ の類似度を3つの指標により評価

- ピアソンの線形相関係数 (LCC)

- グラフのエッジ重みから話者ペア単位での類似度相関を評価

- フロベニウス距離

- 類似度スコアを要素とする隣接行列間の差異を評価

- スペクトル距離

- グラフの正規化グラフラプリアンから得た固有値間のL2距離を計算

- グラフの大局的構造の差異を評価

3. 実験的評価

3.1 実験条件

- データセット

- JVS (男性49名, 女性51名) [5]
- VCTK (女性52名) [6]

- 知覚的話者類似性スコア [5-7]

- 同一性別内の全話者対について,
[-3, 3] の話者類似度スコアが存在

- 話者埋め込み類似性

- 各Transformer層において、各話者10発話の全フレーム・全発話平均表現を話者埋め込みとして抽出
- 同一性別内の全話者対について、話者埋め込み間のコサイン類似度を計算


→ それぞれ [0, 1] に正規化

3.2 全モデルおよび全Transformer 層におけるLCC

- 合計43個のオープンソースモデルを使用 [2-4, 8-17]

※ Layer ratio: 各モデルの層番号を [0,1] に正規化

- 教師あり {ASR, TTS, TTA, 環境音分類} モデル, {音声, 一般音} SSL モデル



- モデルごとにスコアが異なる: WavLM は高いスコアを示す一方、Qwen3-TTS は低い
- 層方向の変化が異なる: 多くのモデルでは深層で低下, AudioGen や VALL-E X では向上
→ 人間知覚との整合性およびその層方向の変化は、モデル設定に依存する可能性を示唆

3.3 重回帰分析によるモデル設定の寄与分析


Response variable	is_dec	is_mlang	is_ssl	hours	params	R ²
layer_max (各モデルの全層における層最大スコア)						
LCC	-0.77	0.00	-0.14	-0.12	-0.14	0.747
Neg. Frobenius norm	-0.22	-0.02	-0.01	-0.01	0.05	0.983
Neg. spectral dist.	0.03	-0.16	-0.15	0.10	-0.03	0.835

- $is_dec < 0$: エンコーダ型は人間知覚と整合的な表現形成を促進する.
- $is_ssl < 0$: 教師ありモデルは人間知覚とより整合する.
- $R^2 \approx 0.8$: モデル設定は層最大スコアを強く説明するが、層傾向は十分に説明できない.

Response variable	is_dec	is_mlang	is_ssl	hours	params	R ²
layer_slope (スコアの層方向変化を表す回帰係数)						
LCC	0.31	0.10	0.06	-0.26	0.29	0.205
Neg. Frobenius norm	-0.12	0.20	-0.02	0.06	0.07	0.123
Neg. spectral dist.	0.09	0.54	0.20	-0.15	0.13	0.241


- $params > 0$: パラメータ増加は層最大スコアを下げるが、層間変動を平坦化する.
 - デコーダ型も上記と同様の傾向を持つ.

3.4 SSL モデルのファインチューニングの影響



- wav2vec2-{base,large}-960h
 - SSL のみで学習されたモデルと比べて、深い層ほどスコアが低下する.
→ ASR fine-tuning により言語情報寄りへ変化
→ 話者性に関する情報が抑制
- wavlm-ssl_sv
 - 全層にわたり平坦化する.
→ 話者関連タスクに最適化されたことにより、話者類似構造が全層で表現

3.5 一般音で学習されたモデル



- audiogen-medium
 - 深い層ほど単調にスコアが上昇
→ 音生成モデルとして学習されたため、深層ほど音色や詳細な音響特徴を表現
- atstframe_base
 - 全層にわたり比較的平坦な傾向
→ 特定のタスクに特化していないため、全層で均一な汎用音響表現を維持

Reference

- [1] 北村, 日本音響学会, 2015 [4] S. Chen, JSTSP, 2022 [7] Y. Saito, TASLP, 2021 [10] F. Kreuk, ICLR, 2023 [13] H. Hu, arXiv, 2026 [16] X. Li, TASLP, 2024
[2] A. Baevski, NeurIPS, 2020 [5] S. Takamichi, arXiv, 2019 [8] D. Zhang, EMNLP, 2023 [11] Y. Gong, Interspeech, 2021 [14] J. Ao, ACL, 2022 [17] D. Rekesh, ASRU, 2023
[3] W.-N. Hsu, TASLP, 2021 [6] J. Yamagishi, 2019 [9] Z. Zhang, arXiv, 2023 [12] A. Radford, ICML, 2023 [15] V. Miara, Interspeech, 2024