

音楽基盤モデルにおける モデル構成と内在音高螺旋の関係

八木 颯斗^{1,a)} 高道 慎之介^{1,2,b)} 佐藤りん³ 田中 啓太郎³ 森島 繁生³

概要：我々の先行研究では、音楽基盤モデルの中間表現を解析することで、音高に関する螺旋構造がモデルに内在することを示した。しかし、その解析対象は限られたモデル系列に留まっており、モデル構成の違いが内在音高螺旋の明瞭さや層方向の出現傾向にどのように関係するかは未解明であった。そこで本研究では、解析対象をより多種の音楽基盤モデルへと拡張するとともに、アーキテクチャ、学習条件、中間表現の構成といったモデル構成上の差異と内在音高螺旋との関係を分析する。加えて、音声や一般音を対象とする基盤モデルにも同一の解析を適用し、音楽基盤モデルで観測された傾向が、異なる音響領域を対象とするモデルにも共通して現れるかを検証する。本研究は、内在音高螺旋の形成に関与するモデル構成上の要因を明らかにし、音楽的概念を構造的に獲得する基盤モデルの設計と内部メカニズムの理解に向けた知見を提供する。

1. はじめに

近年、自己教師あり学習を用いた音楽基盤モデル (music foundation models) が目覚ましい発展を遂げている [1], [2], [3], [4], [5], [6]。これらのモデルは、膨大な楽曲データから音楽の特徴を学習しており、生成だけでなく楽曲分析や検索といった広範なタスクにおいて高い性能を示している [6], [7], [8]。一方で、これらのモデルが内部でどのような音楽的概念をどのように表現しているかについては、依然として十分に解明されていない。

我々は先行研究 [9] において、音楽基盤モデルの中間表現を解析することで、モデル内部に人間の音高知覚と類似した音高螺旋構造 [10] が出現することを示した。具体的には、音高のみが異なる音楽信号を入力した際の中間表現を低次元化し、螺旋モデルをフィッティングすることで、**螺旋構造らしさを定量的に評価する指標である Helicality** を導入した。その結果、Jukebox [1] および MusicGen [2] において、音高の螺旋構造は主として深い層で明瞭に出現




図 1: 内在音高螺旋の解析の流れ

し、モデルサイズや階層構造の異なる条件間で、その明瞭さや層方向の出現傾向が異なることを確認した。以降では、この螺旋を**内在音高螺旋**と称する。

続く先行研究 [11] では、Jukebox の top-level decoder (5B) を対象として、92 種類の楽器単音を用い、入力音の音響的特性と内在音高螺旋の関係を分析した。その結果、Helicality は楽器音色によって大きく変化し、その差異には入力音の調波構造が関係することを示した。

一方で、これらの研究から、どのようなモデル構成が内在音高螺旋の形成と関係するかは十分に明らかになっていない。先行研究 [9] では、モデルサイズや階層構造の異なる条件間で Helicality の差異を観測したものの、解析対象は Jukebox と MusicGen の限られたモデル系列に留まっており、多様なモデル構成

¹ 慶應義塾大学
Keio University

² 東京大学
University of Tokyo

³ 早稲田大学
Waseda University

a) hayatobuti523@keio.jp

b) shinnosuke_takamichi@keio.jp

と内在音高螺旋との関係を共通の枠組みで定量的に分析したものではなかった。また、先行研究 [11] では、入力音側の要因を明らかにするために解析対象のモデルを固定しており、モデルのアーキテクチャ、学習対象、および中間表現の構成といったモデル側の条件については検討されていない。したがって、多種の基盤モデルに同一の解析を適用し、モデル構成と内在音高螺旋の明瞭さおよび層方向の出現傾向との関係を体系的に分析する必要がある。

そこで本研究では、解析対象をより多種の音楽基盤モデルへ拡張するとともに、音声および一般音を対象とする基盤モデルも含む計 26 モデルに内在音高螺旋解析を適用する (図 1)。これにより、内在音高螺旋がモデル系列や対象音響領域を越えて形成されるか、また、先行研究で観測された層方向の変化傾向が、それらの違いを越えて共通して現れるかを検証する。さらに、重回帰分析により、モデル構成の各要因と内在音高螺旋の明瞭さおよびその層方向の変化傾向との関係を定量化し、基盤モデルが音高情報を構造的に獲得する条件についての理解を深める。

2. 関連研究

2.1 音楽基盤モデル

音楽基盤モデルは、大規模な音楽データを用いて事前学習され、音楽生成や音楽理解に関する多様な下流タスクの基盤として利用されるモデルである [12]。本研究では、解析対象に含まれる 4 つの音楽基盤モデル系列である Jukebox [1], MusicGen [2], MusicFM [3], および MERT [4] について述べる。

2.1.1 Jukebox

Jukebox は、マルチスケール VQ-VAE (vector quantized variational autoencoder) [13] を用いて音楽信号を異なる時間解像度の離散トークン列へ符号化し、それらを Transformer [14] に基づく自己回帰モデルによって生成する階層型音楽生成モデルである。離散トークン列を生成するデコーダ言語モデルは、top-level, middle-level, および bottom-level の 3 階層から構成される。top-level は最も粗い時間解像度のトークン列を対象として長時間の音楽構造を捉え、middle-level および bottom-level は上位階層のトークン列を条件として、より高い時間解像度のトークン列を段階的に生成する。

2.1.2 MusicGen

MusicGen は、事前学習済みニューラルオーディオコーデックである EnCodec [15], T5 テキストエンコーダ [16], および Transformer デコーダ言語モデルから構成される非階層型音楽生成モデルである。

2.1.3 MusicFM

MusicFM は、Conformer [17] エンコーダを用いた自己教師あり音楽表現モデル^{*1}であり、マスクトークン予測によって学習される。学習時には、log-Mel スペクトログラムからランダム射影量子化 [18] によって離散ターゲットを生成し、入力音楽信号のマスクされた区間に対応するターゲットを Conformer エンコーダから予測する。この量子化ではランダムに初期化された射影とコードブックを固定して用いるため、別途学習したトークナイザを必要としない。

2.1.4 MERT

MERT は、HuBERT [19] の枠組みに基づく自己教師あり音楽表現モデルであり、Transformer エンコーダをマスク予測によって学習する。MERT は、音響教師と音楽教師の 2 種類の教師モデルを用いて音楽表現を学習する。音響教師から得られる入力信号の音響特徴を表す離散ターゲットを、マスクトークン予測の対象として用いる。一方、音楽教師は定 Q 変換 (constant-Q transform; CQT) 特徴量を再構成対象として与えることで、音高や調和構造に関する情報の獲得を促す。

2.2 音声基盤モデル

音声基盤モデルは、大規模な音声データを用いて学習され、音声認識、音声合成などの多様な下流タスクの基盤として利用されるモデルである。本研究では、解析対象に含まれる 4 つの音声基盤モデル系列である wav2vec 2.0 [20], HuBERT [19], WavLM [21], および Qwen3-TTS-12Hz [22] について述べる。

このうち、wav2vec 2.0, HuBERT, および WavLM は、畳み込みニューラルネットワークに基づく特徴抽出器と Transformer エンコーダから構成される自己教師あり音声表現モデルである。いずれのモデルも、入力音声の特徴抽出器によって潜在表現へ変換し、その一部をマスクした上で Transformer エンコーダに入力する。一方で、予測ターゲットの生成方法や学習目的などのモデル構成が異なる。

2.2.1 wav2vec 2.0

wav2vec 2.0 は、特徴抽出器の出力を Gumbel-Softmax に基づくベクトル量子化 (Gumbel VQ) によって離散化し、得られた量子化表現を予測ターゲットとして用いる。学習時には、マスクされた位置に対応する正解の量子化表現を、複数の負例から識別する対照学習を行う。

^{*1} 本研究のモデル構成分析では、MusicFM を Transformer 系のエンコーダ型モデルとして扱う。

2.2.2 HuBERT

HuBERT は、音響特徴に対してモデル学習とは独立に k -means クラスタリングを行い、得られたクラス ID を離散ターゲットとして用いる。初期段階では MFCC に対するクラスタリングによってターゲットを生成し、後続段階では、学習済みモデルから抽出した中間表現を再度クラスタリングすることでターゲットを更新する。

2.2.3 WavLM

WavLM は、HuBERT のマスク予測を拡張し、雑音や別の発話を混合した音声から、元の音声に対応する離散ターゲットを予測するデノイジングマスク予測によって学習される。

2.2.4 Qwen3-TTS-12Hz

Qwen3-TTS-12Hz は、Qwen3 のデコーダ言語モデルを基盤とし、テキストおよび参照音声を条件として音声を生成する自己回帰型モデルである。音声は、12.5 Hz のフレームレートを持つ 16 層の独自のマルチコードブック型音声トークナイザによって離散化される。このうち、先頭のコードブックは主として発話内容に関する意味情報を表し、後続の 15 層の残差コードブックは音響の詳細を段階的に符号化する。生成時には、モデル本体が先頭コードブックのトークンを自己回帰的に予測し、その予測結果を条件として Multi-Token Prediction モジュールが残りのコードブックのトークンを予測する。

2.3 一般音基盤モデル

本研究では、音声または音楽のみに特化せず、環境音を含む多様な音響信号を対象として学習されたモデルを一般音基盤モデルとして扱う。一般音基盤モデルは、音響イベントや音響シーンの認識、環境音生成などの多様なタスクに利用される。本研究では、解析対象に含まれる 3 つの一般音基盤モデル系列である AST [23], ATST-frame [24], および AudioGen [25] について述べる。

2.3.1 AST

AST (Audio Spectrogram Transformer) は、Transformer エンコーダを用いた教師あり音響分類モデルである。入力音響信号を log-Mel スペクトログラムへ変換し、時間・周波数方向の二次元パッチに分割した上で、線形射影して得られるトークン列から音響イベントを予測する。

2.3.2 ATST-frame

ATST-frame は、Transformer エンコーダを用いた teacher-student 型の自己教師あり音響表現モデルであり、フレーム単位の音響表現を学習する。

2.3.3 AudioGen

AudioGen は、事前学習済みニューラルオーディオコーデックである EnCodec [15], T5 テキストエンコーダ [16], および Transformer デコーダ言語モデルから構成される環境音生成モデルである。

2.4 モデル構成と内部表現特性

基盤モデルのモデル構成と下流タスク性能の関係は、音楽基盤モデルのアプレーションや、多種の基盤オーディオエンコーダの横断比較により調査されている [3], [26]。MusicFM [3] を用いた分析では、事前学習時の入力長を長くすることが、ダウンビート推定や楽曲構造解析などの長時間文脈を必要とするタスクに有効であり、Conformer は Transformer エンコーダより高い性能を示す一方、時間解像度やモデルサイズの影響は比較的小さいことが報告されている。また、基盤オーディオエンコーダの比較では、音楽データを用いたマスク予測モデルが、対照学習モデルや音響コーデックよりも高い楽曲構造解析性能を示す傾向が確認されている [26]。

音声基盤モデルについては、中間表現の性質が層に沿ってどのように変化するかと比較されている [27]。wav2vec 2.0 では最終層付近で中間表現が低次元部分空間へ急激に圧縮される一方、HuBERT や WavLM では深い層まで比較的高次元な表現が維持される。また、WavLM base+ は学習データ量が異なる WavLM base と類似した層方向の変化を示す一方、モデルサイズを拡大した WavLM large では異なる変化傾向が観測されている。

これらの知見は、モデル構成の違いが、下流タスク性能だけでなく、中間表現の性質や層方向の推移にも反映されることを示している。したがって、多種のモデルを共通の枠組みで比較することは、内在音高螺旋の明瞭さや層方向の変化傾向と関係するモデル構成要因を明らかにする上で重要である。

2.5 内在螺旋構造

音高は、その高さ方向の連続性を表す pitch height と、オクターブ周期性に基づく循環構造を表す pitch class からなる二次元的な知覚構造を持つことが知られており、これらを統合した表現として音高螺旋 (pitch helix) が提案されている [10] (図 2)。近年では、このような音高の幾何学的構造が、ラベルなし音響データから教師なしに抽出可能であることも報告されている [28], [29]。

これに対し、我々の先行研究 [9], [11] では、音楽信号そのものではなく音楽基盤モデルの中間表現に




図 2: Shepard の音高螺旋構造 [10].

着目し、モデル内部に音高螺旋構造が内在的に形成されているかを解析した。具体的には、学習済み音楽基盤モデルに対して N_{key} 個の音高のみが異なる単音を入力し、各 Transformer 層から時系列の中間表現を抽出した。そして、得られた中間表現を時間方向に平均化することで、各単音を代表する中間表現ベクトルを得た。次に、各入力音色・各層について、 N_{key} 個の音高に対応する中間表現集合に主成分分析 (PCA) を適用した。第 5 主成分までのうち 3 つを選択する $\binom{5}{3} = 10$ 通りの射影を用いて 3 次元特徴量を生成し、それぞれに対してパラメトリックな音高螺旋モデルをフィッティングした。

音高インデックス t に対する螺旋モデル $\mathbf{y}(t) \in \mathbb{R}^3$ は、高さ変化係数 h_{pitch} 、初期半径 r_0 、半径変化係数 r_{slope} および角周波数 ω_{chroma} など複数のパラメータを用いて、以下のように定式化される：

$$\mathbf{y}(t) = h(t) \cdot \mathbf{c} + r(t) (\cos \theta(t) \cdot \mathbf{u} + \sin \theta(t) \cdot \mathbf{v})$$

$$\text{where } \begin{cases} h(t) = h_{\text{pitch}} \cdot t + h_0 \\ r(t) = r_{\text{slope}} \cdot t + r_0 \\ \theta(t) = \omega_{\text{chroma}} \cdot (t - t_0) \end{cases} \quad (1)$$

ここで $\mathbf{c}, \mathbf{u}, \mathbf{v}$ は $\mathbb{R}^3$ の正規直交基底であり、それぞれ螺旋の中心軸および回転平面を定義する。代表的なパラメータが螺旋形状に与える影響を図 3 に示す。

さらに、PCA により得られた 3 次元特徴量群と螺旋モデルの適合度を定量化する指標として、先行研究 [29] に基づく Helicity を用いた。音高間で次元ごとに標準化した 3 次元特徴量を $\{\mathbf{x}_t\}_{t=1}^{N_{\text{key}}}$ とすると、Helicity は以下のように定義される：

$$\text{Helicity} = \left(\frac{1}{N_{\text{key}}} \sum_{t=1}^{N_{\text{key}}} |\mathbf{x}_t - \mathbf{y}(t)|^2 \right)^{-1} \quad (2)$$

先行研究では、 $\binom{5}{3} = 10$ 通りの 3 次元射影について Helicity を算出し、その最大値を当該入力音色・モデル・層における Helicity とした。

この指標を用いた分析により、Jukebox [1] や MusicGen [2] において、音高の螺旋構造が主として深




図 3: 式 (1) における各パラメータが螺旋形状に与える影響。各行で一つのパラメータのみを変化させる：(a) h_{pitch} は高さ方向の間隔（縦方向スケール）を制御する、(b) r_{slope} は円錐性を制御する（正：半径が増加，負：半径が減少）、(c) ω_{chroma} は 1 回転あたりの音高数（角周波数）を制御する。各列は、3 次元表示（左）とその xz 平面への射影（右）を示す。比較の際、その他のパラメータは固定した。

い層で明瞭に出現することが確認された。また、モデルサイズや階層的アーキテクチャの違いによって、内在音高螺旋の明瞭さや層方向の出現傾向が異なることが示された。

一方で、先行研究 [9] におけるモデル構成に関する分析は、Jukebox と MusicGen の限られたモデル系列内でのモデルサイズおよび階層構造の比較に留まっており、多様なモデル構成と内在音高螺旋との関係を共通の枠組みで体系的に分析したものではなかった。また、続く先行研究 [11] では、入力音側の音響的要因を明らかにするために解析対象のモデルを Jukebox の top-level decoder (5B) に固定しており、モデル側の要因については検討されていない。したがって、アーキテクチャ、学習目的、学習データ、および中間表現の構成といったモデル構成が、内在音高螺旋の明瞭さや層方向の変化傾向とどのように関係するかは未解明である。

そこで本研究では、音楽基盤モデル、音声基盤モデル、および一般音基盤モデルからなる計 26 モデルに同一の内在音高螺旋解析を適用し、モデル構成と内在音高螺旋の明瞭さおよび層方向の変化傾向との関係を体系的に分析する。

3. 分析手法

本研究では、音楽基盤モデル、音声基盤モデル、および一般音基盤モデルに対して共通の内在音高螺旋解析を適用し、モデル構成の違いと内在音高螺旋の明瞭さおよび層方向の変化傾向との関係を分析する。以下に、本研究で用いる分析手法の詳細を述べる。

3.1 種々の基盤モデルへの適用

本研究では、図 1 に示すように、2.5 節で述べた内




図 4: モデル・楽器・層の 3 軸に対する Helicity の集計方法. 各要素は、一つのモデル・楽器・層の組に対して算出した Helicity を表す. 淡青色は各集計量の対象範囲を、濃青色は集計に用いる要素を表す.

在音高螺旋解析を、音楽、音声、および一般音を対象とする複数の基盤モデルに対して同一の手順で適用する. 解析には複数の楽器による単音を用い、各モデル・楽器・層の組について Helicity を算出する. 螺旋モデルおよび評価指標の詳細は先行研究 [9] を参照されたい. これにより、異なる対象音響領域、アーキテクチャ、学習目的、学習データ、および中間表現の構成を持つ基盤モデルを、共通の枠組みで比較する. 具体的には、モデルごとの Helicity と層方向の変化傾向を比較し、モデル構成と内在音高螺旋の明瞭さおよびその出現傾向との関係を分析する.

3.2 Helicity の集計方法

本研究では、各モデル・楽器・層の組に対して得られる Helicity を $H_{m,i,l}$ と表す. m, i, l はそれぞれ、モデル・楽器・層を表す. モデルごとの層方向の傾向を分析するため、まず $H_{m,i,l}$ を楽器間で平均した $\langle H_{m,i,l} \rangle_i$ を、各モデル・各層の Helicity として用いる (図 4 左). $\langle \cdot \rangle$ は、添字方向に平均する演算子である. 本研究では加えて以降の 2 種類の集計量を示す.

- **層平均 Helicity**: 各モデルにおける層間平均 $\langle \langle H_{m,i,l} \rangle_i \rangle_l$.
- **層最大 Helicity**: 各モデルにおける層方向の最大値 $\max_l \langle H_{m,i,l} \rangle_i$.

3.3 モデル構成要因の寄与解析

本節では、内在音高螺旋の明瞭さおよびその層方向の変化傾向が、どのようなモデル構成と関係するかを明らかにするための分析手法を述べる. 具体的には、各モデルにおける Helicity の層方向の推移を数値的に要約し、得られた集計量とモデル構成を表す説明変数との関係を重回帰分析および統計的検定により解析する.

3.3.1 層方向の Helicity 推移の要約

モデル内部で観測される Helicity を、モデルにされる特徴が有する Helicity と比較するため、

各モデルの入力特徴に対しても同一の解析を適用する. 入力特徴には層方向の区別がないため、モデル m に対応する入力特徴と楽器 i の組に対して得られる Helicity を $H_{m,i}^{(in)}$ と表す. これを楽器間で平均した $\langle H_{m,i}^{(in)} \rangle_i$ を**入力特徴 Helicity**と呼ぶ. 次に、各モデル・各層の Helicity から、入力特徴 Helicity を差し引いた $\langle H_{m,i,l} \rangle_i - \langle H_{m,i}^{(in)} \rangle_i$ を**Helicity 改善量 (Helicity improvement; H-Imp)**と呼ぶ. また、我々の先行研究 [30], [31] の知見を踏まえ、本研究では、正の Helicity 改善量を、モデル本体による内在音高螺旋の追加的な獲得・明瞭化として解釈する.

重回帰分析の目的変数には、3.2 節で定義した層平均 Helicity および層最大 Helicity に、以下の 3 種類を加えた計 5 種類を用いる.

- **層平均 Helicity 改善量**: 各モデルにおける Helicity 改善量の層間平均 $\langle \langle H_{m,i,l} \rangle_i - \langle H_{m,i}^{(in)} \rangle_i \rangle_l$. モデルの全層にわたる Helicity の平均的な改善量を表す.
- **層最大 Helicity 改善量**: 各モデルにおける Helicity 改善量の層方向の最大値 $\max_l (\langle H_{m,i,l} \rangle_i - \langle H_{m,i}^{(in)} \rangle_i)$. モデル内部で Helicity が最も大きく改善した層における改善量を表す.
- s_{layer} : Transformer 層インデックスを 0 から 1 の範囲に正規化し、正規化層インデックスに対して Helicity を線形回帰したときの傾き. 正の値は深い層ほど Helicity が上昇する傾向を、負の値は深い層ほど低下する傾向を表す.

3.3.2 モデル構成を説明変数とする重回帰分析

モデル構成は、カテゴリ的な構成を表す二値変数と、数量的な構成条件を表す連続変数によって表現する. 二値変数は、対応するモデル構成を持つ場合を 1、持たない場合を 0 とする. 一方、学習データ量やモデルのパラメータ数などの連続変数は、変数間の尺度を統一するため、モデル間で標準化して用いる. これらの前処理後の説明変数を x_j とする.

各目的変数 y に対して以下の線形モデルを仮定する:

$$y = \beta_0 + \sum_{j=1}^k \beta_j x_j + \varepsilon, \quad (3)$$

ここで、 k は説明変数の数、 x_j はモデル構成を表す第 j 説明変数、 β_0 は切片、 β_j は x_j に対応する回帰係数、 ε は誤差項である. 回帰係数は最小二乗法により推定する.

分析に先立ち、説明変数間の多重共線性を確認するため、分散拡大係数 (variance inflation factor; VIF) を算出する. その後、回帰モデル全体の有意性を F

検定により評価し、各回帰係数について t 検定を行うことで、それぞれのモデル構成要因と目的変数との関係を評価する。

4. 実験の評価

4.1 実験条件

本研究では、先行研究 [9], [11] と同一の楽器単音データセットおよび内在音高螺旋解析を基本としつつ、解析対象を音楽基盤モデル、音声基盤モデル、および一般音基盤モデルからなる計 26 モデルへ拡張した。さらに、モデルへの入力時点ですでに含まれている螺旋構造とモデル内部で観測される螺旋構造を比較するため、入力音から得られる音響特徴、ならびに各モデルで用いられるトークナイザおよび量子化器の表現に対しても同一の解析を適用した。以下に、本研究で用いた実験条件を示す。

4.1.1 モデル条件

本研究では、14 個の音楽基盤モデル、9 個の音声基盤モデル、および 3 個の一般音基盤モデルを解析対象とした。各モデルの詳細を表 1 に示す。学習データについて曲数のみが報告されている場合は、1 曲の長さを 3-6 分と仮定して学習データ量を推定した。

Jukebox. Jukebox については、top-level decoder の 5B および 1B-lyrics, middle-level decoder, ならびに bottom-level decoder の計 4 モデルを用いた。モデルは、先行研究 [9] と同じく、jukemirlib [7] を改変した実装を用いて取得した^{*2}。アーティストおよびジャンルのメタデータは unknown に固定し、1B-lyrics では歌詞トークン入力をゼロ埋めした。

MusicGen. MusicGen については、small, medium, large, および melody の計 4 モデルを用いた^{*3}。すべてのモデルでテキスト条件に空文字列を与えて無効化し、MusicGen-melody ではさらにメロディ特徴入力をゼロに固定して、メロディ条件も無効化した。

MusicFM. MusicFM については、Free Music Archive (FMA) [32] および Million Song Dataset (MSD) [33] を用いてそれぞれ学習された計 2 モデルを用いた^{*4}。

MERT. MERT については、MERT-v0-95M, MERT-v0-95M-public, MERT-v1-95M, および

MERT-v1-330M の計 4 モデルを用いた^{*5}。MERT-v0-95M では、log-Mel 特徴量と chroma をそれぞれ k -means 法 [34] により量子化し、得られたクラス ID を組み合わせた疑似ラベルをマスク予測のターゲットとして用いる。一方、MERT-v1 では、入力音楽信号を EnCodec [15] によって量子化し、複数のコードブックから得られる離散トークンをマスク予測のターゲットとして用いる。また、MERT-v0-95M-public は、公開音楽データセット Music4All [35] のみを用いて学習されている。

wav2vec 2.0. wav2vec 2.0 については、base および large の計 2 モデルを用いた^{*6}。

HuBERT. HuBERT については、base, large, および xlarge の計 3 モデルを用いた^{*7}。

WavLM. WavLM については、base および large の計 2 モデルを用いた^{*8}。

Qwen3-TTS-12Hz. Qwen3-TTS-12Hz については、公式の 12 Hz トークナイザを用いる base モデルのうち、0.6B および 1.7B の計 2 モデルを用いた^{*9}。中間表現の抽出では、テキストおよび参照音声条件として用いず、入力音声をトークナイザによって量子化して得られた離散トークンのみを言語モデルに入力し、各層の中間表現を抽出した。

AST. AST については、AudioSet [36] でファインチューニングされたモデルを用いた^{*10}。

ATST-frame. ATST-frame については、公式の base チェックポイントを用いた^{*11}。

AudioGen. AudioGen については、公式の medium モデルを用いた^{*12}。MusicGen と同様に、解析時はテキスト条件を無効化したうえで、デコーダ言語モデルの各層中間表現を取得した。

4.1.2 比較対象表現条件

基盤モデルの埋め込みに加えて、基盤モデルに入

^{*2} <https://openaipublic.azureedge.net/jukebox/models/> の末尾に、取得したいファイル名 (例: 5b/vqvae.pth.tar, 5b/prior_level_2.pth.tar) を指定する。

^{*3} <https://huggingface.co/facebook/musicgen-small, -medium, -large, および -melody>

^{*4} <https://github.com/minzwon/musicfm>

^{*5} <https://huggingface.co/m-a-p/MERT-v0, https://huggingface.co/m-a-p/MERT-v0-public, https://huggingface.co/m-a-p/MERT-v1-95M, https://huggingface.co/m-a-p/MERT-v1-330M>

^{*6} <https://huggingface.co/facebook/wav2vec2-base, https://huggingface.co/facebook/wav2vec2-large>

^{*7} <https://huggingface.co/facebook/hubert-base-ls960, https://huggingface.co/facebook/hubert-large-1160k, https://huggingface.co/facebook/hubert-xlarge-1160k>

^{*8} <https://huggingface.co/microsoft/wavlm-base, https://huggingface.co/microsoft/wavlm-large>

^{*9} <https://github.com/QwenLM/Qwen3-TTS>

^{*10} <https://huggingface.co/MIT/ast-finetuned-audioset-10-10-0.4593>

^{*11} <https://github.com/Audio-WestlakeU/audioss1/blob/main/audioss1/methods/ATST-Frame/README.md>

^{*12} <https://huggingface.co/facebook/audiogen-medium>

表 1: 解析対象とした基盤モデルのモデル設計. “Input feat.” は入力特徴 Helicity の算出に用いる入力特徴, “Ctx.” はコンテキスト時間長, “Fs” はサンプリング周波数, “Dim.” は埋め込みの次元数を表す.

Model	Transformer	Layers	Params	Training data	Input feat.	Ctx.	Stride	Fs	Frame rate	Dim.
Music foundation models										
Jukebox-top-5B	Decoder	72	5B	60k–120k hours	Top-level VQ-VAE	24 s	2.9 ms	44.1 kHz	345 Hz	4,800
Jukebox-top-1B	Decoder	72	1B	60k–120k hours	Top-level VQ-VAE	24 s	2.9 ms	44.1 kHz	345 Hz	2,048
Jukebox-middle	Decoder	72	1B	60k–120k hours	Middle-level VQ-VAE	6 s	0.73 ms	44.1 kHz	1378 Hz	1,920
Jukebox-bottom	Decoder	72	1B	60k–120k hours	Bottom-level VQ-VAE	1.5 s	0.18 ms	44.1 kHz	5513 Hz	1,920
MusicGen-large	Decoder	48	3.3B	20k hours	MusicGen EnCodec	30 s	20 ms	32 kHz	50 Hz	2,048
MusicGen-medium	Decoder	48	1.5B	20k hours	MusicGen EnCodec	30 s	20 ms	32 kHz	50 Hz	1,536
MusicGen-small	Decoder	24	300M	20k hours	MusicGen EnCodec	30 s	20 ms	32 kHz	50 Hz	1,024
MusicGen-melody	Decoder	48	1.5B	20k hours	MusicGen EnCodec	30 s	20 ms	32 kHz	50 Hz	1,536
MusicFM-FMA	Encoder	12	330M	0.9k hours	Log-Mel spectrogram	30 s	40 ms	24 kHz	25 Hz	1,024
MusicFM-MSD	Encoder	12	330M	50k–100k hours	Log-Mel spectrogram	30 s	40 ms	24 kHz	25 Hz	1,024
MERT-v1-330M	Encoder	24	330M	160k hours	Log-Mel spectrogram	5 s	13.3 ms	24 kHz	75 Hz	1,024
MERT-v1-95M	Encoder	12	95M	20k hours	Log-Mel spectrogram	5 s	13.3 ms	24 kHz	75 Hz	768
MERT-v0-95M	Encoder	12	95M	1k hours	Log-Mel spectrogram	5 s	20 ms	16 kHz	50 Hz	768
MERT-v0-95M-public	Encoder	12	95M	0.9k hours	Log-Mel spectrogram	5 s	20 ms	16 kHz	50 Hz	768
Speech foundation models										
wav2Vec 2.0-base	Encoder	12	95M	960 hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	768
wav2Vec 2.0-large	Encoder	24	317M	60k hours	Log-Mel spectrogram	20 s	20 ms	16 kHz	50 Hz	1,024
WavLM-base	Encoder	12	95M	960 hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	768
WavLM-large	Encoder	24	317M	94k hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	1,024
HuBERT-base	Encoder	12	95M	960 hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	768
HuBERT-large	Encoder	24	317M	60k hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	1,024
HuBERT-xlarge	Encoder	48	1B	60k hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	1,280
Qwen3-TTS-12Hz-0.6B-base	Decoder	28	0.6B	>5M hours	Qwen3-TTS-Tokenizer-12Hz	>524 s	80 ms	24 kHz	12.5 Hz	1,024
Qwen3-TTS-12Hz-1.7B-base	Decoder	28	1.7B	>5M hours	Qwen3-TTS-Tokenizer-12Hz	>524 s	80 ms	24 kHz	12.5 Hz	2,048
General-audio foundation models										
AST	Encoder	12	87M	5.7k hours	Log-Mel spectrogram	10.2 s	10 ms	16 kHz	9.9 Hz	768
ATST-frame-base	Encoder	12	86M	5.3k hours	Log-Mel spectrogram	10 s	40 ms	16 kHz	25 Hz	768
AudioGen-medium	Decoder	48	1.5B	4k hours	AudioGen EnCodec	10 s	20 ms	16 kHz	50 Hz	1,536

力される信号あるいは特徴からも Helicity を計算する. この結果を埋め込みに対する結果と比較することで, 基盤モデルへの入力時点で螺旋が生じたのか, あるいは, Transformer による推論で螺旋が生じたのかを分離して調査する.

音響特徴. 入力信号に内在する局所的な周波数・調波構造のみから, どの程度の Helicity が形成され得るかを検証するため, log-Mel スペクトログラム, log-CQT, MFCC, および chroma の 4 種類の音響特徴を解析した. 各入力信号をサンプリング周波数 22.05 kHz ヘリサンプリングし, librosa を用いて各特徴を算出した後, 時間方向に平均化した. log-Mel スペクトログラムには, FFT サイズ 2048, ホップサイズ 512, および Mel フィルタバンク数 128 を用いた. log-CQT には, ホップサイズ 512, 周波数ビン数 84, および 1 オクターブあたり 12 ビンを用いた. MFCC の次元数は 20 とした. chroma には, ホップサイズ 512, chroma 次元数 12, および 1 オク

表 2: トークナイザ／量子化器の概要. 学習領域は M: 音楽, S: 音声, A: 一般音を表す. CB はコードブック数, Card. は各コードブックの語彙サイズ, 次元は時間平均後の特徴次元である.

トークナイザ	学習領域	データ量	CB	Card.	次元
Jukebox VQ-VAE (bottom / middle / top)	M	60k–120k hours	1	2048	64
MusicGen EnCodec (32 kHz)	M	20k hours	4	2048	128
AudioGen EnCodec (16 kHz)	A+M	4k hours	4	2048	128
Qwen3-TTS-Tokenizer-12Hz	S	>5M hours	16	2048	512

ターブあたり 36 ビンを用いた.

トークナイザ. デコーダ型モデルへの入力時点で表現されている螺旋構造を調べるため, 各モデルで用いられるトークナイザの量子化表現を解析した. 解析対象としたトークナイザの概要を表 2 に示す. 量子化表現としては, 離散コードの ID 自体ではなく, 対応するコードブックベクトルへ戻した連続ベクトルを用い, 時間方向に平均化した.

入力特徴 Helicity. 3.3 節で定義した入力特徴

表 3: 音響特徴およびトークナイザの入力特徴 Helicity.

比較条件	入力特徴 Helicity
音響特徴	
Log-Mel	0.644
Log-CQT	1.115
MFCC	0.704
Chroma	0.764
トークナイザ	
Jukebox VQ-VAE (top)	0.508
Jukebox VQ-VAE (middle)	0.521
Jukebox VQ-VAE (bottom)	0.540
MusicGen EnCodec	0.586
AudioGen EnCodec	0.768
Qwen3-TTS-Tokenizer-12Hz	0.858

Helicity を算出するため、モデルの構成に応じて入力特徴を設定する。エンコーダ型モデルでは音響信号または音響特徴を入力とするが、信号を直接入力とするモデルについても、共通の入力特徴として log-Mel スペクトログラムを用いる。一方、デコーダ型モデルは音響信号や手設計の音響特徴を直接観測せず、対応するトークナイザによって得られた量子化表現を入力として受け取る。したがって、エンコーダ型モデルでは log-Mel スペクトログラムを、デコーダ型モデルでは対応するトークナイザの量子化表現を入力特徴とする（表 1）。

4.1.3 データ条件

本研究では、先行研究 [9], [11] と同一の、合成音楽理論データセット SynTheory [8] の **notes** データセットに含まれる 92 種類の楽器単音を解析対象とした。データセットの構成、音響信号の仕様、ならびにモノラル化およびピーク正規化の前処理は、先行研究 [11] と同一である。各信号は、各モデルおよびトークナイザが要求するサンプリング周波数へ変換した。また、Jukebox については、モデルが要求する入力長に合わせて信号を反復または切り詰めた。

4.1.4 フィッティング条件

式 (1) のパラメータ最適化には Optuna [37] を用いた。探索範囲、乱数シード、および Helicity の採用基準を含む最適化条件は、先行研究 [11] における SynTheory データセットに対する条件（1,000 試行 × 3 回）と同一とした。

4.2 全体分析：層最大 Helicity 改善量

本節では、入力側表現に含まれる音高螺旋構造を基準として、モデル内部で Helicity がどの程度高くなったかを分析する。表 3 に音響特徴およびト




図 5: 各モデルの層最大 Helicity 改善量。

クナイザの入力特徴 Helicity を、図 5 に全 26 モデルの層最大 Helicity 改善量を示す。

モデルに入力される特徴にもわずかに音高螺旋構造が観測される。表 3 に示すように、すべての音響特徴およびトークナイザの入力特徴 Helicity は、我々の先行研究 [11] で算出した 3 次元乱数の Helicity を上回った。この結果は、Transformer 層による処理以前の特徴にも、音高螺旋構造が含まれることを示す。特に log-CQT は 1.115 と最も高く、入力信号の対数周波数配置および調波構造だけでも、音高螺旋構造と整合する表現が生じることが示唆される。また、トークナイザの入力特徴 Helicity は 0.51–0.86 の範囲に分布し、量子化後表現にも音高螺旋構造が保持される一方、その明瞭さはトークナイザ設計によって異なる。

音楽基盤モデルは内在音高螺旋を明瞭化する。図 5 に示すように、すべてのモデルで層最大 Helicity 改善量は正となったため、Transformer 層が内在音高螺旋を形成するといえる。一方で、この値には大きなモデル間差が認められた。層最大 Helicity 改善量の上位 6 モデルはすべて音楽基盤モデルであり、Jukebox-top-5B は 1.150 と突出して高い値を示した。また、14 個の音楽基盤モデルのうち 13 モデルは、音声基盤モデルにおける最大値である Qwen3-




図 6: 全モデルおよび全 Transformer 層における Helicity 改善量。横軸は層インデックスを 0–1 に正規化した値、縦軸はモデルである。

TTS-12Hz-0.6B-base の 0.140 を上回った。したがって、音楽基盤モデルにおける大きな Helicity 改善量は、入力特徴に含まれる周波数・調波構造のみを反映した結果ではなく、音楽を主な学習対象とする事前学習のもとで、自己注意機構を含む Transformer 層が入力系列内の時間方向の情報を統合することにより、人間の音高知覚と整合的な螺旋構造がより明瞭になった可能性を示唆する。一方、一般音基盤モデルである AudioGen-medium も 0.401 と高い値を示したことから、Helicity 改善量の大きさは、音楽を主な学習対象とすることだけでは説明できず、音楽データの有無、アーキテクチャ、学習目的、トークナイザ、および中間表現の構成を含む複数のモデル構成と関係すると考えられる。

4.3 全体分析：層方向の Helicity 推移

層最大値が同程度であっても、広い層範囲で Helicity が高いモデルと、特定層にのみ鋭いピークを持つモデルでは、中間表現における螺旋構造の分布が異なる。そこで、全モデルの各 Transformer 層における Helicity 改善量を図 6 に示す。図の横軸は、モデル間で層数が異なることを考慮し、層インデックスを 0–1 に正規化した値である。各モデルの層平均値、層最大値、および s_{layer} の具体値は表 4 に示す。

音楽基盤モデルは層全体にわたって入力特徴 Helicity を上回る。 図 6 に示すように、音楽基盤モデルでは、多くのモデルが広い層範囲で正の Helicity 改善量を示した。表 4 に示すように、14 個の音楽基盤モデルでは、すべてのモデルで層平均 Helicity 改善量が正となった。一方、9 個の音声基盤モデルでは、すべてのモデルで層平均 Helicity 改善量

が負となった。一般音基盤モデルでは、AudioGen-medium のみが 0.112 と明確な正值を示し、AST および ATST-frame-base は 0 付近であった。この結果は、音楽基盤モデルでは内在音高螺旋が特定層にのみ偶発的に現れるのではなく、モデル内部の比較的広い層範囲にわたって保持または明瞭化されることを示す。

層方向の Helicity 推移はモデル構成によって異なる。 図 6 では、深い層ほど Helicity が高くなるモデル、浅い層ほど高いモデル、および層方向にほぼ平坦なモデルが観察された。Jukebox-top-5B, MusicGen-large, MusicGen-melody, および AudioGen-medium は、深い層に向かって Helicity が上昇した。一方、MusicFM-FMA, MusicFM-MSD, MERT-v0-95M, および MERT-v1-330M は、浅い層側で高い Helicity を示した。音声基盤モデルでは、全 9 モデルで s_{layer} が負となり、特に Qwen3-TTS-12Hz-0.6B-base と Qwen3-TTS-12Hz-1.7B-base では、層が深くなるにつれて Helicity が大きく低下する傾向が認められた。したがって、内在音高螺旋の明瞭さだけでなく、どの層で形成されるかもモデル構成に依存することが示唆される。

4.4 モデル構成の影響：重回帰分析

4.2 節および 4.3 節で観察された全体傾向に、どのモデル構成が関係するかを明らかにするため、3.3.2 節で述べた重回帰分析を行った。説明変数は以下のように定義する：

- **is_encoder**：モデルがエンコーダ型構造か (1), デコーダ型構造か (0) を示す二値変数。
- **log_hours**：事前学習に用いられた学習データ

表 4: 各モデルの層方向 Helicity. 全モデル中の最大値を**太字**, 最小値を下線で示す.

モデル	層平均 Helicity	層最大 Helicity	層平均 H-Imp	層最大 H-Imp	s_{layer}
Music foundation models					
Jukebox-top-5B	0.873	1.658	0.364	1.150	+0.403
Jukebox-top-1B	0.888	1.173	0.379	0.665	+0.224
Jukebox-middle	0.797	1.038	0.276	0.517	-0.092
Jukebox-bottom	0.730	0.851	0.190	0.311	-0.064
MusicGen-large	0.654	0.908	0.068	0.322	+0.415
MusicGen-medium	0.597	0.708	0.011	0.122	+0.178
MusicGen-small	0.822	1.039	0.236	0.453	+0.179
MusicGen-melody	0.925	1.192	0.339	0.606	+0.285
MusicFM-FMA	0.723	0.827	0.080	0.183	-0.233
MusicFM-MSD	0.715	0.822	0.071	0.178	-0.213
MERT-v1-330M	0.812	1.009	0.168	0.365	-0.208
MERT-v1-95M	0.810	0.885	0.166	0.241	+0.056
MERT-v0-95M	0.973	1.149	0.329	0.505	-0.198
MERT-v0-95M-public	0.912	1.011	0.268	0.367	-0.101
Speech foundation models					
wav2Vec 2.0-base	0.561	<u>0.646</u>	-0.083	0.002	-0.162
wav2Vec 2.0-large	<u>0.536</u>	0.660	-0.108	0.016	-0.247
WavLM-base	0.615	0.701	-0.029	0.057	-0.139
WavLM-large	0.640	0.731	-0.004	0.087	-0.065
HuBERT-base	0.639	0.661	-0.004	0.017	-0.048
HuBERT-large	0.616	0.649	-0.028	0.005	-0.089
HuBERT-xlarge	0.639	0.693	-0.005	0.049	-0.094
Qwen3-TTS-12Hz-0.6B-base	0.771	0.997	-0.087	0.140	<u>-0.317</u>
Qwen3-TTS-12Hz-1.7B-base	0.598	0.859	<u>-0.260</u>	<u>0.001</u>	-0.254
General-audio foundation models					
AST	0.640	0.691	-0.004	0.047	-0.042
ATST-frame-base	0.639	0.768	-0.005	0.124	-0.112
AudioGen-medium	0.879	1.169	0.112	0.401	+0.431

表 5: モデル構成を説明変数とした重回帰分析における係数 (p 値). **太字**は $p < 0.05$ で有意な係数を表す.

Dependent variable	is_encoder	log_hours	log_context_sec	frame_rate_hz	dim	includes_music	R^2
層平均 Helicity	-0.08 (0.303)	0.01 (0.727)	-0.04 (0.362)	-0.03 (0.285)	0.00 (0.992)	0.12 (0.055)	0.45
層最大 Helicity	-0.12 (0.301)	0.01 (0.766)	-0.04 (0.515)	-0.07 (0.122)	0.12 (0.005)	0.17 (0.070)	0.68
層平均 H-Imp	-0.10 (0.229)	0.00 (0.998)	-0.09 (0.048)	-0.04 (0.273)	0.04 (0.230)	0.14 (0.038)	0.67
層最大 H-Imp	-0.13 (0.218)	0.00 (0.956)	-0.09 (0.125)	-0.07 (0.098)	0.16 (< .001)	0.18 (0.042)	0.78
s_{layer}	-0.41 (< .001)	-0.05 (0.138)	-0.14 (0.008)	-0.12 (0.002)	0.07 (0.048)	-0.03 (0.616)	0.78

量 [時間] の対数値. 学習データ量が範囲として報告されているモデルについては, その中間値を代表値として用いた.

- **log_context_sec**: 事前学習時にモデルへ入力される音響系列のコンテキスト長 [秒] の対数値.
- **frame_rate_hz**: 中間表現の時間方向のフレームレート [Hz].

- **dim**: 解析対象とした中間表現の特徴次元数.
- **includes_music**: 事前学習データに音楽が含まれるか (1), 含まれないか (0) を示す二値変数.

各説明変数の値には, 表 1 に示したモデル構成を用いた. 目的変数には, 3.3.1 節で定義した, 層平均 Helicity, 層最大 Helicity, 層平均 Helicity 改善量, 層最大 Helicity 改善量, または s_{layer} の 5 種

類の集計量を用いた。

分析に先立ち、説明変数間の多重共線性を確認するため、すべての説明変数について分散拡大係数 (VIF) を算出した。VIF は 1.73–3.73 であり、深刻な多重共線性は確認されなかった。表 5 に重回帰分析の結果を示す。回帰モデル全体に対する F 検定では、層平均 Helicity のみ $p = 0.053$ であり、有意水準 5% には達しなかった。一方、残る 4 つの目的変数では、回帰モデル全体がいずれも $p < 0.001$ で有意であった。これらの結果から、以下の知見が得られる。

入力特徴 Helicity を除くことで、モデル構成要因の影響が明確になる。 入力特徴 Helicity を差し引かない層平均 Helicity では、いずれの説明変数も有意ではなく、回帰モデル全体も有意水準 5% に達しなかった。一方、層平均 Helicity 改善量では $R^2 = 0.67$ 、層最大 Helicity 改善量では $R^2 = 0.78$ となり、入力特徴を考慮することで説明力が高くなった。また、`includes_music` は、層平均および層最大 Helicity では $p = 0.055$ および 0.070 であったのに対し、差分を用いた Helicity 改善量の両目的変数では有意となった。これは、絶対的な Helicity には、音響特徴またはトークナイザが有する音高螺旋構造の影響が含まれるのに対し、Helicity 改善量を用いることで、入力側に由来する構造とモデル内部で生じた変化とを切り分けて評価できるためであると考えられる。

学習データ量よりも、音楽データの有無が内在音高螺旋の明瞭化に関係する。 `includes_music` は、層平均および層最大 Helicity 改善量それぞれに対して有意な正の係数を示した。一方、`log_hours` は 5 つの目的変数のいずれに対しても有意ではなく、層平均および層最大 Helicity 改善量に対する係数も、それぞれ 0.000 ($p = 0.998$) および 0.002 ($p = 0.956$) とほぼ 0 であった。したがって、単純な学習データ量の増加よりも、音楽データを含むことが、内在音高螺旋の明瞭化と関係することが示唆される。この結果は 4.2 節の観察と整合しており、旋律、和声、調性、およびオクターブ等価性を含む音楽的文脈の学習が、Transformer による文脈統合を通じて、異なるオクターブ間の音高関係を人間の音高知覚と整合的な幾何学構造として組織化する可能性を示唆する。

高次元なモデルでは、特定層で内在音高螺旋が明瞭になる。 `dim` は、層最大 Helicity および層最大 Helicity 改善量に対して有意な正の係数を示した一方、層平均に対する係数はいずれも有意ではなかった。この結果は、中間表現次元の増加が全層の Helicity を一様に高めるのではなく、特定の層にお

いて、より明瞭な内在音高螺旋が現れる傾向と関係することを示す。さらに、中間表現次元は `s_layer` に対しても有意な正の係数を示し、次元が大きいモデルほど深層側で Helicity が高まる傾向が認められた。

アーキテクチャの違いは、内在音高螺旋の層方向推移に現れる。 `is_encoder` は、`s_layer` に対して -0.406 ($p < 0.001$) と、有意な負の係数を示した。一方、層平均値および層最大値に対する係数はいずれも有意ではなかった。したがって、エンコーダ/デコーダの違いは、内在音高螺旋の明瞭さそのものよりも、その明瞭さがモデル内部でどのように推移するかに強く関係する。

時間の長さや解像度は内在音高螺旋の層方向の推移に関係する。 さらに、時間の長さや解像度に関する `log_context_sec` および `frame_rate_hz` も、`s_layer` に対して有意な負の係数を示した。すなわち、コンテキスト長が長いモデル、およびフレームレートが高いモデルほど、深層に向かって Helicity が低下する傾向が認められた。

主要なモデル構成は内在音高螺旋の全体傾向を説明するが、モデル間差も残る。 層平均 Helicity 改善量、層最大 Helicity 改善量、および `s_layer` の決定係数は、それぞれ 0.67 、 0.78 、 0.78 であった。したがって、本研究で用いた 6 つの説明変数は、入力特徴に対する Helicity の変化と、その層方向推移を比較的良好に説明する。一方で、これらの説明変数では捉えきれないモデル間差も一部残された。

5. まとめ

本研究では、音楽基盤モデル、音声基盤モデル、および一般音基盤モデルからなる計 26 モデルに共通の内在音高螺旋解析を適用し、モデル構成と Helicity の明瞭さおよび層方向の推移との関係を分析した。また、音響特徴ならびにトークナイザの量子化表現を入力特徴として用いることで、入力特徴が有する螺旋構造と、モデル内部で生じる変化とを区別して評価した。

全体分析の結果、モデルへの入力特徴にも一定の音高螺旋構造が認められた一方、すべてのモデルで層最大 Helicity 改善量が正となり、Transformer 層による処理を通じて内在音高螺旋がさらに明瞭化されることが示された。特に、層最大 Helicity 改善量の上位 6 モデルはいずれも音楽基盤モデルであり、音楽基盤モデルではモデル内部で螺旋構造が大きく明瞭化される傾向が確認された。

重回帰分析では、音楽データを用いたモデルほど層平均 Helicity 改善量が大きく、広い層範囲にわ

たって内在音高螺旋が明瞭化される傾向が認められた。また、中間表現次元が大きいモデルほど層最大 Helicity およびその改善量が大きく、一部の層で明瞭な螺旋構造を示す傾向が認められた。一方、学習データ量はいずれの指標とも有意な関係を示さず、データ量の増加だけで内在音高螺旋が明瞭化する傾向は確認されなかった。さらに、Helicity の層方向の推移には、主にアーキテクチャおよび中間表現次元が関係することが示された。

以上より、内在音高螺旋の明瞭さと層方向の推移には、複数のモデル構成要因が異なる形で関係することが示唆された。ただし、本研究は既存の学習済みモデル間の対応関係を分析したものであり、各モデル構成要因の因果的な効果を直接検証したのではない。今後は、個々のモデル系列の詳細な比較や、モデル構成を独立に変更した統制実験を行い、各要因が内在音高螺旋の形成および明瞭化に与える影響を詳細に検証する必要がある。

謝辞： 本研究は、JST 創発的研究支援事業 JPMJFR226V の支援を受けて実施した。

参考文献

- [1] P. Dhariwal, H. Jun, C. Payne, J. W. Kim, A. Radford, and I. Sutskever, “Jukebox: A generative model for music,” *arXiv preprint arXiv:2005.00341*, 2020.
- [2] J. Copet, F. Kreuk, I. Gat, T. Remez, D. Kant, G. Synnaeve, Y. Adi, and A. Défossez, “Simple and controllable music generation,” in *NeurIPS*, 2023.
- [3] M. Won, Y.-N. Hung, and D. Le, “A foundation model for music informatics,” *arXiv preprint arXiv:2311.00318*, 2023.
- [4] Y. Li, R. Yuan, G. Zhang, Y. Ma, X. Chen, H. Yin, C. Xiao, C. Lin, A. Ragni, E. Benetos, N. Gyenge, R. Dannenberg, R. Liu, W. Chen, G. Xia, Y. Shi, W. Huang, Z. Wang, Y. Guo, and J. Fu, “MERT: Acoustic music understanding model with large-scale self-supervised training,” *arXiv preprint arXiv:2306.00107*, 2023.
- [5] A. Agostinelli, T. I. Denk, Z. Borsos, J. Engel, M. Verzetti, A. Caillon, Q. Huang, A. Jansen, A. Roberts, M. Tagliasacchi, M. Sharifi, N. Zeghidour, and C. Frank, “MusicLM: Generating music from text,” *arXiv preprint arXiv:2301.11325*, 2023.
- [6] W.-H. Liao, Y. Takida, Y. Ikemiya, Z. Zhong, C.-H. Lai, G. Fabbro, K. Shimada, K. Toyama, K. W. Cheuk, M. A. Martínez-Ramírez, S. Takahashi, S. Uhlich, T. Akama, W. Choi, Y. Koyama, and Y. Mitsufuji, “Music foundation model as generic booster for music downstream tasks,” *TMLR*, 2025.
- [7] R. Castellon, C. Donahue, and P. Liang, “Codified audio language modeling learns useful representations for music information retrieval,” in *ISMIR*, 2021.
- [8] M. Wei, M. Freeman, C. Donahue, and C. Sun, “Do music generation models encode music theory?” in *ISMIR*, 2024.
- [9] 八木 颯斗 and 高道 慎之介, “音楽基盤モデルは音高情報を螺旋構造に埋め込むか?” in **情報処理学会 音楽情報科学研究会**, Aug. 2025.
- [10] R. N. Shepard, “Geometrical approximations to the structure of musical pitch,” *Psychological Review*, vol. 89, no. 4, pp. 305–333, 1982.
- [11] 八木 颯斗, 高道 慎之介, 佐藤 りん, 田中 啓太郎, and 森島 繁生, “音楽基盤モデルにおける音響特徴と内在音高螺旋の関係,” in **情報処理学会 音楽情報科学研究会**, Mar. 2026.
- [12] Y. Ma, A. Øland, A. Ragni, B. M. D. Sette, C. Saitis, C. Donahue, C. Lin, C. Plachouras, E. Benetos, E. Shatri, F. Morreale, G. Zhang, G. Fazekas, G. Xia, H. Zhang, I. Manco, J. Huang, J. Guinot, L. Lin, L. Marinelli, M. W. Y. Lam, M. Sharma, Q. Kong, R. B. Dannenberg, R. Yuan, S. Wu, S.-L. Wu, S. Dai, S. Lei, S. Kang, S. Dixon, W. Chen, W. Huang, X. Du, X. Qu, X. Tan, Y. Li, Z. Tian, Z. Wu, Z. Wu, Z. Ma, and Z. Wang, “Foundation models for music: A survey,” *arXiv preprint arXiv:2408.14340*, 2024.
- [13] A. van den Oord, O. Vinyals, and K. Kavukcuoglu, “Neural discrete representation learning,” in *NeurIPS*, vol. 30, 2017.
- [14] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. u. Kaiser, and I. Polosukhin, “Attention is all you need,” in *NeurIPS*, vol. 30, 2017.
- [15] A. Défossez, J. Copet, G. Synnaeve, and Y. Adi, “High Fidelity Neural Audio Compression,” in *ICLR*, 2024.
- [16] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, “Exploring the limits of transfer learning with a unified text-to-text transformer,” *Journal of machine learning research*, vol. 21, no. 140, pp. 1–67, 2020.
- [17] A. Gulati, J. Qin, C.-C. Chiu, N. Parmar, Y. Zhang, J. Yu, W. Han, S. Wang, Z. Zhang, Y. Wu, and R. Pang, “Conformer: Convolution-augmented transformer for speech recognition,” in *Interspeech*. ISCA, 2020, pp. 5036–5040.
- [18] C.-C. Chiu, J. Qin, Y. Zhang, J. Yu, and Y. Wu, “Self-supervised learning with random-projection quantizer for speech recognition,” in *ICML*, vol. 162. PMLR, 2022, pp. 3915–3924.
- [19] W.-N. Hsu, B. Bolte, Y.-H. H. Tsai, K. Lakhota, R. Salakhutdinov, and A. Mohamed, “HuBERT: Self-supervised speech representation learning by masked prediction of hidden units,” *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 29, pp. 3451–3460, 2021.
- [20] A. Baevski, Y. Zhou, A. Mohamed, and M. Auli, “wav2vec 2.0: A framework for self-supervised learning of speech representations,” in *NeurIPS*, vol. 33, 2020, pp. 12 449–12 460.
- [21] S. Chen, C. Wang, Z. Chen, Y. Wu, S. Liu, Z. Chen, J. Li, N. Kanda, T. Yoshioka, X. Xiao, J. Wu, L. Zhou, S. Ren, Y. Qian, Y. Qian, J. Wu, M. Zeng, X. Yu, and F. Wei, “WavLM: Large-scale self-supervised pre-training for full stack speech

- processing,” *IEEE Journal of Selected Topics in Signal Processing*, vol. 16, no. 6, pp. 1505–1518, 2022.
- [22] H. Hu, X. Zhu, T. He, D. Guo, B. Zhang, X. Wang, Z. Guo, Z. Jiang, H. Hao, Z. Guo, X. Zhang, P. Zhang, B. Yang, J. Xu, J. Zhou, and J. Lin, “Qwen3-TTS technical report,” *arXiv preprint arXiv:2601.15621*, 2026.
- [23] Y. Gong, Y.-A. Chung, and J. Glass, “AST: Audio spectrogram transformer,” in *Interspeech*, 2021, pp. 571–575.
- [24] X. Li, N. Shao, and X. Li, “Self-supervised audio teacher-student transformer for both clip-level and frame-level tasks,” *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 32, pp. 1336–1351, 2024.
- [25] F. Kreuk, G. Synnaeve, A. Polyak, U. Singer, A. Défossez, J. Copet, D. Parikh, Y. Taigman, and Y. Adi, “AudioGen: Textually guided audio generation,” in *ICLR*, 2023.
- [26] K. Toyama, Z. Zhong, A. Takahashi, S. Takahashi, and Y. Mitsufuji, “Do foundational audio encoders understand music structure?” in *ICASSP*, 2026, pp. 15 242–15 246.
- [27] S. Sadok and X. Alameda-Pineda, “Insidessl: Understanding self-supervised speech representations using a model-centric perspective,” in *Interspeech*, 2026.
- [28] V. Lostanlen, S. Sridhar, B. McFee, A. Farnsworth, and J. P. Bello, “Learning the helix topology of musical pitch,” in *ICASSP*, 2020, pp. 11–15.
- [29] S. Sridhar and V. Lostanlen, “Helicality: An isomap-based measure of octave equivalence in audio data,” in *ISMIR*, 2020.
- [30] 佐藤 りん, 田中 啓太郎, 八木 颯斗, 高道 慎之介, and 森島 繁生, “音楽基盤モデルの表現形成における学習過程の解析手法の検討,” in 情報処理学会 音楽情報科学研究会, Mar. 2026.
- [31] —, “音楽基盤モデルの学習過程における内在音高螺旋の解析,” in 情報処理学会 音楽情報科学研究会, Jun. 2026.
- [32] M. Defferrard, K. Benzi, P. Vandergheynst, and X. Bresson, “Fma: A dataset for music analysis,” in *ISMIR*, 2017.
- [33] T. Bertin-Mahieux, D. P. Ellis, B. Whitman, and P. Lamere, “The million song dataset,” in *ISMIR*, 2011.
- [34] J. A. Hartigan and M. A. Wong, “A k-means clustering algorithm,” *JSTOR: Applied Statistics*, vol. 28, no. 1, pp. 100–108, 1979.
- [35] I. A. P. Santana, F. Pinhelli, J. Donini, L. G. Catharin, R. B. Mangolin, Y. M. G. Costa, V. D. Feltrim, and M. A. Domingues, “Music4All: A new music database and its applications,” in *IWS-SIP*. IEEE, 2020, pp. 399–404.
- [36] J. F. Gemmeke, D. P. W. Ellis, D. Freedman, A. Jansen, W. Lawrence, R. C. Moore, M. Plakal, and M. Ritter, “Audio Set: An ontology and human-labeled dataset for audio events,” in *ICASSP*, 2017, pp. 776–780.
- [37] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” in *ACM SIGKDD*, 2019, pp. 2623–2631.