

Full-duplex 音声対話モデルにおける性別表現のプロービング

八木 颯斗^{1,a)} 稲垣 賢斗¹ 高島 悠樹² 安藤 厚志² 高道 慎之介¹

概要：近年、ユーザの音声を聞きながらシステムも同時に発話することが可能な full-duplex 音声対話モデルが注目されている。従来手法は言語情報やターンテイキングにおいて高い自然性を実現している一方で、話者性などの非言語情報の制御が困難であり、また非言語情報がモデル内部でどのように保持・制御されているのかも明らかでない。本研究では、非言語情報のうち話者性別を対象とし、full-duplex 音声対話モデルにおける性別情報がモデルのどの部分で獲得されているか、どのような内部表現を持つかを明らかにすることを旨とする。音声対話モデルの中間表現または出力表現に対してプロービング分析を行い、その正解精度を比較することで、中間表現における話者性別表現の有無を検証する。日本語 full-duplex 音声対話モデル J-Moshi の生成音声および Temporal Transformer が出力する中間表現を対象としてプロービング分析を行った結果、既存の full-duplex 音声対話モデルでは、モデル前半部で言語情報と話者性別情報が同時に保持されていることが確認され、話者性制御に向けた有用な手がかりが得られた。

キーワード：Full-duplex 音声対話, プロービング, 話者性別分類

Probing Gender Representations in Full-Duplex Spoken Dialogue Model

HAYATO YAGI^{1,a)} KENTO INAGAKI¹ YUKI TAKASHIMA² ATSUSHI ANDO² SHINNOSUKE TAKAMICHI¹

Abstract: Recently, full-duplex spoken dialogue models, which enable a system to speak while simultaneously listening to user speech, have attracted increasing attention. While conventional methods achieve high naturalness in terms of linguistic content and turn-taking behavior, controlling non-linguistic information, such as speaker characteristics, remains challenging. Moreover, it is still unclear how such non-linguistic information is represented and controlled within these models. In this study, we focus on speaker gender as a representative non-linguistic attribute. Our goal is to identify which modules of full-duplex spoken dialogue models acquire gender information and what internal representations they have. To this end, we conduct probing analyses on both intermediate and output representations of the models. By comparing classification accuracies, we examine whether speaker gender information is encoded in intermediate representations. We apply this probing framework to generated speech and intermediate representations produced by the Temporal Transformer in the Japanese full-duplex spoken dialogue model J-Moshi. Our results show that existing full-duplex spoken dialogue models simultaneously retain both linguistic and speaker gender information in the early part of the model. These findings provide valuable insights toward developing controllable modeling of speaker attributes in full-duplex dialogue systems.

Keywords: Full-duplex spoken dialogue, probing, speaker gender classification

1. はじめに

大規模言語モデルの登場により、人間と対話システムと

のテキスト対話の自然性は著しく向上した [1–3]。これに追従する形で、音声対話研究も発展を遂げている。人間同士の音声対話では、言語情報（テキスト内容）だけでなく、発話のタイミングや話し方といった言語以外の側面も重要な役割を果たしている。同様に、人間と対話システムとの音声対話においても、こうした側面を適切に扱うことは、自然で円滑な対話を実現する上で重要である。

¹ 慶應義塾大学
Keio University, Japan.

² NTT 株式会社
NTT, Inc.

^{a)} hayatobuti523@keio.jp

近年の音声対話モデルは、その構成の観点から、カスケード型と full-duplex 型の二つに大別できる。カスケード型音声対話モデルは、典型的には音声認識、対話制御、音声合成を直列に結合した構成をとり、各要素を独立に設計・最適化できるという特徴を有する。このとき、対話制御モジュールにおけるルール設計や予測モデルによって人間らしいターンテイキングや相槌を実現している [4,5]。一方で、音声認識と音声合成を時間的に分離して処理するという構造上の制約から、従来手法の多くはユーザとシステムが発話・聴取を交互に行うことを前提とした設計となっている [6]。これに対し、full-duplex 音声対話モデルでは、ユーザ音声とシステム音声を並列に扱い、発話と聴取を同時に行う [7-11]。このような構成により、発話権交替を含む対話的挙動を、モデル内部の時系列処理として直接扱うことが可能となる。

Full-duplex 音声対話モデルにおける重要な課題として、発話権交代に加えて、話者性のような非言語情報を適切に制御可能かという点がある。話者性は、システムの人格や話者同一性の知覚に強く関わる要素であり、対話システムの自然性に大きな影響を与える。従来、音声合成の分野では、話者埋め込みを用いて、テキストエンコーダや音響モデルで話者性を明示的に制御する手法が提案されてきた [12]。一方、入力音声の理解から出力音声の生成までを統合的に扱う full-duplex 音声対話モデルにおいては、話者性がモデル内部のどの表現に内在し、どのような機序で出力音声に反映されるのかについて、十分に明らかにされていない。本稿では、日本語 full-duplex 音声対話モデルの先駆的存在である J-Moshi [8] に着目する。著者らの予備検討により、J-Moshi が生成するシステム音声において、対話の途中で話者性が意図せず変化する場合があることが確認された。この結果は、話者性が文脈情報の変動に伴って不安定に表出している可能性を示唆している。

そこで本稿では、話者性の要素の 1 つとして話者性別に着目し、J-Moshi におけるシステム音声の性別表現の在処を明らかにすることを目的とする。本研究では、性別に関する情報が J-Moshi を構成する Temporal Transformer の内部表現に保持されているという仮説のもと、Temporal Transformer の潜在表現に対してプロービング分析を実施する。具体的には、Temporal Transformer の出力表現を入力として話者性別分類器を学習し、その予測性能を評価することで、性別表現がどの程度現れているかを分析する。本研究により、日本語 full-duplex 音声対話モデル J-Moshi において話者性別に関する情報が内部表現のどの段階で保持・処理されているかを明らかにし、話者性制御に向けたモデル機序の理解を深めることを目指す。




図 1 J-Moshi のアーキテクチャ。(1) ユーザ音声とシステム音声を並列ストリームで表現し、(2) Temporal Transformer により次フレームの文脈情報 (temporal context) を生成したのち、(3) Depth Transformer でトークン深さ方向の生成を行う。

Fig. 1 Model architecture of J-Moshi, consisting of Mimi, a Temporal Transformer, and a Depth Transformer.

2. 関連研究

2.1 日本語 Full-duplex 音声対話モデル J-Moshi

J-Moshi のアーキテクチャを図 1 に示す。以降では、J-Moshi の出力する音声をシステム音声、対話相手である人間の音声をユーザ音声と称する。

音声符号化. 再帰ベクトル量子化 (residual vector quantization; RVQ) [13] に基づくニューラル音声符号化器である Mimi を用いる。RVQ は、各フレームの音声波形を Q 個のコードブックを用いて再帰的にベクトル量子化する。モデルは、量子化を担うエンコーダと逆量子化を担うデコーダから構成され、音声波形を再構成するように学習される。深さインデックス q ($1 \leq q \leq Q$) では、深さインデックス $1, \dots, q-1$ の量子化で生じた量子化残差に対して、量子化が行われる。これを改良した Mimi は、 $q=1$ と $q \geq 2$ で異なる表現を学習する。 $q=1$ では、波形再構成だけでなく、自己教師あり学習モデル WavLM [14] の特徴量を予測するように学習される。WavLM は Transformer [15] に基づいて音声から文脈的特徴を獲得するため、 $q=1$ において得られる量子化ベクトルは、semantic トークンに類する。他方、 $q \geq 2$ では波形再構成のみを目的として学習されるため、音響的特徴を保持する acoustic トークンに類する。

音声の並列ストリーム. システム音声とユーザ音声を並列ストリームで扱う。各フレームは、{システム, ユーザ} 音声の {semantic, acoustic} トークンを結合した特徴量を扱う^{*1}。ユーザ音声のトークンはユーザ音声から Mimi を介して生成され、システム音声のトークンは後述する RQ-Transformer から生成される。この並列ストリーム構造により、人間とシステムによる同時の聴取・発話が実現されている。

時間方向の予測と深さ方向の生成. RQ-Transformer を用

^{*1} 詳細は省略するが³、システム音声に対応する単語トークンも並列に扱う。

いて、次のフレームのシステム音声のトークンを生成する。このモデルは、時間方向の予測を担う Temporal Transformer と、量子化深さ方向の予測を担う Depth Transformer により実現される。あるフレームにおいて、Temporal Transformer は、当該フレームより前のフレームのトークン系列から、当該フレームにおける文脈情報 (temporal context) を生成する。この文脈情報に基づいて、Depth Transformer は、当該フレームのトークンを再帰的に生成する。システム音声は、生成されたトークンから Mimi のデコーダを介して生成される。

2.2 Full-duplex 音声対話モデルにおける話者性制御

従来の full-duplex 音声対話モデルの多くでは、システム音声の話者性を明示的に制御する機構は備えられておらず、話者性は学習データに依存して生成される場合が多い [10, 16]。文献 [17] では、音声対話モデルが出力した音声トークンをメルスペクトログラム変換器およびボコーダを介してシステム音声へ変換する方式を採用しているが、この際メルスペクトログラムへの変換時に話者埋め込みを入力することでシステム音声の話者性を制御している。しかしながらこのような手法は、話者性が音声合成過程において付与されるため、音声対話モデル内部の時系列表現や文脈表現と話者性との関係を直接的に捉えることはできない。そのため、音声対話モデルそのものにおける話者性の明示的な制御については依然として検討の余地がある。音声対話モデル内部における話者性の表現と制御可能性を明らかにすることは、full-duplex 音声対話モデルにおける話者性の一貫性確保や制御手法の設計に向けた重要な手がかりとなる。

2.3 プロービングによる分析

プロービングとは、深層学習モデルが入力から得る中間表現 (例えば、中間層が出力したベクトル) に含まれる情報を解析する手法である [18]。対象とする中間表現から線形分類器などの単純な分類器 (プローブ) を学習し、所望するラベルをどの程度分類できるかを評価する。この分類性能が高ければ、その中間表現はそのラベルについて識別的な特徴を有していると言える。

このようなプロービング分析は、言語モデルにおける構文情報や意味情報の解析 [19]、視覚言語モデルにおける領域情報・オブジェクト情報の解析 [20] など、モデル内部表現に含まれる様々な情報を評価する一般的な手法として用いられている。音声モデルに対しても、自己教師あり音声表現モデル (例えば wav2vec 2.0 [21], HuBERT [22], WavLM [14]) を中心に、プロービング分析が行われており、中間表現に含まれる韻律・パラ言語情報などが調査されている [23]。しかしながら、同様の調査は full-duplex モデルに対して未実施であり、話者性に関する中間表現の分




図2 性別表現のプロービング分析の概要。 (1) は音響特徴量 (メルフィルタバンク特徴量) を、(2) は temporal context を入力とした性別分類の流れを示す。

Fig. 2 Overview of our probing analysis: (1) the case using acoustic features extracted from generated speech, (2) the case using temporal context.

析は十分に検討されていない。したがって本研究では、先行研究と同様に単純な分類器を用いたプロービング分析の枠組みに基づき、full-duplex 音声対話モデルの中間表現に含まれる話者性別情報の有無を評価する。

3. 分析手法

本章では、日本語 full-duplex 音声対話モデル J-Moshi において、非言語情報がモデル内部のどの処理段階に表出しているかを明らかにするための分析手法について述べる。本研究では、非言語情報の一例として話者性別に着目する。

3.1 分析の基本方針

本研究では、J-Moshi の内部表現である temporal context に対してプロービング分析を実施する。2.1 節で述べたように、J-Moshi の Temporal Transformer ではフレームごとに文脈情報である temporal context を生成する。Temporal context はフレームごとに変化する時系列情報をモデル化した表現であり、システムが次に発話する内容に関する文脈情報が保持されていると考えられる。また、Depth Transformer は temporal context に基づいて単語トークンおよび音声トークンを生成する。J-Moshi はシステム音声およびユーザ音声ともに複数話者からなるデータで学習されているため、temporal context には言語的な文脈情報に加えて話者に依存する非言語情報も含まれていると考えられる。そこで本研究では、temporal context には音声の非言語情報が含まれており、Depth Transformer はそれに基づいて生成音声の話者を再現している、という仮説を立て、実験によりこれを検証する。

3.2 分析の流れ

上記の仮説を検証するため、本研究ではプロービング分析を用いる。具体的には図2に示すように、システム音声から算出した音響特徴量および temporal context を入力とした性別分類タスクを設定し、それぞれの分類精度を比較することで、temporal context における話者性別情報の表出

の程度を評価する。

まず、入力ユーザ音声を J-Moshi に与えて推論を行い、対応する temporal context を計算するとともに、システム音声を生成する。そして得られたシステム音声に対して、性別ラベルを付与する。続いて、temporal context および生成音声それぞれを入力として、話者性別分類器を学習する。最後に、性別分類精度の評価を通じて、temporal context に含まれる話者性別情報の表出度合いを定量的に分析する。生成音声を入力とした場合と同程度の分類精度が得られる場合には、話者性別情報が temporal context に十分保持されていると解釈できる。一方で、分類精度が低下する場合には、話者性別情報が Depth Transformer において文脈情報等に基づいて補完されている可能性が示唆される。

4. 実験の評価

4.1 実験条件

J-Moshi モデル. 本実験では、プロービング分析に用いるシステム音声を生成するために、日本語 full-duplex 音声対話モデルである J-Moshi [8] を使用した。モデルパラメータは、Hugging Face 上で公開されている nu-dialogue/j-moshi-ext を用いた。J-Moshi は、英語のモデルである Moshi [11] を基に、日本語音声対話データを用いて追加学習された日本語モデルである。本モデルは、日本語音声対話コーパス J-CHAT [24] による事前学習の後、日本語 Callhome [25], CSJ [26], 旅行代理店対話コーパス [27] など、合計 344 時間のステレオ日本語音声対話データと、合成対話音声を用いてファインチューニングされたモデルである。

システム音声生成. システム音声を取得するための入力用ユーザ音声として、audio コーパス社の日本語対談音声データセット^{*2}を用いた。本データセットは、動画制作に関する話題を中心とした 1 対 1 の自由対談音声をステレオ収録したもので構成されており、総音声時間は約 11 時間である。実験では、データセットに含まれる 28 対話について、各対話の左右チャンネルを分離した音声対話データを使用した。なお、本データセットの音声はサンプリング周波数 44.1 kHz で収録されているため、J-Moshi への入力に際して 24 kHz にダウンサンプリングして用いた。本データセットの音声に対して音声区間検出 [28] を適用し、約 30～40 秒の長さを持つ対話区間に分割することで、入力用のユーザ音声データを構築した。これらのユーザ音声データを J-Moshi の入力として用い、この入力音声を時間方向に読み進めながら自身のシステム音声を逐次生成するオフライン推論によって、システム音声および対応する temporal context を取得した。また本実験では、分析対象データを多く確保するため、単語トークンおよび音声トークンをサン

表 1 システム音声データセットの統計量

Table 1 Statistics of the system speech dataset used for probing.

	Duration [sec]	Utterances		
		Female	Male	All
Train	98,089	23,544	5,474	29,018
Test	13,545	3,136	807	3,943
Total	111,634	26,680	6,281	32,961

プリングしながらシステム音声を生成し、1 つの入力対話に対して 8 回の試行を行った。

疑似性別ラベル付与. 生成されたシステム音声に対して話者性別分類器学習のための性別ラベルを付与した。本稿では人手によるアノテーションは労力が大きいため、Common Voice [29] で学習された話者性別分類器^{*3}により推定された疑似性別ラベルを使用した。疑似性別ラベルの付与手順としては、生成されたシステム音声に対して音声区間検出を適用し、切り出された 2 秒以上の発話単位 (utterance) に対して事前学習済みの性別分類モデルを用いて性別推定を行い、疑似ラベルを付与した。なお、プロービング分析は、1 つのシステム音声から切り出された全ての発話において推定された性別ラベルが一致する場合のみ、それらの発話を分析対象として使用した。そして、疑似性別ラベルが付与されたシステム音声データを、学習・評価セットの割合が 9: 1 となるように分割した。また、本実験で使用する疑似性別ラベルの精度検証のために、事前学習済みの話者埋め込み抽出器^{*4}と k-means を用いた実験も行い、典型的な話者埋め込みに基づく手法との整合性を確認した。k-means のクラス数数は 2 とし、学習セットを用いて各クラスに性別ラベルを割り当てた。表 1 に得られたシステム音声データセットの統計量を示す。

分類器の入力特徴量. 図 2 に示すように、temporal context および生成音声のそれぞれを入力特徴量として用い、分類器を学習する。Temporal context は 4096 次元のベクトルであり、フレームレート 12.5 Hz で取得される。プロービングにおける比較対象として、生成音声から算出した 80 次元の対数メルフィルタバンク特徴量を用いた。FFT サイズは 2048 サンプル (85.3 ms)、フレームシフトは 10 ms とした。

分類器のアーキテクチャ. 本研究では、時間方向の局所的な文脈情報を考慮する最小限のプロービング分類器として、1 層の Time Delay Neural Network (TDNN) [30] に基づく分類器を用いた。TDNN は x-vector [31] などの話者認識モデルにおいて広く用いられており、時系列音声特徴から固定長表現を得るための標準的な構成である。分類器の構造は以下の通りである。

^{*3} <https://huggingface.co/prithivMLmods/Common-Voice-Gender-Detection>

^{*4} <https://huggingface.co/speechbrain/spkrec-ecapa-voxceleb>

^{*2} <https://www.otocorpus.com/services/%E5%AF%BE%E8%AB%87>

- 線形層（入力次元 → 64）
- 1 次元畳み込み層（kernel size = 3, hidden dim = 64）
- ReLU 活性化関数
- 統計量プーリング層
- 線形層（128 → 2）

分類器の学習設定. 分類器の学習には Adam を用い、損失関数には交差エントロピー損失を用いた。また、学習データにおける性別ラベルの不均衡に対処するため、出現頻度の逆数をクラス重みとして用いた。学習率は、temporal context では 5×10^{-6} 、メルフィルタバンクでは 1×10^{-5} とし、重み減衰係数は両者ともに 1×10^{-5} とした。バッチサイズは、temporal context では 64、メルフィルタバンクでは 32 とした。Temporal context では 60 エポック、メルフィルタバンクでは 100 エポックの学習を行った。

評価尺度. 性別分類性能の評価尺度として、Accuracy, Precision, Recall, および F1 スコアを用いた。分類器の学習および評価の検証は、異なるモデルパラメータ初期値 10 通りを用いて実施し、各指標についてその平均値を最終的な評価結果として用いた。また、temporal context およびメルフィルタバンク特徴量に対して、t-SNE [32] を用いた可視化を行った。t-SNE の入力にはプロービング分類器の統計量プーリング層の出力を用い、perplexity は 20 とした。

4.2 話者分類実験

表 2 に、プロービング分析による話者分類結果を示す。分類器として、k-means はモデル学習なし、TDNN はモデル学習ありであることに注意されたい。話者埋め込みと k-means を用いた場合、分類精度は 97.87%、F1 スコアは 96.69% となった。この結果から、本実験で用いた疑似性別ラベルは典型的な話者埋め込みを用いた手法と同程度の分類性能を有していることを確認した。

Temporal context を入力特徴量とした場合、Accuracy および F1 スコアはそれぞれ 98.54%、97.75% であった。また、異なるモデルパラメータ初期値を用いて複数回学習した分類器の予測結果に対して McNemar 検定を行った結果、temporal context とメルフィルタバンク特徴量の分類精度に統計的に有意な差は確認されなかった。この結果から、両者は同程度の分類性能を示すと考えられる。本実験では、temporal context の次元数がメルフィルタバンク特徴量よりも大きいため、プロービング分類器のモデルパラメータ数が約 25 万個多くなっている。このため、temporal context を入力とした場合にやや高い性能が得られる傾向が見られた可能性があると考えられる。

4.3 分類器中間表現の可視化

Temporal context およびメルフィルタバンク特徴量に対する t-SNE による可視化結果を、それぞれ図 3 および図 4 に示す。図において、赤い点が女性話者のサンプル、青い

表 2 話者性別分類結果

Table 2 Gender classification performance.

Input	Classifier	Accuracy [%]	Precision [%]	Recall [%]	F1 [%]
Speaker embedding	k-means	97.87	97.32	96.08	96.69
Mel filterbank	TDNN	98.07	97.51	96.53	97.01
Temporal context	TDNN	98.54	97.79	97.71	97.75




図 3 temporal context を入力とした分類器の中間表現の t-SNE による可視化結果。色は疑似性別ラベルに基づき、女性話者および男性話者を示す。

Fig. 3 t-SNE visualization of the classifier hidden representations for temporal context. Colors indicate pseudo gender labels.




図 4 メルフィルタバンク特徴量を入力とした分類器の中間表現の t-SNE による可視化結果。

Fig. 4 t-SNE visualization of the classifier hidden representations for Mel filterbank features.

点が男性話者のサンプルを表す。いずれの入力特徴量においても性別ごとにクラスが形成されていることが確認できる。特に、temporal context では性別ごとの分離がより明確であり、temporal context が話者性別に関する情報を保持していると考えられる。

これらの結果から、J-Moshi では時系列モデリングの段階において、文脈情報に加えて音声の非言語情報も保持していることが示唆される。また、Depth Transformer では、

temporal context を入力として、単語トークンおよび音声トークンという異なる種類の出力を生成する。このことから、Depth Transformer では、temporal context に内在する複数の情報のうち、生成対象となるトークンの種別（単語／音声）に応じて必要な情報を選択的に利用していると考えられる。

4.4 対話中における性別一貫性の分析

本実験では、4.1 節で述べたように、音声区間検出によって切り出された全ての発話において、同一の疑似性別ラベルが付与されたシステム音声のみを分析の対象とした。その割合は全体の 68.9% であった。この結果は、話者性別という比較的単純な話者性の要素であっても、対話の進行中に一貫して生成することが容易ではないことを示している。2.2 節で述べたように full-duplex 音声対話においては、話者性を含む非言語情報を安定的に保持・制御することが依然として重要な課題である。

5. おわりに

本研究では、日本語 full-duplex 音声対話モデル J-Moshi において、非言語情報の一例である話者性別に着目し、モデル内部表現における性別情報の表出位置をプロービング分析により調査した。実験の結果、temporal context を入力とした場合に高い性別分類性能が得られ、生成されたシステム音声を入力とした場合と同程度の性能を示すことが確認された。この結果から、J-Moshi では時系列のモデリング過程で、文脈情報に加えて話者性別に関する情報も保持していると考えられる。今後は、性別以外の非言語情報への拡張に加え、Depth Transformer を含むより詳細な内部解析や、中間表現への介入による話者性制御手法の検討を進める。

参考文献

- [1] Xi, Z., Chen, W., Guo, X., He, W., Ding, Y., Hong, B., Zhang, M., Wang, J., Jin, S., Zhou, E., Zheng, R., Fan, X., Wang, X., Xiong, L., Zhou, Y., Wang, W., Jiang, C., Zou, Y., Liu, X., Yin, Z., Dou, S., Weng, R., Cheng, W., Zhang, Q., Qin, W., Zheng, Y., Qiu, X., Huang, X. and Gui, T.: The rise and potential of large language model based agents: A survey, *arXiv preprint arXiv:2309.07864* (2023).
- [2] Higashinaka, R., Inaba, M., Qi, Z., Sasaki, Y., Funakoshi, K., Moriya, S., Sato, S., Minato, T., Sakai, K., Funayama, T., Komuro, M., Nishikawa, H., Makino, R., Kikuchi, H. and Usami, M.: Dialogue system live competition goes multimodal: Analyzing the effects of multimodal information in situated dialogue systems, *Proc. IWSDS* (2024).
- [3] Yi, Z., Ouyang, J., Xu, Z., Liu, Y., Liao, T., Luo, H. and Shen, Y.: A survey on recent advances in LLM-based multi-turn dialogue systems, *ACM Comput. Surv.*, Vol. 58, No. 6 (2025).
- [4] Skantze, G.: Turn-taking in conversational systems and human-robot interaction: A review, *Computer Speech & Language*, Vol. 67, p. 101178 (2021).
- [5] Inoue, K., Lala, D., Skantze, G. and Kawahara, T.: Yeah, un-oh: Continuous and real-time backchannel prediction with fine-tuning of voice activity projection, *Proc. NAACL*, pp. 7171–7181 (2025).
- [6] Zhang, D., Li, S., Zhang, X., Zhan, J., Wang, P., Zhou, Y. and Qiu, X.: SpeechGPT: Empowering large language models with intrinsic cross-modal conversational abilities, *Findings of the Association for Computational Linguistics: EMNLP 2023*, pp. 15757–15773 (2023).
- [7] Chen, Z., Casanova, E., Chen, C., Hu, K., Pasad, A., Rastorgueva, E., Narasimhan, S. L., Deng, S., Asl, E. H., Zelasko, P., Mendelev, V., Ghosh, S., Peng, Y., Li, J., Balam, J., Lavrukhin, V. and Ginsburg, B.: Open full-duplex voice agent with speech-to-speech language model, *Proc. ASRU* (2025).
- [8] Ohashi, A., Iizuka, S., Jiang, J. and Higashinaka, R.: Towards a Japanese full-duplex spoken dialogue system, *Proc. INTERSPEECH*, pp. 1783–1787 (2025).
- [9] Lin, J., Huang, Y., Sun, M., Seide, F. and Metze, F.: Directional speech recognition with full-duplex capability, *Proc. INTERSPEECH*, pp. 2570–2574 (2025).
- [10] Hu, K., Hosseini-Asl, E., Chen, C., Casanova, E., Ghosh, S., Zelasko, P., Chen, Z., Li, J., Balam, J. and Ginsburg, B.: Efficient and direct duplex modeling for speech-to-speech language model, *Proc. INTERSPEECH*, pp. 2715–2719 (2025).
- [11] Défossez, A., Mazaré, L., Orsini, M., Royer, A., Pérez, P., Jégou, H., Grave, E. and Zeghidour, N.: Moshi: A speech-text foundation model for real-time dialogue, *arXiv preprint arXiv:2410.00037* (2024).
- [12] Chen, Z., Ai, Z., Ma, Y., Li, X. and Xu, S.: Optimizing feature fusion for improved zero-shot adaptation in text-to-speech synthesis, *EURASIP Journal on Audio, Speech, and Music Processing*, Vol. 2024, No. 28 (2024).
- [13] Zeghidour, N., Luebs, A., Omran, A., Skoglund, J. and Tagliasacchi, M.: SoundStream: An end-to-end neural audio codec, *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, Vol. 30, pp. 495–507 (2022).
- [14] Chen, S., Wang, C., Chen, Z., Wu, Y., Liu, S., Chen, Z., Li, J., Kanda, N., Yoshioka, T., Xiao, X., Wu, J., Zhou, L., Ren, S., Qian, Y., Qian, Y., Wu, J., Zeng, M., Yu, X. and Wei, F.: WavLM: Large-scale self-supervised pre-training for full stack speech processing, *IEEE Journal of Selected Topics in Signal Processing*, Vol. 16, No. 6, pp. 1505–1518 (2022).
- [15] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. u. and Polosukhin, I.: Attention is all you need, *Proc. NeurIPS*, Vol. 30 (2017).
- [16] Zhang, Q., Cheng, L., Deng, C., Chen, Q., Wang, W., Zheng, S., Liu, J., Yu, H., Tan, C.-H., Du, Z. and Zhang, S.: Omni-Flatten: An end-to-end GPT model for seamless voice conversation, *Proc. ACL*, pp. 14570–14580 (2025).
- [17] Lee, S., Kim, K.-w. and Kim, G.: Behavior-SD: Behaviorally aware spoken dialogue generation with large language models, *Proc. NAACL*, pp. 9574–9593 (2025).
- [18] Alain, G. and Bengio, Y.: Understanding intermediate layers using linear classifier probes, *ICLR* (2017).
- [19] Pérez-Mayos, L., Carlini, R., Ballesteros, M. and Wanner, L.: On the evolution of syntactic information encoded by BERT’s contextualized representations, *Proc. EACL*, pp. 2243–2258 (2021).
- [20] Salin, E., Farah, B., Ayache, S. and Favre, B.: Are vision-language transformers learning multimodal representations? A probing perspective, *Proc. AAAI*, Vol. 36, No. 10, pp. 11248–11257 (2022).
- [21] Baevski, A., Zhou, H., Mohamed, A. and Auli, M.: Wav2vec 2.0: A framework for self-supervised learning of speech representations, *arXiv preprint arXiv:2006.11477* (2020).
- [22] Hsu, W.-N., Bolte, B., Tsai, Y.-H. H., Lakhota, K., Salakhut-

- dinov, R. and Mohamed, A.: HuBERT: Self-supervised speech representation learning by masked prediction of hidden units, *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, Vol. 29, pp. 3451–3460 (2021).
- [23] Chiu, A. Y. F., Fung, P. K. C., Li, R. T. Y., Li, J. and Lee, T.: A large-scale probing analysis of speaker-specific attributes in self-supervised speech representations, *arXiv preprint arXiv:2501.05310* (2025).
- [24] Nakata, W., Seki, K., Yanaka, H., Saito, Y., Takamichi, S. and Saruwatari, H.: J-CHAT: Japanese large-scale spoken dialogue corpus for spoken dialogue language modeling, *arXiv preprint arXiv:2407.15828* (2024).
- [25] Canavan, A. and Zipperlen, G.: CALLHOME Japanese speech (1996). LDC96S37, Linguistic Data Consortium, Philadelphia.
- [26] Maekawa, K.: Corpus of Spontaneous Japanese: Its design and evaluation, *Proc. ISCA & IEEE Workshop on Spontaneous Speech Processing and Recognition* (2003).
- [27] Inaba, M., Chiba, Y., Qi, Z., Higashinaka, R., Komatani, K., Miyao, Y. and Nagai, T.: Travel agency task dialogue corpus: A multimodal dataset with age-diverse speakers, *ACM Transactions on Asian and Low-Resource Language Information Processing*, Vol. 23, No. 9, pp. 1–23 (2024).
- [28] Silero Team: Silero VAD: pre-trained enterprise-grade Voice Activity Detector (VAD), Number Detector and Language Classifier (2024).
- [29] Ardila, R., Branson, M., Davis, K., Kohler, M., Meyer, J., Henretty, M., Morais, R., Saunders, L., Tyers, F. and Weber, G.: Common Voice: A massively-multilingual speech corpus, *Proc. LREC*, pp. 4218–4222 (2020).
- [30] Waibel, A., Hanazawa, T., Hinton, G., Shikano, K. and Lang, K.: Phoneme recognition using time-delay neural networks, *IEEE Transactions on Acoustics, Speech, and Signal Processing*, Vol. 37, No. 3, pp. 328–339 (1989).
- [31] Snyder, D., Garcia-Romero, D., Sell, G., Povey, D. and Khudanpur, S.: X-Vectors: Robust DNN embeddings for speaker recognition, *Proc. IEEE ICASSP*, pp. 5329–5333 (2018).
- [32] van der Maaten, L. and Hinton, G.: Visualizing data using t-SNE, *Journal of Machine Learning Research*, Vol. 9, No. 86, pp. 2579–2605 (2008).