


[S3-P34] 音楽基盤モデルは音高情報を螺旋構造に埋め込む


八木 颯斗¹, 高道 慎之介^{1,2}, 佐藤 りん³, 田中 啓太郎³, 森島 繁生³ (¹慶應義塾大学, ²東京大学, ³早稲田大学)

1. はじめに

- 人間の音高知覚
 - pitch height: 周波数の高低に対応する1次元的な量
 - pitch class: 音名に対応する周期的な性質
 - オクターブ等価性を反映した音高螺旋モデルを提唱 [1]
- 音楽基盤モデル [2]
 - 大規模な音楽データセットによって事前学習
 - 生成・解析・検索など, 幅広い音楽タスクで高性能
 - 一方, 内部で音楽的概念をどのように表現しているかは未解明




音楽基盤モデルは音高情報を螺旋構造に埋め込むか？



2. 提案法

- 全体像:



- 螺旋フィッティング関数: ①

$$y(t) = \underbrace{h(t)}_{\text{高さ}} \cdot \underbrace{c}_{\text{高さ}} + \underbrace{r(t)}_{\text{半径}} \{ \underbrace{\cos \theta(t)}_{\text{位相}} \cdot \underbrace{u}_{\text{正規直交基底}} + \underbrace{\sin \theta(t)}_{\text{正規直交基底}} \cdot \underbrace{v}_{\text{正規直交基底}} \}$$

t : 音高インデックス

$$h(t) = h_{\text{pitch}} \cdot t + h_0$$

高さ変化係数 初期高さ

$$r(t) = r_{\text{slope}} \cdot t + r_0$$

半径変化係数 初期半径


$$\theta(t) = \omega_{\text{chroma}}(t - t_0)$$

角周波数 回転の初期位置

- Helicity スコア [3]: ②

- 3次元特徴と螺旋関数との平均2乗誤差の逆数

$$\text{Helicity} = \left(\frac{1}{N_{\text{key}} \sum_{t=1}^{N_{\text{key}}} |x_t - y(t)|^2} \right)^{-1}$$



3. 実験的評価

3.1 実験条件


- データ条件
 - 音高範囲:
 - C3-B5の3オクターブ ($N_{\text{key}}=36$)
 - 楽器単音データセット:
 - SynTheory notes (92楽器)[4]
 - 人工音データセット:
 - 調波成分の異なる137種の人工音
- モデル条件
 - 14種の音楽基盤モデルの全層 [5-8]
- PCA条件: 第1-第5主成分まで算出
- 螺旋関数フィッティング条件
 - パラメータ最適化: Optuna [9]

3.2 入力特徴 Helicity

	Helicity (乱数差)
3次元乱数	0.371 (—)
Log-Mel	0.644 (+0.273)
Jukebox VQ-VAE [10]	top-level 0.508 (+0.137)
	middle-level 0.521 (+0.150)
	bottom-level 0.540 (+0.169)
MusicGen EnCodec [11]	0.586 (+0.215)


- Helicityが3次元乱数を上回る:
 - 入力特徴は**わずかに**音高螺旋構造を有する。
 - 入力特徴からのHelicity改善量をもとにモデル内部での明瞭化を評価する。

3.3 Helicity改善量 (H-Imp) の推移



- 全てのモデルの多くの層で**Helicity改善量が正** → **Transformer 層が内在音高螺旋を形成する。**


3.4 高Helicityにおける螺旋形状の例



- Hammond organ**: 1オクターブで**1周**
 - 人間の音高知覚に基づく螺旋構造と整合
- Electric clean guitar**: 1オクターブで**2周**
 - 半オクターブ離れた音も同位相となる。
- 入力音色に応じて, モデル内部の音高関係が異なる周期性で表現される可能性。

3.5 内在音高螺旋の形成要因: 重回帰分析

どの入力音で螺旋が明瞭になるか？



- 調波を制御した人工音でHelicityを算出
 - 例: Decay, Flat
- 目的変数: 層最大 Helicity
- 説明変数: 当該信号成分の有無 (2値変数)
- f_0 との比が**2ⁿ**となる調波成分が**正の係数**
- その他の調波成分は**負の係数**
- **オクターブ等価の調波**が螺旋形成を**促進**,
その他の調波が**阻害**する。

どのモデル構成で螺旋が明瞭になるか？

- 目的変数:
 - 層最大 Helicity (layer_peak)
 - 層方向の回帰傾き (layer_slope)
- 説明変数:
 - モデル構成5項目 (2値変数 or 連続変数)

	is_enc	hours	ctx.	fps	dim	R ²
layer_peak	-0.06	-0.03	-0.11	-0.13	0.20	0.69
layer_slope	-0.35	-0.02	-0.01	-0.10	0.06	0.77

※ 太字は $p < 0.05$ の係数

- 中間表現次元が layer_peak に**正の係数** → 高次元なモデルほどモデル内部で明瞭な内在音高螺旋が観測される。
- Encoder型**が層方向傾きに**負の係数** → **Decoder型**はEncoder型より深層に向かつて内在音高螺旋が明瞭化する。

Reference

- [1] R. N. Shepard, Psychological Review, 1982 [4] M. Wei, ISMIR, 2024 [7] M. Won, arXiv, 2023 [10] A. van den Oord, NeurIPS, 2017
[2] Y. Ma, arXiv, 2024 [5] P. Dhariwal, arXiv, 2020 [8] Y. Li, arXiv, 2023 [11] A. Défossez, ICLR, 2024
[3] S. Sridhar, ISMIR, 2020 [6] J. Copet, NeurIPS, 2023 [9] T. Akiba, ACM SIGKDD, 2019