

2026年8月 MUS研究会 Day3-PM1 (48)

音楽基盤モデルにおける モデル構成と内在音高螺旋の関係

八木 颯斗¹，高道 慎之介^{1,2}，佐藤 りん³，田中 啓太郎³，森島 繁生³


(1: 慶應義塾大学, 2: 東京大学, 3: 早稲田大学)



研究背景

音楽基盤モデルの現状と課題

- 音楽基盤モデルは {生成, 解析, 検索} など多様なタスクで高い性能を示す。
- 一方、内部で音楽的概念をどのように表現しているかは未解明




音楽基盤モデルは音高情報を螺旋構造に埋め込む

- 単音を入力した際の基盤モデルの中間表現に**螺旋構造**が出現 [Yagi, 2025]

- 人間の音高知覚も同じく**螺旋構造**で説明可能 [Sheard, 1982]
 - 周期的な音名 (pitch class) と音の高さ (pitch height) から構成

→ 人間の知覚と基盤モデルの内部表現が一致することを示唆



ご報告・御礼

- 過去のMUS研究会でいただいた貴重なご意見に支えられ、


ISMIR 2026 採択

山下記念研究賞 受賞

- 貴重なご議論・ご助言をいただいた皆様に心より御礼申し上げます。


音響特徴と内在音高螺旋の関係

- 内在音高螺旋は入力音の倍音に反応する [Yagi, 2026].
 - オクターブ倍音が螺旋形成を促進し、その他の倍音が阻害する。



モデル構成と内在音高螺旋の関係

- 先行研究[Yagi, 2025]では **一部のモデル系列のみ** を分析
 - 基盤モデルの違いが内在音高螺旋に与える影響は**未調査**




- また、**どのモデル構成**によって、内在音高螺旋が生じるのか？
→ {音楽, 音声, 一般音} 基盤モデルを含む**合計 26 基盤モデル**を分析


関連研究

音響基盤モデル

- 大規模な音響データから汎用表現を学習したモデル
 - 音楽基盤モデル (MERT [Li, 2023], Jukebox [Dhariwal, 2020] など)
 - 音声基盤モデル (HuBERT [Hsu, 2021], WavLM [Chen, 2022] など)
 - 一般音基盤モデル (AST [Gong, 2021], AudioGen [Kreuk, 2023] など)
- Decoder型**でも中間表現を下流タスクの特徴量として利用可能 [Castellon, 2021]
 - Encoder型**
 - Decoder型**



音楽基盤モデルにおける内在音高螺旋の分析 [Yagi, 2025]



螺旋フィッティング関数

高さ方向

回転方向

$$\mathbf{y}(t) = \underbrace{h(t)}_{\text{高さ}} \cdot \underbrace{\mathbf{c}}_{\text{半径}} + r(t) \{ \underbrace{\cos \theta(t)}_{\text{位相}} \cdot \mathbf{u} + \sin \theta(t) \cdot \mathbf{v} \}$$

高さ

半径

位相

$\{\mathbf{c}, \mathbf{u}, \mathbf{v}\}$: 正規直交基底

t : 音高インデックス

$$h(t) = h_{\text{pitch}} \cdot t + h_0$$


高さ変化係数 初期高さ

$$r(t) = r_{\text{slope}} \cdot t + r_0$$

半径変化係数 初期半径

$$\theta(t) = \omega_{\text{chroma}}(t - t_0)$$


角周波数 回転の初期位置



Helicityスコア


スコアが高い＝綺麗な螺旋

$$\text{Helicity} = \left(\frac{1}{N_{\text{key}}} \sum_{t=1}^{N_{\text{key}}} |x_t - y(t)|^2 \right)^{-1}$$




フィッティング

Helicity



誤差計算

Jukebox top 5B における内在音高螺旋 [Yagi, 2026]




- モデルの**深い層**で音高情報を**明瞭な螺旋構造**として埋め込む。
→ 別モデルでは内在音高螺旋の明瞭さはどの程度変わるのか？

分析手法

分析手法 1：種々の基盤モデルへの適用


- 内在音高螺旋解析の枠組みを**多種の基盤モデル**に適用
 - 異なるモデル構成を持つ基盤モデルを，共通の枠組みで比較
 - 基盤モデルの違いが内在音高螺旋の形成に与える影響を分析



分析手法 2 : Helicity 集計量

※ $\langle \cdot \rangle$: 添字方向に平均する演算子


- $\{\text{モデル } m, \text{楽器 } i, \text{層 } l\}$ の組に対して得られる Helicity を $H_{m,i,l}$ と表す。



- **Helicity** : 各モデル・各層における楽器間平均 $\langle H_{m,i,l} \rangle_i$
- **層平均 Helicity** : 各モデルにおける層間平均 $\langle \langle H_{m,i,l} \rangle_i \rangle_l$
- **層最大 Helicity** : 各モデルにおける層方向の最大値 $\max_l \langle H_{m,i,l} \rangle_i$

入力特徴 Helicity：入力特徴に対する Helicity スコア

- 各モデルの**入力特徴**に対しても同一の内在音高螺旋の解析を適用
 - 入力特徴には層方向の区別がないため、モデル m に対応する入力特徴と楽器 i の組に対して得られる Helicity を $H_{m,i}^{(\text{in})}$ 表す.
 - 入力特徴 Helicity**： $H_{m,i}^{(\text{in})}$ を楽器間で平均した $\langle H_{m,i}^{(\text{in})} \rangle_i$.




Helicity 改善量 (Helicity improvement ; H-Imp)

- 各モデル・各層のHelicity から，入力特徴Helicityを差し引いた

$$\langle H_{m,i,l} \rangle_i - \langle H_{m,i}^{(\text{in})} \rangle_i$$

- 正の **Helicity 改善量** を，モデル本体による**内在音高螺旋の追加的な明瞭化**として解釈する．



分析手法3：各モデル構成の影響の定量化

- 各目的変数に対して重回帰分析を実施

当該モデル構成の影響

$$\underbrace{y}_{\text{Helicity集計量}} = \underbrace{\beta_0}_{\text{切片}} + \sum_{j=1}^k \underbrace{\beta_j x_j}_{\text{モデル構成を表す 2値変数/連続変数}} + \underbrace{\varepsilon}_{\text{残差}}$$

各モデル構成要因
についての総和

k：説明変数の数

- 以下の5種の目的変数を用いる。
 - 層平均 Helicity：各モデルにおける層間平均 $\langle \langle H_{m,i,l} \rangle_i \rangle_l$
 - 層最大 Helicity：各モデルにおける層方向の最大値 $\max_l \langle H_{m,i,l} \rangle_i$
 - 層平均 Helicity 改善量：各モデルの層間平均 $\langle \langle H_{m,i,l} \rangle_i - \langle H_{m,i}^{(\text{in})} \rangle_i \rangle_l$
 - 層最大 Helicity 改善量：各モデルの層方向の最大値 $\max_l \left(\langle H_{m,i,l} \rangle_i - \langle H_{m,i}^{(\text{in})} \rangle_i \right)$
 - s_{layer} ：正規化したTransformer層インデックスに対する Helicity の回帰傾き

実験の評価

実験条件：モデル（1/2）

Music foundation models		Transformer	data	input feat.	Ctx.	frame rate	Dim.
Jukebox [Dhariwal, 2020]	top-5B	Decoder	60k-120k h	top VQ-VAE	24 s	345 Hz	4800
	top-1B					2048	
	middle			middle VQ-VAE	6 s	1378 Hz	1920
	bottom			bottom VQ-VAE	1.5 s	5513 Hz	
MusicGen [Copet, 2023]	large		20k h	EnCodec [Défossez, 2024]	30 s	50 Hz	2048
	medium						1536
	small						1024
	melody						1536
MusicFM [Won, 2023]	FMA	Encoder	0.9k h	Log-Mel	30 s	25 Hz	1024
	MSD		50k-100k h				
MERT [Li, 2023]	v1-330M		160k h		5 s	75 Hz	1024
	v1-95M		20k h				
	v0-95M		1k h			50 Hz	768
	v0-95M -public		0.9k h				


実験条件：モデル（2/2）

Speech foundation models		Transformer	data	input feat.	Ctx.	frame rate	Dim.
wav2Vec 2.0 [Baevski, 2020]	base	Encoder	960 h	Log-Mel	15.6 s	50 Hz	768
	large		60k		20 s		1024
WavLM [Chen, 2022]	base		960 h		15.6 s		768
	large		94k h				1024
HuBERT [Hsu, 2021]	base		960 h				768
	large		60k h				1024
	xlarge						1280
Qwen3-TTS [Hu, 2026]	0.6B-base	Decoder	>5M h	Qwen3-TTS-Tokenizer-12Hz	>524 s	12.5 Hz	1024
	1.7B-base						2048
General-audio foundation models							
AST [Gong, 2021]		Encoder	5.7k h	Log-Mel	10 s	9.9 Hz	768
ATST-frame [Li, 2024]	base		5.3k h			25 Hz	
AudioGen [Kreuk, 2023]	medium	Decoder	4k h	EnCodec			50 Hz

各モデルの入力特徴 (Input feat.)

→ : Encoder
→ : Decoder

- **Encoder** : Log-Mel スペクトログラム
- **Decoder** : 対応するトークナイザによって得られた量子化表現



実験条件：データ，フィッティング条件


データ	SynTheory [Wei, 2024]	Notes	音高範囲：C3~B5 ， 92楽器 の合成音源 カテゴリ：General MIDIに基づく分類
フィッティング	Optuna [Akiba, 2019]	SynTheory：試行回数1000回，乱数による繰り返し3回 → 最も良いHelicalityスコアを採用 角周波数範囲：1オクターブで最低1周 $\rightarrow \pi/6 \leq \omega_{\text{chroma}} \leq \pi/2$	

入力特徴 Helicality


		入力特徴Helicality (乱数差)
3次元乱数 [yagi, 2026]		0.371 (—)
Log-Mel スペクトログラム		0.644 (+0.273)
Jukebox VQ-VAE	top-level	0.508 (+0.137)
	middle-level	0.521 (+0.150)
	bottom-level	0.540 (+0.169)
MusicGen EnCodec		0.586 (+0.215)
AudioGen EnCodec		0.768 (+0.379)
Qwen3-TTS-Tokenizer-12Hz		0.858 (+0.487)

- 全ての入力特徴 Helicality が3次元乱数のスコアを上回る。
→ 入力特徴は**わずかに音高螺旋構造を有する**。

全体分析：層最大 Helicity 改善量




- 全ての基盤モデルで 層最大 H-Imp が正
→ **Transformer層**が内在音高螺旋を明瞭化



- 上位 6 モデルはすべて **音楽基盤モデル**
→ 音楽基盤モデルで特に **大きく明瞭化**
- 一方, **AudioGen-medium** も高い H-Imp
→ 学習対象領域以外のモデル構成要因の関与

全体分析：Helicality 改善量 (H-Imp) の推移



- 音楽基盤モデルでは広い層範囲で **H-Imp > 0**
→ 内在音高螺旋が特定層に限らず保持・明瞭化される。
- また、層方向の H-Imp 推移はモデルによって異なる。

モデル構成の影響：重回帰分析

※ 太字は $p < 0.05$ の係数

目的変数	is_enc	hours	ctx	fps	dim	music	R^2
層平均 H	-0.08	0.01	-0.04	-0.03	0.00	0.12	0.45
層最大 H	-0.12	0.01	-0.04	-0.07	0.12	0.17	0.68
層平均 H-Imp	-0.10	0.00	-0.09	-0.04	0.04	0.14	0.67
層最大 H-Imp	-0.13	0.00	-0.09	-0.07	0.16	0.18	0.78
S_{layer}	-0.41	-0.05	-0.14	-0.12	0.07	-0.03	0.78

- 説明変数 計6種 (※ 多重共線性は確認されなかった.)
 - バイナリ変数：is_enc (encoder型(1) or decoder型(0)),
music (音楽データを含む(1) or 含まない(0))
 - 連続変数：hours (学習データ量 [時間]), ctx (コンテキスト長 [秒]),
fps (フレームレート [Hz]), dim (中間表現次元数)

モデル構成の影響：重回帰分析（1/4）

※ 太字は $p < 0.05$ の係数

目的変数	is_enc	hours	ctx	fps	dim	music	R^2
層平均 H	-0.08	0.01	-0.04	-0.03	0.00	0.12	0.45
層最大 H	-0.12	0.01	-0.04	-0.07	0.12	0.17	0.68
層平均 H-Imp	-0.10	0.00	-0.09	-0.04	0.04	0.14	0.67
層最大 H-Imp	-0.13	0.00	-0.09	-0.07	0.16	0.18	0.78
S_{layer}	-0.41	-0.05	-0.14	-0.12	0.07	-0.03	0.78



- Helicality よりも Helicality 改善量の決定係数の方が**大きい**
 - **H-Imp**を目的変数とすると、モデル構成による**説明力が向上**
 - 入力特徴 Helicality を差し引くことで、**入力由来の影響を切り分け**
- H-Imp は**モデル内部の変化**とモデル構成との関係を**より明確に評価**

モデル構成の影響：重回帰分析（2/4）

※ 太字は $p < 0.05$ の係数

目的変数	is_enc	hours	ctx	fps	dim	music	R^2
層平均 H	-0.08	0.01	-0.04	-0.03	0.00	0.12	0.45
層最大 H	-0.12	0.01	-0.04	-0.07	0.12	0.17	0.68
層平均 H-Imp	-0.10	0.00	-0.09	-0.04	0.04	0.14	0.67
層最大 H-Imp	-0.13	0.00	-0.09	-0.07	0.16	0.18	0.78
S_{layer}	-0.41	-0.05	-0.14	-0.12	0.07	-0.03	0.78

- music は H-Imp に対して、**有意な正の係数**
→ 音楽データを含むモデルほど **Helicality 改善量**が大きい
- hours は H-Imp への**寄与はほぼ 0**，**有意な関係なし**

→ **データ量**よりも，**音楽データの有無**が内在音高螺旋の明瞭化と関係

モデル構成の影響：重回帰分析（3/4）

※ 太字は $p < 0.05$ の係数

目的変数	is_enc	hours	ctx	fps	dim	music	R^2
層平均 H	-0.08	0.01	-0.04	-0.03	0.00	0.12	0.45
層最大 H	-0.12	0.01	-0.04	-0.07	0.12	0.17	0.68
層平均 H-Imp	-0.10	0.00	-0.09	-0.04	0.04	0.14	0.67
層最大 H-Imp	-0.13	0.00	-0.09	-0.07	0.16	0.18	0.78
S_{layer}	-0.41	-0.05	-0.14	-0.12	0.07	-0.03	0.78

- dim は層最大 Helicity/H-Imp に対して、有意な正の係数
→ 中間表現次元が大きいほど、層最大 Helicity / H-Imp が大きい
- 一方、層平均では有意な関係なし

→ 高次元化は全層ではなく、特定層で螺旋を明瞭化

モデル構成の影響：重回帰分析（4/4）

※ 太字は $p < 0.05$ の係数

目的変数	is_enc	hours	ctx	fps	dim	music	R^2
層平均 H	-0.08	0.01	-0.04	-0.03	0.00	0.12	0.45
層最大 H	-0.12	0.01	-0.04	-0.07	0.12	0.17	0.68
層平均 H-Imp	-0.10	0.00	-0.09	-0.04	0.04	0.14	0.67
層最大 H-Imp	-0.13	0.00	-0.09	-0.07	0.16	0.18	0.78
s_{layer}	-0.41	-0.05	-0.14	-0.12	0.07	-0.03	0.78

- **Encoder型**ほど s_{layer} が**有意に小さい**
→ Encoder型では**深層ほど Helicality が低下**
- 一方、螺旋の明瞭さを表す 4 指標とは**有意な関係なし**

→ Encoder/Decoder の違いは、螺旋の明瞭さよりも**層方向の推移**に反映

まとめ

- 目的
 - 多種の基盤モデルにおける内在音高螺旋の比較
 - モデル構成と螺旋の明瞭さ・層方向推移との関係进行分析
- 分析手法
 - {音楽, 音声, 一般音} の計26モデルに共通の内在音高螺旋解析を適用
 - 重回帰分析により, 内在音高螺旋の形成とモデル構成との関係を定量化
- 評価結果
 - 全モデルで螺旋が形成され, 音楽基盤モデルでは大きく・広範囲に明瞭化
 - {音楽データの有無, 中間表現次元, Encoder/Decoder構造} が関係
- 結論
 - 音楽データを学習し, 高次元表現を持つモデルほど螺旋が明瞭になる傾向
 - Encoder/Decoder構造は, 螺旋の明瞭さよりも層方向の推移と関係

今後の展望

- 表現形成の因果検証
 - モデル構成を独立に変更した統制実験
→ 明瞭な内在音高螺旋を形成する設計条件を特定
- 知覚整合性とモデル性能の関係を検証
 - Helicalityと下流タスク性能の関係を調査
→ Helicality は表現の有用性を捉える指標になり得るか？
- 内在音高螺旋の知見を制御へ応用
 - 螺旋を用いた {補間, 補外} による音高制御
→ 微分音, 3 オクターブ外の音を生成可能か？
 - 螺旋形状を変化させ, 音色を制御
→ 内部表現から音高を保ったまま音色を操作可能か？

補足

モデル構成

Model	Transformer	Layers	Params	Training data	Input baseline	Ctx.	Stride	Fs	Frame rate	Dim.
Music foundation models										
Jukebox-top-5B	Decoder	72	5B	60k–120k hours	Top-level VQ-VAE	24 s	2.9 ms	44.1 kHz	345 Hz	4,800
Jukebox-top-1B	Decoder	72	1B	60k–120k hours	Top-level VQ-VAE	24 s	2.9 ms	44.1 kHz	345 Hz	2,048
Jukebox-middle	Decoder	72	1B	60k–120k hours	Middle-level VQ-VAE	6 s	0.73 ms	44.1 kHz	1378 Hz	1,920
Jukebox-bottom	Decoder	72	1B	60k–120k hours	Bottom-level VQ-VAE	1.5 s	0.18 ms	44.1 kHz	5513 Hz	1,920
MusicGen-large	Decoder	48	3.3B	20k hours	MusicGen EnCodec	30 s	20 ms	32 kHz	50 Hz	2,048
MusicGen-medium	Decoder	48	1.5B	20k hours	MusicGen EnCodec	30 s	20 ms	32 kHz	50 Hz	1,536
MusicGen-small	Decoder	24	300M	20k hours	MusicGen EnCodec	30 s	20 ms	32 kHz	50 Hz	1,024
MusicGen-melody	Decoder	48	1.5B	20k hours	MusicGen EnCodec	30 s	20 ms	32 kHz	50 Hz	1,536
MusicFM-FMA	Encoder	12	330M	0.9k hours	Log-Mel spectrogram	30 s	40 ms	24 kHz	25 Hz	1,024
MusicFM-MSD	Encoder	12	330M	50k–100k hours	Log-Mel spectrogram	30 s	40 ms	24 kHz	25 Hz	1,024
MERT-v1-330M	Encoder	24	330M	160k hours	Log-Mel spectrogram	5 s	13.3 ms	24 kHz	75 Hz	1,024
MERT-v1-95M	Encoder	12	95M	20k hours	Log-Mel spectrogram	5 s	13.3 ms	24 kHz	75 Hz	768
MERT-v0-95M	Encoder	12	95M	1k hours	Log-Mel spectrogram	5 s	20 ms	16 kHz	50 Hz	768
MERT-v0-95M-public	Encoder	12	95M	0.9k hours	Log-Mel spectrogram	5 s	20 ms	16 kHz	50 Hz	768
Speech foundation models										
wav2Vec 2.0-base	Encoder	12	95M	960 hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	768
wav2Vec 2.0-large	Encoder	24	317M	60k hours	Log-Mel spectrogram	20 s	20 ms	16 kHz	50 Hz	1,024
WavLM-base	Encoder	12	95M	960 hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	768
WavLM-large	Encoder	24	317M	94k hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	1,024
HuBERT-base	Encoder	12	95M	960 hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	768
HuBERT-large	Encoder	24	317M	60k hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	1,024
HuBERT-xlarge	Encoder	48	1B	60k hours	Log-Mel spectrogram	15.6 s	20 ms	16 kHz	50 Hz	1,280
Qwen3-TTS-12Hz-0.6B-base	Decoder	28	0.6B	>5M hours	Qwen3-TTS-Tokenizer-12Hz	>524 s	80 ms	24 kHz	12.5 Hz	1,024
Qwen3-TTS-12Hz-1.7B-base	Decoder	28	1.7B	>5M hours	Qwen3-TTS-Tokenizer-12Hz	>524 s	80 ms	24 kHz	12.5 Hz	2,048
General-audio foundation models										
AST	Encoder	12	87M	5.7k hours	Log-Mel spectrogram	10.2 s	10 ms	16 kHz	9.9 Hz	768
ATST-frame-base	Encoder	12	86M	5.3k hours	Log-Mel spectrogram	10 s	40 ms	16 kHz	25 Hz	768
AudioGen-medium	Decoder	48	1.5B	4k hours	AudioGen EnCodec	10 s	20 ms	16 kHz	50 Hz	1,536

トークナイザの概要


トークナイザ	学習領域	データ量	CB	Card.	次元
Jukebox VQ-VAE (bottom / middle / top)	M	60k–120k hours	1	2048	64
MusicGen EnCodec (32 kHz)	M	20k hours	4	2048	128
AudioGen EnCodec (16 kHz)	A+M	4k hours	4	2048	128
Qwen3-TTS-Tokenizer-12Hz	S	>5M hours	16	2048	512

Jukebox：階層的な音楽生成モデル [Dhariwal, 2020]

- 3つのレベルのVQ-VAE [Van Den Oord, 2017] によって音楽信号を離散トークン化
 - Top**：最も圧縮率が高い．**大域な情報**を捉える．
 - Middle**：中間の圧縮率
 - Bottom**：最も圧縮率が低い．**局所的な情報**を捉える．
- TransformerベースのDecoderLMで
階層的にトークン生成


1 トークンあたりの受容野

Top: 1トークン = 2.9ms
Middle: 1トークン = 0.73ms
Bottom: 1トークン = 0.18ms




MusicGen：非階層的な音楽生成モデル [Copet, 2023]

- **EnCodec** [Défossez, 2022]によって音楽信号を離散トークン化
- **DecoderLM**でトークン列生成



MusicFM：ランダム量子化を用いた音楽理解モデル



MERT：学習型トークナイザを用いた音楽理解モデル

