

第159回SLP研究会

Full-duplex音声対話モデルにおける 性別表現のプロービング

八木 颯斗¹，稲垣 賢斗¹，高島 悠樹²，安藤 厚志²，高道 慎之介¹

(1: 慶應義塾大学, 2: NTT株式会社)




Takamichi Laboratory
慶應義塾大学 高道研究室

背景


音声対話モデル

• カスケード型



- 各モジュールを直列に結合.
- 話者ターン制を前提.
- 対話的挙動をモジュールで制御.


• Full-duplex型




- ユーザとシステム音声を並列化.
- 発話/聴取を同時に行う.
- 対話的挙動をモデル内部で直接扱う.

Full-duplex 音声対話モデルの課題


- 発話/聴取を統合的に扱うFull-duplex 音声対話モデルにおいて、話者性が**どの表現に内在し、制御されるのか不明**.



- J-Moshi[Ohashi, 2025]では、対話の途中で**話者性が大きく変化**する場合あり。
→ 話者性の柔軟な制御や一貫性が課題。



話者性の制御による利点



- ユーザ体験の向上
 - 相手や文脈に合わせた声を応答することで、対話没入感や愛着性が向上.


本研究の目的

- 目的
 - 話者情報が内部表現のどの段階で保持・処理されているか調査.
→ 話者性制御に向けたモデル機序の理解を深める.
- 手段
 - J-Moshi を構成する Temporal Transformer の潜在表現に対して,
プロービング分析によって分類精度評価.

関連研究

Full-duplex 音声対話モデル Moshi^[D'efossez, 2024]

多様な話し方の理解や表現が可能な，リアルタイム音声対話システム




- Mimi :
 - 再帰ベクトル量子化[Zeghidour, 2022]に基づくニューラルオーディオコーデック
 - ユーザ音声のトークン化と生成されたシステム音声トークンのデコード.
- RQ-Transformer :
 - {ユーザ, システム} の音声トークン, Moshiの発話内容のマルチストリームの時系列をモデル化.

RQ-Transformer の構造

時系列情報を使う機構と各音声トークンを生成する機構で構成。

- Temporal Transformer
 - 対話の時系列情報をモデル化。
 - {ユーザ, システム}の音声トークン系列から次のトークン生成の元となる時系列特徴 **temporal context** を生成。
- Depth Transformer
 - **Temporal context** から当該ステップの**音声トークン**を生成。




Moshi の応用

- 日本語 Full-duplex 音声対話モデル J-Moshi[Ohashi, 2025] :
 - 英語のモデルである Moshi を基に，日本語音声対話データを用いて追加学習された日本語モデル
- 本研究では J-Moshi を対象にプロービング分析を行う.

プロービングによる分析

プロービングとは？：

- 深層学習モデルの中間表現に含まれる情報を解析する手法[Alain, 2018]
 - 単純な分類器を学習し、所望するラベルの分類精度を評価。




- 自己教師あり音声表現モデルのプロービング[Chiu, 2025]
 - Transformer encoder 層の初期層で話者識別精度が最も高い。
 - 層が深くなるにつれて、話者識別精度は低下。
- 一方で、Full-duplexモデルに対して同様の調査は未実施。

分析手法


分析の基本方針

- 話者性別分類タスクを行い，分類精度を評価



分析の基本方針：プロービングでの実験条件の妥当性


- 話者性別分類タスクを行い，分類精度を評価



- 話者埋め込みと音響特徴を入力した時の分類精度が**同程度**
→ 学習データや学習条件としての**制約に依存せず分類可能**
- 話者埋め込みを入力した時より，音響特徴を入力した時の精度が低下
→ 学習データや学習条件の違いによる影響あり

分析の基本方針：プロービングでの実験条件の妥当性


- 話者性別分類タスクを行い，分類精度を評価



- 話者埋め込みと音響特徴を入力した時の分類精度が同程度
→ 学習データや学習条件としての制約に依存せず分類可能
- 話者埋め込みを入力した時より，音響特徴を入力した時の**精度が低下**
→ **学習データや学習条件の違い**による影響あり

分析の基本方針：話者性別情報の有無


- 話者性別分類タスクを行い，分類精度を評価



- 音響特徴と temporal context を入力した時の分類精度が**同程度**
→ **Temporal context**で**性別情報を有する**.
- 音響特徴を入力した時より，temporal contextを入力した時の精度が低下
→ 後段 (Depth Transformer) でも性別情報が付与される.


分析の基本方針：話者性別情報の有無

- 話者性別分類タスクを行い，分類精度を評価




- 音響特徴と temporal context を入力した時の分類精度が同程度
→ Temporal contextで性別情報を有する。
- 音響特徴を入力した時より，temporal contextを入力した時の**精度が低下**
→ 後段 (Depth Transformer) でも性別情報が付与される。

プロービング用データセットの準備手順




- J-Moshiへの入力用 **ユーザ音声** を用意
- プロービングに使用する {システム音声, temporal context} を取得
- 分類器の学習のため, システム音声に擬似性別ラベルを付与

プロービング用データセットの準備手順



- J-Moshiへの入力用ユーザ音声を用意
- プロービングに使用する {システム音声, temporal context} を取得
- 分類器の学習のため, システム音声に擬似性別ラベルを付与

プロービング用データセットの準備手順




- J-Moshiへの入力用ユーザ音声を用意
- プロービングに使用する {システム音声, temporal context} を取得
- 分類器の学習のため, システム音声に**擬似性別ラベル**を付与

実験条件

入力用ユーザ音声データセット

- {システム音声, temporal context} を得るための入力用ユーザ音声を用意。
- データセット構築手順：
 - audio コーパス社の1対1の日本語対談音声データセット^{*1}を使用。
 - 各対話の左右のチャンネルを分離。
 - 音声区間検出により各対話を約30~40秒の長さを持つ対話区間に分割。




audio コーパス社のデータセット詳細

総音声時間	11時間
対話数	28
収録形式	ステレオ

^{*1}: <https://www.otocorpus.com/services/%E5%AF%BE%E8%AB%87> 22


プロービング用データセット

- 用意した入力用ユーザ音声で J-Moshi へ入力。
- プロービングに使用する {システム音声, temporal context} を取得。
 - サンプリングしながらシステム音声を生成。
 - データ量を増やすため、1つの入力対話に対して複数回試行を行う。
 - 30~40秒の入力対話に対応する{システム音声, temporal context} を得る。



擬似ラベル付与

- 分類器の学習のため、システム音声に**擬似性別ラベル**を付与。
 - 2秒以上の発話に切り出し、性別分類^{*2}を実施。
 - 推定された性別ラベルが全ての発話で一致するか否かを判定
 - 安定した対話を使用するため、**性別ラベルが一致した対話のみ**を選択する。



	Duration [sec]	Utterances		
		Female	Male	All
Train	98,089	23,544	5,474	29,018
Test	13,545	3,136	807	3,943
Total	111,634	26,680	6,281	32,961

^{*2}: <https://huggingface.co/prithivMLmods/Common-Voice-Gender-Detection>

性別分類器と評価尺度

- 分類器への入力特徴量
 - Temporal context : 4096 次元, フレームレート 12.5 Hz
 - Mel filter bank : 80 次元, FFTサイズ 2048 サンプル, フレームシフト 10 ms
- 分類器のアーキテクチャ
 - 1層の Time Delay Neural Network (TDNN) [Waibel, 1989]に基づく分類器
 - TDNN は話者認識モデル[Snyder, 2018]で広く用いられる標準的な構成.
 - アーキテクチャの詳細：
 - 線形層 (入力次元 → 64次元)
 - 1次元畳み込み層 (kernel size = 3, hidden dim = 64)
 - ReLU 活性化関数 → 統計量プーリング層 → 線形層 (128次元 → 2次元)
- 評価尺度 : Accuracy, Precision, Recall, F1スコア
 - {学習, 評価} の検証は異なるモデルパラメータ初期値10通りを用いて実施.
 - 各指標について, その平均値を最終的な評価結果とした.

実験結果

話者性別分類実験


- 話者埋め込み^{*3}と k-means :
 - 擬似性別ラベルは典型的な話者埋め込みを用いた手法と同程度の性能.
 - 話者埋め込みと Melfbank を入力した時の分類精度が同程度.
- Temporal context :
 - 高精度に分類可能であり, Melfbank の結果と統計的有意差なし.
→ Temporal context は文脈情報に加えて**話者性別情報も保持**.

Input	Classifier	Accuracy [%]	Precision [%]	Recall [%]	F1 [%]
Speaker embedding	k-means	97.87	97.32	96.08	96.69
Melfbank	1層TDNN	98.07	97.51	96.53	97.01
Temporal context	1層TDNN	98.54	97.79	97.71	97.75


*3: <https://huggingface.co/speechbrain/spkrec-ecapa-voxceleb>

分類器の中間表現の可視化


- 各特徴量を入力した時の分類器の中間表現を t-SNE_[Maaten, 2008] で可視化.
 - どちらも性別ごとにクラスターを形成.
 - 特に temporal context では分離が明確.
- 時系列モデリング段階で非言語情報も保持することが示唆.
 - Depth Transformer は token 種別（単語／音声）に応じて内在情報を選択的に利用している可能性.



Mel filter bank





Temporal context



補足：対話中における性別一貫性の分析

- 全ての発話で一貫した擬似性別ラベルである対話の割合：68.9 %
 - 生成したシステム音声のうち 31.1% の対話で性別が変動.
 - 話者性別という単純な要素でも対話の進行中に一貫して生成することが困難.
- Full-duplex 対話では非言語情報の保持/制御が依然として課題.

		
割合	68.9 %	31.1 %

まとめ

- 目的
 - J-Moshi において、話者性別情報がどのように内在するかを調査.
- 手法
 - Temporal context と音響特徴量のプロービング精度を比較.
- 評価結果
 - Temporal context からの性別分類は、音響特徴量と同程度の性能.
- 結論
 - J-Moshi は時系列モデリング段階で話者性別情報を保持.
 - 対話中の話者性別の曖昧さから、非言語情報の保持/制御が依然として課題.
- 今後の展望
 - 性別以外の非言語情報への拡張, Depth Transformer を含む詳細な内部解析.
 - 中間表現への介入による話者性制御手法の検討.

補足

Full-duplex 音声対話モデルにおける話者性制御^[Lee, 2025]

